

# Статистика

## Конспект курса

Мат-Мех, ПМИ

5–6 семестры (2015–2016)

\$Revision: 1.39 \$

## Содержание

<b>Вопросы по курсу</b>	<b>2</b>
<b>1. Выборка</b>	<b>2</b>
1.1. Выборка и эмпирическая случайная величина	2
1.2. Виды признаков	3
<b>2. Точечное оценивание</b>	<b>3</b>
2.1. Характеристики распределений	3
2.1.1. Определения и метод подстановки	3
2.1.2. Характеристики положения	4
2.1.3. Характеристики разброса	5
2.1.4. Другие характеристики	5
2.2. Свойства оценок	6
2.2.1. Определения	6
2.2.2. $\bar{m}_1$	7
2.2.3. $\bar{m}_2^{(0)}$	8
2.2.4. $\bar{F}_n$	9
2.2.5. $\bar{z}_p$	9
2.3. Метод моментов	9
2.4. Метод оценки максимального правдоподобия	10
2.4.1. Функция правдоподобия и метод	10
2.4.2. Информационное количество Фишера и эффективность оценки MLE	11
<b>3. Некоторые распределения, связанные с нормальным</b>	<b>12</b>
3.1. Распределение $\chi^2(m)$	12
3.2. Распределение Стьюдента $t(m)$	12
3.3. Квадратичные формы от нормально распределенных случайных величин	13
<b>4. Построение гипотез</b>	<b>14</b>
4.1. Построение критерия	14
4.2. Статистика критерия	15
4.3. $t$ -критерий	19
4.3.1. $\widehat{E\xi}$	19
4.3.2. $\widehat{D\xi}$	20
4.4. Гипотеза согласия с видом распределения	21
4.4.1. Критерий $\chi^2$	21

4.4.2. Критерий Колмогорова-Смирнова . . . . .	24
4.4.3. Критерий типа $\omega^2$ . . . . .	25
4.4.4. Визуальное определение согласия с распределением . . . . .	25
4.5. Гипотеза о равенстве распределений . . . . .	26
4.5.1. Проверка гипотезы о равенстве математических ожиданий . . . . .	26
<b>5. Доверительные интервалы</b>	<b>27</b>
5.1. Мотивация и определение . . . . .	27
5.2. Доверительные интервалы для математического ожидания и дисперсии в нормальной модели . . . . .	28
5.2.1. Доверительный интервал для $a$ . . . . .	28
5.2.2. Доверительный интервал для $\sigma^2$ . . . . .	28
5.3. Асимптотический доверительный интервал для математического ожидания в модели с конечной дисперсией . . . . .	29
5.4. Асимптотический доверительный интервал для параметра на основе MLE . . . . .	29
5.5. Доверительный интервал для проверки гипотезы о значении параметра . . . . .	30
<b>6. Зависимость и корреляция</b>	<b>30</b>
6.1. Вероятностная независимость . . . . .	30
6.1.1. Визуальное определение независимости . . . . .	30
6.1.2. Критерий независимости $\chi^2$ . . . . .	31
6.2. Линейная / полиномиальная зависимость . . . . .	32
6.3. Корреляционная зависимость . . . . .	33
6.3.1. Свойства корреляционного отношения . . . . .	33
6.4. Частная корреляция . . . . .	34
6.5. Значимость коэффициента корреляции . . . . .	35
6.6. Зависимость между порядковыми признаками . . . . .	35
6.6.1. Ранговый коэффициент Спирмана . . . . .	35
6.6.2. Ранговый коэффициент Кэндалла $\tau(\xi, \eta)$ . . . . .	37
6.7. Корреляционные матрицы . . . . .	37
6.8. Парная линейная регрессия . . . . .	38
<b>A. Другие полезные распределения случайных величин</b>	<b>40</b>
A.1. Пуассона . . . . .	40
A.2. Логнормальное . . . . .	40
<b>B. Свойства условного математического ожидания</b>	<b>40</b>

## Вопросы по курсу

1. Распределения и их свойства: нормальное, Стьюдента,  $\chi^2$ , экспоненциальное, Пуассона, Бернулли, биномиальное, отрицательно-биномиальное, геометрическое, логнормальное, 12, 40
3. Что такое повторная независимая выборка (два определения), 2

## 1. Выборка

### 1.1. Выборка и эмпирическая случайная величина

Пусть  $\xi$  — случайная величина с распределением  $\mathcal{P}$ .

**Определение.** Повторной независимой выборкой объема  $n$  (до эксперимента) называется набор

$$\mathbf{x} = (x_1, \dots, x_n)$$

независимых одинаково распределенных случайных величин с распределением  $\mathcal{P}$ .

**Определение.** Повторной независимой выборкой (после эксперимента) называется набор реализаций, т.е. конкретных значений  $\xi$ , случайных величин  $x_i$ . Это позволяет ввести эмпирическую случайную величину  $\bar{\xi}_n$  с дискретным распределением

$$\bar{P}_n : \begin{pmatrix} x_1 & \dots & x_n \\ 1/n & \dots & 1/n \end{pmatrix}.$$

*Замечание.* Подходящее определение выбирается по контексту.

*Замечание.* Если  $\xi$  имеет дискретное распределение, то выборку можно сгруппировать; тогда получим случайную величину  $\bar{\xi}_m$  с распределением

$$\bar{P}_m : \begin{pmatrix} x_1^* & \dots & x_m^* \\ \nu_1 & \dots & \nu_m \end{pmatrix} \quad \nu_i = \frac{n_i}{n},$$

где  $x_i^*$  — уникальные значения из выборки  $\mathbf{x}$ , а  $n_i$  — число  $x_i^*$  в  $\mathbf{x}$  (т.н. «абсолютная частота»; тогда  $\nu_i$  — «относительная частота»).

## 1.2. Виды признаков

Виды признаков случайной величины  $\xi : (\Omega, \mathcal{F}, P) \rightarrow (V, \mathfrak{A})$  характеризуются тем, что из себя представляет множество  $V$  и что можно делать с его элементами.

**Количественные признаки:**  $V \subset \mathbb{R}$

По типу операций:

- Аддитивные: заданы, т.е. имеют смысл в контексте данного признака, операции  $+$ ,  $-$
- Мультипликативные: заданы операции  $\cdot$ ,  $/$ ; признак принимает не отрицательные значения.

По типу данных:

- Непрерывные
- Дискретные

**Порядковые признаки**  $V$  — упорядоченное множество, определены отношения  $>$ ,  $=$ .

**Качественные признаки** на  $V$  заданы отношения  $=$ ,  $\neq$

**Пример.** Цвет глаз; имена.

## 2. Точечное оценивание

### 2.1. Характеристики распределений

#### 2.1.1. Определения и метод подстановки

**Определение.** Статистика — измеримая функция от выборки.

Обобщением статистики является понятие характеристики.

**Определение.** Характеристика — функционал от распределения:

$$T : \{\mathcal{P}\} \rightarrow V.$$

Где  $V$  — измеримое пространство, чтобы на нём можно было завести  $\sigma$ -алгебру.

*Замечание.* Чаще всего,  $V = \mathbb{R}$ .

Выделяют *генеральные* характеристики  $T(\mathcal{P})$  и *выборочные* характеристики  $T(\bar{P}_n)$ . Выражения для вычисления генеральных и выборочных характеристик отличаются только используемыми мерами ( $\mathcal{P}$  и  $\bar{P}_n$  соответственно).

**Определение.** *Оценка* — статистика, не зависящая от оцениваемой характеристики  $\theta$ . Оценка характеристики  $\theta$ , полученная по выборке объема  $n$ , обозначается  $\hat{\theta}_n$ .

**Определение.** Пусть  $\bar{P}_n$  — распределение эмпирической случайной величины. Тогда *эмпирическая функция распределения* есть

$$\bar{F}_n(x) = \bar{P}_n((-\infty, x)) = \int_{-\infty}^x d\bar{P}_n = \sum_{x_i: x_i \leq x} \frac{1}{n} = \frac{|\{x_i \in \mathbf{x} : x_i \leq x\}|}{n}.$$

*Утверждение.* Пусть  $\bar{F}_n$  — эмпирическая функция распределения,  $F_\xi$  — функция распределения  $\xi$ . Тогда, по теореме Гливенко-Кантелли,

$$\sup_x |\bar{F}_n(x) - F_\xi(x)| \xrightarrow{\text{a.s.}} 0.$$

Значит, при достаточно больших  $n$ , в качестве интересующей характеристики  $\theta$  распределения  $\mathcal{P}$  можем брать ее оценку  $\hat{\theta}_n$  — аналогичную характеристику  $\bar{P}_n$ .

**Определение** (Моменты и центральные моменты). Генеральные и соответствующие им выборочные характеристики  $k$ -го момента и  $k$ -го центрального момента:

$$\begin{aligned} m_k &= \int_{\mathbb{R}} x^k d\mathcal{P} & \bar{m}_k &= \int_{\mathbb{R}} x^k d\bar{P}_n = \frac{1}{n} \sum_{i=1}^n x_i^k \\ m_k^{(0)} &= \int_{\mathbb{R}} (x - m_1)^k d\mathcal{P} & \bar{m}_k^{(0)} &= \int_{\mathbb{R}} (x - \bar{m}_1)^k d\bar{P}_n = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{m}_1)^k. \end{aligned}$$

### 2.1.2. Характеристики положения

В качестве характеристики положения выделяется 1-й момент — математическое ожидание и *выборочное среднее*:

$$m_1 = E\xi, \quad \bar{m}_1 =: \bar{\mathbf{x}} = \widehat{E\xi} = E\bar{\xi}_n.$$

*Замечание.* В случае мультипликативных признаков можно посчитать среднее геометрическое; часто логарифмируют и считают среднее арифметическое.

**Определение.** Пусть  $p \in [0, 1]$  и  $F = \text{cdf}_{\mathcal{P}}$ .  $p$ -квантилью называется

$$z_p = \sup \{z : F(z) \leq p\}.$$

**Определение.** *Квартиль* есть 1/4- или 3/4-квантиль.

**Определение.** *Медиана* есть 1/2-квантиль.

**Определение.** *Мода* ( $\text{mode} \xi$ ) есть точка локального максимума плотности.

По методу подстановки можем получить аналогичные выборочные характеристики.

**Определение.** *Выборочная  $p$ -квантиль* есть такая точка  $\bar{z}_p$ , что она больше по значению  $|\mathbf{x}| \cdot p = np$  точек из выборки:

$$\bar{z}_p = \sup \{z : \bar{F}_n(z) \leq p\} = x_{[np]+1}.$$

**Определение.** *Выборочная медиана* упорядоченной выборки  $\mathbf{x} = (x_{(1)}, \dots, x_{(n)})$  есть

$$\bar{z}_{1/2} = \overline{\text{med}} = \begin{cases} x_{(k+1)} & n = 2k + 1 \\ \frac{x_{(k)} + x_{(k+1)}}{2} & n = 2k \end{cases}$$

**Определение.** *Выборочная мода* ( $\overline{\text{mode}}$ ) есть значение из выборки, которое чаще всего встречается.

### 2.1.3. Характеристики разброса

В качестве характеристики разброса выделяется 2-й центральный момент — дисперсия и выборочная дисперсия:

$$m_2^{(0)} = D\xi \quad \bar{m}_2^{(0)} =: s^2 = \widehat{D\xi} = D\bar{\xi}_n = \begin{cases} E(\bar{\xi}_n - E\bar{\xi}_n)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \\ E\bar{\xi}_n^2 - (E\bar{\xi}_n)^2 = \left( \frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2. \end{cases}$$

*Замечание.* Если среднее  $E\xi = a$  известно, то дополнительно вводится

$$s_a^2 := \begin{cases} \frac{1}{n} \sum_{i=1}^n (x_i - a)^2 \\ \left( \frac{1}{n} \sum_{i=1}^n x_i^2 \right) - a^2. \end{cases}$$

**Пример** (Оценка дисперсии оценки мат. ожидания). Пусть строится оценка мат. ожидания  $\bar{x}$ . Может интересоваться точность построенной оценки. Вычислим дисперсию теоретически, после чего оценим точность по выборке:

$$D\bar{x} = D\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n^2} \sum_{i=1}^n Dx_i = \frac{1}{n^2} \sum_{i=1}^n D\xi = \frac{D\xi}{n},$$

откуда

$$\widehat{D\bar{x}} = \frac{s^2}{n}.$$

**Пример** (Дисперсия оценки дисперсии). См. по ссылке<sup>1</sup>.

**Определение.** *Энтропия*

### 2.1.4. Другие характеристики

**Определение.** *Коэффициент асимметрии («скошенности»<sup>2</sup>)*

$$\gamma_3 = A\xi = \frac{m_3^{(0)}}{\sigma^3}.$$

**Определение.** *Коэффициент эксцесса («крутизны», «kurtosis»):*

$$\gamma_4 = K\xi = \frac{m_4^{(0)}}{\sigma^4} - 3.$$

*Замечание.* Величина  $m_4^{(0)}/\sigma^4 = 3$  соответствует стандартному нормальному распределению.

*Замечание.* При замене  $z := (\xi - E\xi)/\sigma$  величину  $m_4^{(0)}/\sigma^4 = E(z^4)$  можно интерпретировать как ожидание четвертой степени центрированных и нормированных данных. Точки выборки, лежащие внутри  $E\xi \pm \sigma$  из-за малости по модулю не будут увеличивать значение коэффициента, в то время как аутлаеры будут или «тяжелые хвосты» плотности распределения будут. Поэтому  $\gamma_4$  принимает большие значения на распределениях с «тяжелыми хвостами» или выборках с некоторым количеством аутлаеров.

<sup>1</sup><http://mathworld.wolfram.com/SampleVarianceDistribution.html>

<sup>2</sup>«Skewness».

*Замечание.* Справедлива оценка

$$\gamma_3^2 + 4 \leq \gamma_4 + 3 \leq \infty,$$

где минимум достигается  $\text{Ber}(1/2)$ .

**Определение.** Пусть  $(\xi_1, \xi_2) \sim \mathcal{P}$  и  $(x_1, y_1), \dots, (x_n, y_n) \sim \mathcal{P}(du \times dv)$ . Тогда можно записать две другие важные характеристики: *ковариацию* и *коэффициент корреляции*:

$$\begin{aligned} \text{cov}(\xi_1, \xi_2) &= \iint_{\mathbb{R}^2} (u - m_1(u))(v - m_1(v)) \mathcal{P}(du \times dv) & \overline{\text{cov}}(\mathbf{x}, \mathbf{y}) &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{\mathbf{x}})(y_i - \bar{\mathbf{y}}) \\ \text{cor}(\xi_1, \xi_2) &= \frac{\text{cov}(\xi_1, \xi_2)}{\sigma_{\xi_1} \sigma_{\xi_2}} & \overline{\text{cor}}(\mathbf{x}, \mathbf{y}) &= \frac{\overline{\text{cov}}(\mathbf{x}, \mathbf{y})}{s(\mathbf{x})s(\mathbf{y})}. \end{aligned}$$

*Замечание (Важное).*  $\xi_1 \not\parallel \xi_2 \implies \text{cov}(\xi_1, \xi_2) \neq 0$ , но  $\text{cov}(\xi_1, \xi_2) = 0 \not\implies \xi_1 \parallel \xi_2$ . Необходимость и достаточность выполняется только в случае нормального распределения.

*Замечание (Проблема моментов).* Для заданной последовательности моментов  $m_1, m_2, \dots$  не обязательно существовать подходящее распределение. Помимо требований  $m_{2k} \geq 0$  и взаимосвязи между соседними моментами по неравенству Гёльдера, существенно, что ряд Тейлора по  $m_\ell$ , в который, как известно, раскладывается характеристическая функция, должен сходиться равномерно.

## 2.2. Свойства оценок

### 2.2.1. Определения

**Определение.** *Смещение*<sup>3</sup> есть

$$\text{bias } \hat{\theta}_n := E\hat{\theta}_n - \theta \quad \forall \theta \in \Theta.$$

**Определение.** *Среднеквадратичная ошибка*<sup>4</sup> есть

$$\text{MSE } \hat{\theta}_n := E(\hat{\theta}_n - \theta)^2.$$

*Замечание.* Поскольку

$$D\hat{\theta}_n = D(\hat{\theta}_n - \theta) = E(\hat{\theta}_n - \theta)^2 - (E(\hat{\theta}_n - \theta))^2,$$

то

$$\underbrace{E(\hat{\theta}_n - \theta)^2}_{\text{MSE}} = D\hat{\theta}_n + \underbrace{(E(\hat{\theta}_n - \theta))^2}_{\text{bias}^2}.$$

Выделяются следующие свойства оценок:

**Несмещенность**  $\text{bias } \hat{\theta}_n = 0$ , т.е.

$$E\hat{\theta}_n = \theta.$$

**Состоятельность в среднеквадратичном смысле**

$$\text{MSE } \hat{\theta}_n \xrightarrow{n \rightarrow \infty} 0.$$

**Состоятельность**

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta.$$

**Асимптотическая нормальность**

$$\frac{\hat{\theta}_n - E\hat{\theta}_n}{\sqrt{D\hat{\theta}_n}} \xrightarrow{d} N(0, 1).$$

<sup>3</sup>Bias.

<sup>4</sup>Mean square error (MSE).

*Замечание.* Если  $\xi \sim N(a, \sigma^2)$ , то  $\bar{\mathbf{x}}$  — просто нормальная оценка (как линейная комбинация нормальных случайных величин).

**Предложение.** Если оценка несмещенная и состоятельная в среднеквадратичном смысле, то она состоятельная.

*Доказательство.* В самом деле, по неравенству Чебышева,

$$P(|\hat{\theta}_n - \theta| > \epsilon) = P(|\hat{\theta}_n - E\hat{\theta}_n| > \epsilon) \leq \frac{D\hat{\theta}_n}{\epsilon^2} = \frac{\text{MSE } \hat{\theta}_n}{\epsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

□

**Предложение.**  $\bar{m}_k$  является состоятельной оценкой  $m_k$ .

*Доказательство.* Докажем для  $\bar{m}_1$ . По определению выборки до эксперимента,  $x_i \sim \mathcal{P}$ . Тогда, по теореме Хинчина о ЗБЧ,

$$\bar{\mathbf{x}} = \frac{\sum_{i=1}^n x_i}{n} \xrightarrow{P} m_1(\mathcal{P}).$$

Для  $k$ -го момента доказывается аналогично заменой  $y_i := x_i^k$ .

□

*Замечание.* Для  $m_k^{(0)}$  доказательство не пройдет, потому что  $x_i$  и  $\bar{\mathbf{x}}$  не будут независимыми.

**Предложение.**  $\bar{m}_k^{(0)}$  является состоятельной оценкой  $m_k^{(0)}$ .

*Утверждение.* Пусть  $\xi_n \xrightarrow{P} c$  и  $f \in C(U_\epsilon(c))$ . Тогда  $f(\xi_n) \xrightarrow{P} f(c)$ .

*Доказательство предложения.* Докажем для  $s^2$ . Пусть  $f : (x, y) \mapsto x - y^2$ . Устроим последовательность  $(\bar{m}_2, \bar{m}_1) \xrightarrow{P} (m_2, m_1)$ . Тогда

$$f(\bar{m}_2, \bar{m}_1) = \bar{m}_2 - \bar{m}_1^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{\mathbf{x}}^2 = s^2 \xrightarrow{P} f(m_2, m_1) = D\xi.$$

Для  $m_k^{(0)}$  доказывается аналогично.

□

### 2.2.2. $\bar{m}_1$

**Предложение.**  $\bar{\mathbf{x}}$  — несмещенная оценка  $E\xi$ .

*Доказательство.* Пусть  $\theta = E\xi$ ,  $\hat{\theta}_n = E\bar{\xi}_n = \bar{\mathbf{x}}$ . Тогда

$$E\bar{\mathbf{x}} = E\frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} \sum_{i=1}^n E x_i = \frac{1}{n} \sum_{i=1}^n E\xi = E\xi \implies E\hat{\theta}_n = E\theta, \text{ bias } \hat{\theta}_n = 0.$$

□

**Пример** (Сравнение оценок мат. ожидания симметричного распределения). Пусть  $\mathcal{P}$  симметрично — в этом случае  $\widehat{\text{med } \xi} = \bar{\mathbf{x}}$  и имеет смысл сравнить две эти характеристики. Найдем среднеквадратичную ошибку  $\widehat{\text{med } \xi}$  и  $\bar{\mathbf{x}}$ . Поскольку обе эти оценки несмещенные,  $\text{MSE} = D$  и

$$\begin{aligned} D\bar{\mathbf{x}} &= \frac{D\xi}{n} \\ \widehat{D\text{med } \xi} &\sim \frac{1}{4n \text{pdf}_{N(a, \sigma^2)}(\text{med } \xi)} \quad \text{при } n \rightarrow \infty. \end{aligned}$$

Так, если  $\xi \sim N(a, \sigma^2)$ , то

$$\text{pdf}_{N(a, \sigma^2)}(\text{med } \xi) = \frac{1}{2\pi\sigma^2} \exp\left\{-\frac{(\text{med } \xi - a)^2}{\sigma^2}\right\} = \frac{1}{2\pi\sigma^2},$$

откуда

$$\widehat{D\text{med } \xi} = \frac{\pi \sigma^2}{2n} > \frac{\sigma^2}{n} = D\bar{x},$$

значит  $\widehat{\text{med } \xi}$  хуже, чем  $\bar{x}$ .

В то же время,  $\widehat{\text{med } \xi}$  более устойчив к аутлаерам, чем  $\bar{x}$ , и этим лучше.

**Предложение.**  $\bar{x}$  — состоятельная оценка  $E\xi$ .

*Доказательство.* Либо по (2.2.1) для  $k = 1$ , либо из того факта, что  $\text{bias } \bar{x} = 0$ , значит

$$\text{MSE } \bar{x} = D\bar{x} = \frac{D\xi}{n} \xrightarrow{n \rightarrow \infty} 0,$$

и по (2.2.1) получаем утверждение. □

### 2.2.3. $\bar{m}_2^{(0)}$

**Предложение.**  $s^2$  является только асимптотически несмещенной оценкой  $D\xi$ .

*Доказательство.* В самом деле,

$$Es^2 = E \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n E (x_i - \bar{x})^2.$$

По несмещенности  $\bar{x}$ ,  $E\bar{x} = E\xi$ , откуда

$$D(x_i - \bar{x}) = E(x_i - \bar{x})^2 - (E(x_i - \bar{x}))^2 = E(x_i - \bar{x})^2 - (E\xi - E\xi)^2 = E(x_i - \bar{x})^2,$$

значит

$$E(x_i - \bar{x})^2 = D\xi - D\bar{x} = D\xi - \frac{1}{n^2} \sum_{i=1}^n Dx_i = D\xi - \frac{D\xi}{n}.$$

Продолжив равенство, получим

$$\frac{1}{n} \sum_{i=1}^n E(x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n D\xi - \frac{D\xi}{n} = D\xi - \frac{D\xi}{n} = \frac{n-1}{n} D\xi \xrightarrow{n \rightarrow \infty} D\xi.$$

□

*Альтернативное доказательство.* Распишем

$$\begin{aligned} Es^2 &= E \left( \frac{1}{n} \sum_{i=1}^n x_i^2 \right) - E\bar{x}^2 = E\xi^2 - E\bar{x}^2 = E\xi^2 - \frac{E(x_1 + \dots + x_n)(x_1 + \dots + x_n)}{n^2} \\ &= E\xi^2 - \frac{1}{n^2} (nE\xi^2 + n(n-1)(E\xi)^2) = E\xi^2 - \frac{E\xi^2}{n} - \frac{(n-1)(E\xi)^2}{n} = \frac{n-1}{n} (E\xi^2 - (E\xi)^2) \\ &= \frac{n-1}{n} D\xi \xrightarrow{n \rightarrow \infty} D\xi. \end{aligned}$$

□

**Определение.** Исправленная дисперсия:

$$\tilde{s}^2 := \frac{n}{n-1} s^2.$$

**Предложение.**  $s^2$  — состоятельная оценка  $D\xi$ .

*Доказательство.* По (2.2.1) с  $k = 2$ . □



#### 2.2.4. $\bar{F}_n$

**Предложение.**  $\bar{F}_n$  — состоятельная оценка  $F$  в каждой точке.

*Доказательство.* Введем

$$y_i := \mathbf{1}_{\{x_i < x\}} = \begin{cases} 1 & x_i < x \\ 0 & x_i \geq x. \end{cases}$$

Тогда по теореме Хинчина о ЗБЧ,

$$\bar{F}_n(x) = \frac{|\{x_i \in \bar{\mathbf{x}} : x_i < x\}|}{n} = \frac{\sum_{i=1}^n y_i}{n} \xrightarrow{P} \mathbb{E} y_i = \mathbb{E} \mathbf{1}_{\{x_i < x\}} = P(x_i < x) = F(x).$$

Независимость  $y_i$  очевидна, если расписать  $F_{y_i}(x)F_{y_j}(y) = F_{y_i, y_j}(x, y)$ .  $\square$

*Замечание.* Помимо ранее упомянутых, больше нет состоятельных выборочных характеристик.

#### 2.2.5. $\bar{z}_p$

**Теорема.** Пусть  $\exists! p_0 : F(x) = p_0$  и  $F(x)$  монотонно возрастает в окрестности  $p_0$ . Тогда  $\bar{z}_{p_0} \xrightarrow{P} z_{p_0}$ , т.е. является состоятельной оценкой.

### 2.3. Метод моментов

Пусть  $\mathcal{P}(\boldsymbol{\theta})$ ,  $\boldsymbol{\theta} = (\theta_1, \dots, \theta_r)^T$  — параметрическая модель. Найдем оценки для параметров  $\hat{\theta}_i$ ,  $i \in \overline{1:r}$ , для чего составим и решим систему уравнений:

$$\begin{cases} m_1 = \phi_1(\theta_1, \dots, \theta_r) \\ \vdots \\ m_r = \phi_r(\theta_1, \dots, \theta_r) \end{cases} \implies \begin{cases} \theta_1 = f_1(m_1, \dots, m_r) \\ \vdots \\ \theta_r = f_r(m_1, \dots, m_r). \end{cases}$$

Примем

$$\hat{\theta}_i = f_i(\hat{m}_1, \dots, \hat{m}_r).$$

*Замечание.* Поскольку  $f_i$  — непрерывные функции и при непрерывных преобразованиях сходимость не портится, оценки  $\hat{\theta}_i$  являются состоятельными.

Как правило, эти оценки смещенные.

*Замечание.* Случается, что решение находится вне пространства параметров. На практике, если пространство параметров компактное, можно взять точку, ближайшую к полученной оценке. Однако это свидетельствует о том, что модель плохо соответствует данным.

**Пример 1** ( $r = 1$ ). Пусть  $\mathcal{P}_\xi(\lambda) = \text{Exp}(\lambda)$ . Тогда  $\mathbb{E}\xi = 1/\lambda$  и  $\bar{\mathbf{x}} = 1/\lambda$ .

**Пример 2** ( $r = 2$ ). Пусть  $\mathcal{P}_\xi(\theta_1, \theta_2) = \text{Bin}(m, p)$ . Тогда

$$\begin{cases} \mathbb{E}\xi = mp \\ D\xi = mp(1-p) \end{cases} \quad \begin{cases} m = \frac{\mathbb{E}\xi}{p} \\ D\xi = \mathbb{E}\xi - \mathbb{E}\xi p \end{cases} \quad \begin{cases} p = \frac{\mathbb{E}\xi - D\xi}{\mathbb{E}\xi} \\ m = \frac{(\mathbb{E}\xi)^2}{\mathbb{E}\xi - D\xi} \end{cases} \implies \begin{cases} \hat{p} = \frac{\bar{\mathbf{x}} - s^2}{\bar{\mathbf{x}}} \\ \hat{m} = \frac{\bar{\mathbf{x}}^2}{\bar{\mathbf{x}} - s^2}. \end{cases}$$

## 2.4. Метод оценки максимального правдоподобия

### 2.4.1. Функция правдоподобия и метод

Пусть  $\mathcal{P}_\xi(\boldsymbol{\theta})$ ,  $\boldsymbol{\theta} = (\theta_1, \dots, \theta_r)^T$  — параметрическая модель.

**Определение.** Функция правдоподобия:

$$\mathcal{L}(\boldsymbol{\theta} \mid \mathbf{y}) = P(\mathbf{y} \mid \boldsymbol{\theta}) = \begin{cases} P_\xi(\boldsymbol{\theta}) & \text{дискретно;} \\ p_\theta(\mathbf{y}) & \text{абсолютно непрерывно.} \end{cases}$$

**Пример 3.** Пусть  $\xi \sim N(a, \sigma^2)$ . По независимости  $x_i$ ,  $p_\theta(\mathbf{x})$  распадается в произведение:

$$\mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}) = p_\theta(\mathbf{x}) = \prod_{i=1}^n p_\theta(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x_i - a)^2}{2\sigma^2}\right\} = \frac{1}{(2\pi)^{n/2} \sigma^n} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2\right\}.$$

**Пример 4.**  $\xi \sim \text{Pois}(\lambda)$ ,

$$P(\xi = k) = \frac{\lambda^k}{k!} e^{-\lambda} \implies \mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}) = \prod_{i=1}^n \frac{1}{x_i!} \lambda^{x_i} e^{-\lambda} = \frac{1}{\prod_{i=1}^n x_i!} \lambda^{n\bar{x}} e^{-n\lambda}.$$

*Утверждение.* Пусть  $\mathbf{x}$  — выборка. В качестве оценки максимального правдоподобия<sup>5</sup>  $\hat{\boldsymbol{\theta}}_{\text{MLE}}$  следует взять

$$\hat{\boldsymbol{\theta}}_{\text{MLE}} = \underset{\boldsymbol{\theta}}{\operatorname{argmax}} \ln \mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}).$$

**Предложение.**  $\hat{\boldsymbol{\theta}}_{\text{MLE}}$  является состоятельной оценкой.

*Доказательство.* Пусть  $\boldsymbol{\theta}_0$  — истинный параметр  $\mathcal{P}(\boldsymbol{\theta})$ . По УЗБЧ,

$$\frac{1}{n} \ln \mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \ln p_\theta(x_i) \xrightarrow{P} E \ln p_\theta(x_i) = \int_{\mathbb{R}} \ln(p_\theta(x)) p_{\theta_0}(x) dx.$$

Навесим на обе стороны  $\operatorname{argmax}$  в условии, что это непрерывное преобразование:

$$\hat{\boldsymbol{\theta}}_{\text{MLE}} \leftarrow \underset{\boldsymbol{\theta}}{\operatorname{argmax}} \frac{1}{n} \ln \mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}) \xrightarrow{P} \underset{\boldsymbol{\theta}}{\operatorname{argmax}} \int_{\mathbb{R}} \ln(p_\theta(x)) p_{\theta_0}(x) dx \rightarrow \boldsymbol{\theta}^*.$$

Тогда в предположении непрерывности  $p_\theta$  по  $\boldsymbol{\theta}$ ,  $\hat{\boldsymbol{\theta}}_{\text{MLE}} \xrightarrow{P} \boldsymbol{\theta}^*$ . Покажем, что  $\boldsymbol{\theta}^* = \boldsymbol{\theta}_0$ . Поделим на  $p_{\theta_0}$  — константу по  $\boldsymbol{\theta}$ :

$$\frac{1}{n} \sum_{i=1}^n \ln \frac{p_\theta}{p_{\theta_0}}(x_i) \xrightarrow{P} \int_{\mathbb{R}} \ln \left( \frac{p_\theta(x)}{p_{\theta_0}(x)} \right) p_{\theta_0}(x) dx = E \ln \frac{p_\theta}{p_{\theta_0}} \leq \ln E \frac{p_\theta}{p_{\theta_0}} = \ln \int_{\mathbb{R}} \frac{p_\theta}{p_{\theta_0}}(x) p_{\theta_0}(x) dx = \ln 1 = 0$$

по неравенству Ёнсена  $Eg(\xi) \leq g(E\xi)$ , для выпуклой вверх  $g(x) = \log(x)$ . Таким образом,

$$\int_{\mathbb{R}} \ln \left( \frac{p_\theta(x)}{p_{\theta_0}(x)} \right) p_{\theta_0}(x) dx = 0 \iff \ln \left( \frac{p_\theta(x)}{p_{\theta_0}(x)} \right) = 0 \iff \frac{p_\theta(x)}{p_{\theta_0}(x)} = 1 \iff p_\theta(x) = p_{\theta_0}(x).$$

В предположении свойства *идентифицируемости* задачи  $(\theta_1 \neq \theta_2 \implies \mathcal{P}_{\theta_1} \neq \mathcal{P}_{\theta_2})$ , получаем  $\boldsymbol{\theta} = \boldsymbol{\theta}_0$ .  $\square$

**Пример.**  $\xi \sim \text{Pois}(\lambda)$ .

$$\ln \mathcal{L}(\lambda \mid \mathbf{x}) = - \sum_{i=1}^n x_i! - n\lambda + \ln(\lambda^{n\bar{x}}) \implies \frac{d \ln \mathcal{L}(\lambda \mid \mathbf{x})}{d\lambda} = -n + \lambda^{-n\bar{x}} n\bar{x} \lambda^{n\bar{x}-1} = -n + \frac{n\bar{x}}{\lambda}$$

откуда

$$\frac{d \ln \mathcal{L}(\lambda \mid \mathbf{x})}{d\lambda} = 0 \iff -n + \frac{n\bar{x}}{\lambda} = 0, \quad n\bar{x} - n\lambda = 0, \quad \lambda = \bar{x}.$$

<sup>5</sup>Maximum likelihood estimate (MLE).

Утверждение. В условиях регулярности<sup>6</sup>:

1. Существует один глобальный максимум, так что

$$\left. \frac{d\mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x})}{d\boldsymbol{\theta}} \right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}_{\text{MLE}}} = 0.$$

2.  $\hat{\boldsymbol{\theta}}_{\text{MLE}}$  обладает всеми свойствами:

- а) Состоятельность;
- б) Асимптотическая несмещенность;
- в) Асимптотическая нормальность;
- г) Эффективность.

#### 2.4.2. Информационное количество Фишера и эффективность оценки MLE

Пусть  $r = 1$ .

**Определение.** Информанта  $n$ -го порядка:

$$S_n(\mathbf{x}, \theta) = \frac{d^n \ln \mathcal{L}(\theta \mid \mathbf{x})}{d\theta^n}.$$

**Определение.** Информационное количество Фишера:

$$I_n(\theta) := -ES_2(\mathbf{x}, \theta).$$

Утверждение.

$$I_n(\theta) = ES_1^2(\mathbf{x}, \theta).$$

**Пример.**  $\xi \sim \text{Pois}(\lambda)$ .

$$S_1(\mathbf{x}, \theta) = -n + \frac{n\bar{x}}{\lambda}, \quad S_2(\mathbf{x}, \theta) = -\frac{n\bar{x}}{\lambda^2} \implies I_n(\lambda) = E \frac{n\bar{x}}{\lambda^2} = \frac{n}{\lambda^2} E\bar{x} = \frac{n}{\lambda}.$$

Замечание.

$$\ln \mathcal{L}(\theta \mid \mathbf{x}) = \sum_{i=1}^n \ln p_{\theta}(x_i) \implies S_2 = \frac{d^2 \ln \mathcal{L}(\theta \mid \mathbf{x})}{d\theta^2} = \sum_{i=1}^n (\ln p_{\theta}(x_i))'',$$

откуда, для повторной независимой выборки,

$$I_n(\theta) = -\sum_{i=1}^n E(\ln p_{\theta}(x_i))'' = n \cdot i(\theta), \quad \text{где } i(\theta) = -E(\ln p_{\theta}(\xi))''.$$

Утверждение. Для несмещенных оценок в условиях регулярности справедливо неравенство Рао-Крамера:

$$D\hat{\theta}_n \geq \frac{1}{I_n(\theta)}.$$

**Определение.** Эффективная оценка:

$$D\hat{\theta}_n = \frac{1}{I_n(\theta)}.$$

**Определение.** Пусть  $\hat{\theta}_n$  — асимптотически несмещенная оценка. Тогда  $\hat{\theta}_n$  — асимптотически эффективная, если

$$D\hat{\theta}_n \cdot I_n \xrightarrow{n \rightarrow \infty} 1.$$

**Пример.**  $\xi \sim \text{Pois}(\lambda)$ ,

$$D\bar{x} = \frac{\lambda}{n} = I_n(\lambda).$$

<sup>6</sup>Область, где  $x = 0$  не должна зависеть от  $\boldsymbol{\theta}$  + условия на производные (существование, ограниченность, ...).

### 3. Некоторые распределения, связанные с нормальным

#### 3.1. Распределение $\chi^2(m)$

**Определение** (Распределение  $\chi^2(m)$ ).  $\eta$  имеет распределение  $\chi^2$  с  $m$  степенями свободы:

$$\eta \sim \chi^2(m) \iff \eta = \sum_{i=1}^m \beta_i^2, \quad \beta_i \sim N(0, 1), \quad \beta_i \text{ независимы.}$$

**Свойства**<sup>7</sup>  $\chi^2(m)$

$$\begin{aligned} E\eta &= \sum_{i=1}^m E\beta_i^2 = m \\ D\eta &= 2m. \end{aligned}$$

**Утверждение.** Пусть  $\eta_m \sim \chi^2(m)$ . Тогда, по ЦПТ,

$$\frac{\eta_m - E\eta_m}{\sqrt{D\eta_m}} = \frac{\eta_m - m}{\sqrt{2m}} \xrightarrow{d} N(0, 1).$$

**Пример.**  $m = 50$ ,  $\eta_m = 80$ . Тогда

$$\frac{80 - 50}{10} = 3$$

и можно посчитать, к примеру,  $\Phi(3) \approx 0.9986$ .

#### 3.2. Распределение Стьюдента $t(m)$

**Определение** (Распределение  $t(m)$ ).  $\zeta$  имеет распределение Стьюдента с  $m$  степенями свободы, если

$$\zeta \sim t(m) \iff \zeta = \frac{\beta}{\sqrt{\eta/m}}, \quad \beta \sim N(0, 1), \quad \eta \sim \chi^2(m).$$

**Свойства**  $t(m)$

- При  $m = 1$  это распределение Коши.
- При  $m > 1$ ,  $E\zeta = 0$  по симметричности.
- При  $m > 2$ ,  $D\zeta = m/(m - 2)$ .
- При  $m > 3$ ,  $A\zeta = 0$  по симметричности.
- При  $m > 4$ ,  $K\zeta = 6/(m - 4)$ .

**Предложение.** Распределение Стьюдента сходится к стандартному нормальному:

$$t \Rightarrow N(0, 1).$$

*Соображения по поводу.*  $D\zeta \rightarrow 1$ ,  $K\zeta \rightarrow 0$ . □

---

<sup>7</sup>Вычисление  $D\eta$ : <https://www.statlect.com/probability-distributions/chi-square-distribution>

### 3.3. Квадратичные формы от нормально распределенных случайных величин

Пусть  $\boldsymbol{\xi} = (\xi_1, \dots, \xi_p)^T \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_p)$ ,  $\mathbf{B}$  — симметричная, неотрицательно определенная матрица. Найдем распределение  $\boldsymbol{\xi}^T \mathbf{B} \boldsymbol{\xi}$ .

*Утверждение.* Пусть  $\boldsymbol{\xi} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_p)$ ,  $\mathbf{B}, \mathbf{C}$  — симметричные матрицы размерности  $p \times p$ . Тогда  $\boldsymbol{\xi}^T \mathbf{B} \boldsymbol{\xi} \not\parallel \boldsymbol{\xi}^T \mathbf{C} \boldsymbol{\xi} \iff \mathbf{BC} = \mathbf{0}$ .

**Пример** (Независимость  $\bar{\mathbf{x}}^2$  и  $s^2$ ). Пусть

$$\mathbf{B} = \frac{1}{p} \begin{pmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{pmatrix};$$

тогда

$$\mathbf{x}^T \mathbf{B} \mathbf{x} = \frac{1}{p} (x_1, \dots, x_p) \begin{pmatrix} \sum_{i=1}^p x_i \\ \vdots \\ \sum_{i=1}^p x_i \end{pmatrix} = \frac{1}{p} \sum_{j=1}^p \sum_{i=1}^p x_i x_j = \frac{1}{p} \left( \sum_{i=1}^p x_i \right)^2 = p \bar{\mathbf{x}}^2.$$

В то же время, пусть

$$\mathbf{C} = \begin{pmatrix} 1 - 1/p & \dots & -1/p \\ \vdots & \ddots & \vdots \\ -1/p & \dots & 1 - 1/p \end{pmatrix};$$

тогда

$$\begin{aligned} \mathbf{x}^T \mathbf{C} \mathbf{x} &= (x_1, \dots, x_p) \begin{pmatrix} (1 - 1/p) x_1 - 1/p \cdot \sum_{i=2}^p x_i \\ \vdots \\ -1/p \cdot \sum_{i=1}^{p-1} x_i + (1 - 1/p) x_p \end{pmatrix} = (x_1, \dots, x_p) \begin{pmatrix} x_1 - 1/p \cdot \sum_{i=1}^p x_i \\ \vdots \\ x_p - 1/p \cdot \sum_{i=1}^p x_i \end{pmatrix} \\ &= \sum_{j=1}^p \left( x_j^2 - \frac{1}{p} \sum_{i=1}^p x_i x_j \right) = \sum_{j=1}^p x_j^2 - p \bar{\mathbf{x}}^2 = p s^2. \end{aligned}$$

Но, учитывая  $\mathbf{B}^2 = \mathbf{B}$  (легко проверяется),

$$\mathbf{C} = \mathbf{I}_p - \mathbf{B} \implies \mathbf{BC} = \mathbf{B} - \mathbf{B}^2 = \mathbf{0},$$

откуда  $\bar{\mathbf{x}}^2 \not\parallel s^2$ .

Видно, что  $\sigma^{-2} \boldsymbol{\xi}^T \mathbf{I}_p \boldsymbol{\xi} \sim \chi^2(p)$ . На самом деле справедливо

*Утверждение.* Пусть  $\boldsymbol{\xi} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_p)$ ,  $\mathbf{B}$  — симметричная, неотрицательно неопределенная матрица размерности  $p \times p$  и  $\text{rk } \mathbf{B} = r$ . Тогда

$$\sigma^{-2} \boldsymbol{\xi}^T \mathbf{B} \boldsymbol{\xi} \sim \chi^2(r) \iff \mathbf{B}^2 = \mathbf{B}.$$

**Пример.**  $n\sigma^{-2}s^2 \sim \chi^2(p-1)$ . Воспользуемся представлением из предыдущего примера:  $ps^2 = \mathbf{x}^T \mathbf{C} \mathbf{x}$ . Но  $\text{rk } \mathbf{C} = \text{rk}(\mathbf{I}_p - \mathbf{B}) = p-1$ ;  $\mathbf{B}^2 = \mathbf{B}$ , значит  $p\sigma^{-2}s^2 \sim \chi^2(p-1)$ .

*Утверждение (Cochran).* Пусть  $\boldsymbol{\xi} \sim N(\mathbf{0}, \mathbf{I}_p)$ ,  $\boldsymbol{\xi}^T \boldsymbol{\xi} = \sum_i Q_i$ , где  $Q_i$  — квадратичная форма, заданная  $\mathbf{B}_i$ ,  $\text{rk } \mathbf{B}_i = r_i$ . Тогда следующие утверждения эквивалентны:

1.  $\sum r_i = p$
2.  $Q_i \sim \chi^2(r_i)$
3.  $Q_i \not\parallel Q_j, \quad \forall i \neq j$ , т.е.  $\mathbf{B}_i \mathbf{B}_j = \mathbf{0}$ .

## 4. Построение гипотез

*Замечание.* Этот раздел иногда называется «Confirmatory Data Analysis» в противовес «Exploratory Data Analysis», не включающему в себя понятие *гипотезы*.

### 4.1. Построение критерия

**Определение.** *Модель* — утверждение о  $\mathcal{P}$ , которое считается верным и не проверяется.

**Определение.** *Гипотеза* — утверждение о  $\mathcal{P}$ , требующее проверки.

При построении эксперимента, фиксируется *нулевая гипотеза*  $H_0$ , обыкновенно состоящая в том, что эффект, который хотят выявить *не присутствует*. Задача статистического эксперимента тогда — опровергнуть  $H_0$ .

**Пример** (Презумпция невиновности).  $H_0$ : подсудимый невиновен. Работа обвиняющей стороны сводится к опровержению  $H_0$ .

Поскольку выборка конечного объема позволяет делать только вероятностные заключения, со статистическим критерием ассоциирована величина  $\alpha_I$  — вероятность ошибочно отвергнуть  $H_0$  («вероятность ошибки I-го рода»<sup>8</sup>). До эксперимента фиксируется величина  $\alpha$ :  $\alpha \geq \alpha_I$  называемая *уровнем значимости* критерия. Неформально,  $\alpha$  обратно пропорциональна «строгости» критерия, выбираемой экспериментатором.

**Определение** (Критерий). Для выборки

$$\mathbf{x} = (x_1, \dots, x_n) : (\Omega, \mathcal{F}, \mathbf{P}) \rightarrow (V^n, \mathcal{A}^n)$$

*критерий* есть разбиение

$$V^n = \mathcal{A}_{\text{крит}}^{(\alpha)} \sqcup \mathcal{A}_{\text{дов}}^{(\alpha)}$$

такое, что  $H_0$  отвергается, если  $\mathbf{x} \in \mathcal{A}_{\text{крит}}^{(\alpha)}$  и не отвергается, если  $\mathbf{x} \in \mathcal{A}_{\text{дов}}^{(\alpha)}$ .

**Определение.** *Уровень значимости*  $\alpha \in [0, 1]$  есть вероятность попадания в критическую область при верной нулевой гипотезе:

$$\alpha_I = \mathbf{P}_{H_0}(\mathbf{x} \in \mathcal{A}_{\text{крит}}^{(\alpha)}) \sim \alpha, \quad \text{где } \sim \in \{=, \leq, \rightarrow\}.$$

*Замечание.* Если  $\alpha_I = \alpha$ , то критерий называется *точным*; если  $\alpha_I > \alpha$ , то *радикальным*, если  $\alpha_I < \alpha$ , то *консервативным*.

**Пример** (Экстрасенс угадывает карты). Некто заявляет о способности не глядя угадывать масти предлагаемых карт. Выдвигаем гипотезу  $H_0$ : человек *не* экстрасенс, так что угадывает с вероятностью  $p = 1/4$ . Предлагаем отгадать масть 25 карт; число угаданных карт есть  $x$ . Наибольшей «строгости» будет соответствовать  $x = 25$ , таким образом

$$\mathbf{P}_{H_0}(x \in \mathcal{A}_{\text{крит}}) = \mathbf{P}_{H_0}(x = 25) = \left(\frac{1}{4}\right)^{25} \approx 10^{-15} = \alpha.$$

Если же для нас достаточно 24 угаданных карт из 25, то  $\alpha$  будет побольше:  $\mathbf{P}_{H_0}(x \geq 24) = \mathbf{P}_{H_0}(x = 24) + \mathbf{P}_{H_0}(x = 25)$  и т.д. Зафиксированная до эксперимента  $\alpha$  определяет количество карт  $c$  такое, что при угадывании большего количества  $H_0$  будет считаться опровергнутой:

$$\alpha_I = \mathbf{P}_{H_0}(x \geq c) \leq \alpha.$$

Среди всех таких  $c$  следует выбрать наименьшее, чтобы минимизировать ошибку второго рода (см. далее).

---

<sup>8</sup>Size.

*Замечание.* Стандартный уровень значимости  $\alpha = 0.05$  или  $\alpha = 0.01$ .

Помимо  $H_0$ , может вводиться *альтернативная гипотеза*  $H_1$ , учитывающая отклонения от  $H_0$ , обнаружение которых желательно.

**Определение** (Ошибки I-го и II-го родов). Ошибка

- *I-го рода* есть отвержение  $H_0$ , при верной  $H_0$ ; соответствующая вероятность есть

$$\alpha_I := P_{H_0}(\mathbf{x} \in \mathcal{A}_{\text{крит}}^{(\alpha)}).$$

*Замечание.* Для точного критерия вероятность  $\alpha_I$  совпадает с уровнем значимости  $\alpha$ .

- *II-го рода* есть не отвержение  $H_0$  при верной  $H_1$ ; соответствующая вероятность есть

$$\alpha_{II} := P_{H_1}(\mathbf{x} \in \mathcal{A}_{\text{дов}}^{(\alpha)}).$$

*Замечание.* Если  $H_1$  — отрицание  $H_0$ , то её распределение может считаться сложно.

**Определение.** *Мощность* критерия против альтернативы это

$$\beta := 1 - \alpha_{II} = 1 - P_{H_1}(\mathbf{x} \in \mathcal{A}_{\text{дов}}^{(\alpha)}) = P_{H_1}(\mathbf{x} \in \mathcal{A}_{\text{крит}}^{(\alpha)}),$$

т.е. вероятность отвергнуть  $H_0$  при верной  $H_1$  («справедливо»).

Иными словами, это способность критерия отличать  $H_0$  от  $H_1$ .

**Определение.** Критерий называется *состоятельным*, если  $\beta \rightarrow 1$ .

*Замечание.* Утверждать об *отвержении* гипотезы можно с вероятностью ошибки  $\alpha$  (достаточно малой); утверждать о *принятии* гипотезы можно с вероятностью ошибки  $\alpha_{II}$  — не контролируемой и потенциально довольно большой. Поэтому безопасно гипотезу можно только отвергать или не отвергать.

*Замечание.* При высокой вероятности ошибки II-го рода возможна ситуация не отвержении заведомо ложной гипотезы. Это, в свою очередь, может произойти из-за маленького объема выборки (критерий не находит разницу, см. 6). Чем больше объем выборки, тем мощность больше, но возможна ситуация, когда критерий чувствителен настолько, что находит разницу там, где не должен — например, при генерации «идеальным» датчиком случайных чисел, начиная с какого-то объема заведомо истинная гипотеза может быть отвергнута из-за ошибок в точности представления чисел с плавающей точкой.

## 4.2. Статистика критерия

**Определение.** *Статистика критерия* есть отображение

$$T : \mathbf{x} \mapsto y \in \mathbb{R}.$$

*Утверждение.* С введенной статистикой критерия можно разбивать на критическую и доверительную области не  $V^n$ , а образ  $T$ :

$$\text{im } T = \mathcal{A}_{\text{крит}}^{(\alpha)} \sqcup \mathcal{A}_{\text{дов}}^{(\alpha)}.$$

Остальные связанные с критерием понятия остаются в силе с соответствующей заменой  $\mathbf{x}$  на  $T$ .

## Схема построения критерия с помощью статистики критерия

1. Выдвигают  $H_0$  (и  $H_1$ ).
2. Фиксируют предположение относительно данных (например, независимость).
3. Выбирают подходящий критерий и статистику  $T$ .  $T$  должна измерять то, насколько выборка соответствует гипотезе. В этом случае должно быть известно «идеальное соответствие»  $T$ .

**Пример.** Пусть  $H_0 : E\xi = a_0$ ; тогда  $T = \bar{x} - a_0$  и идеальное значение  $T = 0$ .

4. Распределение  $T$  при верной  $H_0$  должно быть известно хотя бы асимптотически.

**Пример.** См. 4.3.1.

5. Фиксируют уровень значимости  $\alpha$ .

6. Строят разбиение  $\text{im } T$  так:

- Если  $H_1$  неизвестна, то  $\mathcal{A}_{\text{крит}}$  следует выбрать так, чтобы она располагалась как можно дальше от идеального значения, т.е. разбиение должно максимизировать мощность.

**Пример.** В случае  $T \sim N(0, 1)$ , разумно определить  $\mathcal{A}_{\text{крит}}$  «на хвостах» графика  $\text{pdf}_{N(0,1)}$  симметрично по обе стороны от 0 так, что для  $\mathcal{A}_{\text{крит}} = (-\infty, T_0) \cup (T_1, \infty)$

$$\alpha/2 = \int_{-\infty}^{T_0} \text{pdf}_{N(0,1)}(y) dy = \int_{T_1}^{+\infty} \text{pdf}_{N(0,1)}(y) dy.$$

Иными словами,

$$\alpha/2 = 1 - \text{cdf}_{N(0,1)}(T_1) \implies T_1 = \text{cdf}_{N(0,1)}^{-1}(1 - \alpha/2)$$

и аналогично для  $T_0$ .

- Если  $H_1$  известна, то  $\mathcal{A}_{\text{крит}}$  выбирается так, чтобы минимизировать  $\alpha_{\text{II}}$ .

**Пример.** Пусть  $\xi \sim N(a, \sigma^2)$ ,  $\sigma^2$  известна,  $H_0 : E\xi = a_0$ ,  $H_1 : E\xi = a_1$ . Тогда по 4.3.1,

$$z = \frac{\sqrt{n}(\bar{x} - a_0)}{\sigma} \sim N(0, 1) \text{ при верной } H_0.$$

В то же время, поскольку при верной  $H_1$ ,  $E\bar{x} = 1/n \cdot \sum_{i=1}^n \xi_i = n/n \cdot a_1$  то

$$Ez = \frac{\sqrt{n}(a_1 - a_0)}{\sigma} \implies z \sim N\left(\frac{\sqrt{n}(a_1 - a_0)}{\sigma}, 1\right) \text{ при верной } H_1.$$

(дисперсия, конечно, не меняется при сдвиге).




Рис. 1: Плотности распределения  $z$  (неоптимальное разбиение)



Чтобы минимизировать  $\alpha_{II}$ , логично определить  $\mathcal{A}_{\text{крит}}$  только на одном хвосте — с той стороны, где находится альтернатива.




Рис. 2: Плотности распределения  $z$  (оптимальное разбиение)

*Замечание.* Помимо этого, по рисунку видно, что минимизировать  $\alpha_{II}$  (согласившись на бóльшую ошибку первого рода) можно сдвинув вправо центр второй плотности, увеличив  $n$ .

Аналогично, чем  $a_1$  дальше от  $a_0$ , тем  $\alpha_{II}$  меньше. Стоит отметить, что  $H_1$  не выбирается, но берется из смысла задачи.

7. Считают значение статистики и принимают решение об отвержении  $H_0$  в зависимости от того, попадает ли оно в  $\mathcal{A}_{\text{крит}}$  или  $\mathcal{A}_{\text{дов.}}$ . Альтернативно, можно посчитать  $p$ -value, на основании чего сделать вывод.

**Пример** (С гранатами).

**Определение.**  $p$ -value значения статистики  $T$  есть вероятность получить такое же или большее по модулю значение  $T$  при верной  $H_0$ .

$p$ -value обратно пропорционален «существенности» результата.

Если  $p$ -value меньше  $\alpha$ , то  $H_0$  отвергается, иначе нет.

**Пример** (Средняя температура в холодильнике). Хотят купить холодильник, такой, чтобы температура не опускалась ниже 0 — иначе продукты померзнут. Известно количество измерений  $n = 25$  и  $\bar{x} = 0.7$ .

1. Выдвинута  $H_0 : E\xi = 0$  — если гипотеза опровергнется, то холодильник купят.
2. Пусть  $\xi \sim N(a, \sigma^2)$ ,  $\sigma^2 = 4$ .
3. Поскольку модель нормальная и известная  $\sigma^2$ , выберем статистику 4.3.1 («z-test»):

$$z = \frac{\sqrt{n}(\bar{x} - a_0)}{\sigma} \sim N(0, 1) \text{ при верной } H_0.$$

Идеальное значение статистики — 0.

4. Зафиксируем два уровня значимости: 0.2 (храним петрушку) и 0.01 (храним дорогую красную икру). Поскольку идеально значение статистики 0, обозначим на хвостах  $\text{pdf}_{N(0,1)}$ .
5. Посчитаем

$$z(\mathbf{x}) = \frac{\sqrt{n}(\bar{x} - a_0)}{\sigma} = \frac{5(0.7 - 0)}{2} = 1.75.$$

Дальнейшее принятие решения возможно на основании критического значения или  $p$ -value.

6. Вычислим критическое значение:

- Для  $\alpha = 0.2$ ,

$$z_r = \text{cdf}_{N(0,1)}^{-1}(1 - \alpha/2) = \text{cdf}_{N(0,1)}^{-1}(0.9) \approx 1.28.$$

Но  $z(\mathbf{x}) = 1.75$ . Таким образом,  $z \in \mathcal{A}_{\text{крит}}$ ,  $H_0$  отвергнется и холодильник купят.

- Для  $\alpha = 0.01$ ,  $z_r \approx 2.57$ ,  $z(\mathbf{x}) = 1.75 \in \mathcal{A}_{\text{дов}}$  и  $H_0$  не отвергается; значит холодильник, быть может, не купят.

7. Можно посчитать  $p$ -value:

$$2 \cdot (1 - \text{cdf}_{N(0,1)}(1.75)) \approx 0.08.$$

Поэтому при уровне значимости  $\alpha = 0.2 > 0.08$   $H_0$  не отвергается, а при  $\alpha = 0.01 < 0.08$  отвергается.

**Пример (С мышой).** В одном из рукавов Т-образного лабиринта лежит морковка. К развилке по лабиринту бежит мышь и 7 раз из 10 поворачивает в направлении морковки. На основании этих данных хотим сделать вывод, что мышь чует морковь на расстоянии, после чего написать научную статью.

- $\xi \sim \text{Ber}(p)$ . Выдвинем гипотезу, что мышь *не* чует морковку,  $H_0 : p = p_0 = 0.5$ . По ЦПТ,

$$\frac{\sum_{i=1}^n \xi_i - \sum_{i=1}^n E\xi_i}{\sqrt{\sum_{i=1}^n D\xi_i}} = \frac{n\bar{x} - nE\xi}{\sqrt{n} \sqrt{D\xi}} = \frac{\sqrt{n}(\bar{x} - p_0)}{\sqrt{p_0(1 - p_0)}} \xrightarrow{d} N(0, 1).$$

Пусть это будет статистикой критерия с идеальным значением 0. Тогда


$$T = \frac{\sqrt{n}(\bar{x} - p_0)}{\sqrt{p_0(1 - p_0)}} = \frac{\sqrt{10} \cdot 0.2}{0.5} \approx 1.2649 \implies p\text{-value} = 2 \cdot (1 - \text{cdf}_{N(0,1)}(1.2649)) \approx 0.2.$$

Значит, с уровнем значимости 0.2 гипотеза не отвергается. Хочется иметь, конечно, один из стандартных уровней значимости, например 0.1.

- Увеличим мощность критерия, введя альтернативную гипотезу, что мышь чует морковку (в предположении, что все мыши любят морковь и к ней бегут),  $H_1 : p_1 > p_0$ . По 6, можем устроить односторонний критерий, так что  $p$ -value теперь 0.1. Однако пользуемся асимптотическим критерием при  $n = 10$ .
- Воспользуемся точным односторонним критерием со статистикой

$$T := n\bar{x} = \sum_{i=1}^n x_i \sim \text{Bin}(n, p_0)$$

и идеальным значением  $np_0$ . Тогда  $T = 10 \cdot 0.5 = 5$ . При уровне значимости  $\alpha = 0.1$  успешно попадаем в критическую область, вследствие чего  $H_0$  отвергается, и можем публиковаться.



*Замечание.* Исторически существовало два подхода к проверке гипотез: Фишера («significance test») и Неймана-Пирсона («hypothesis testing»).

**Фишер** Выдвигается  $H_0$ . Подсчитывается и сообщается точное  $p$ -value. Если результат «незначительный», не делается никаких выводов об отвержении  $H_0$ , но делается возможным дополнительный сбор данных.

**Нейман-Пирсон** Выдвигаются  $H_1, H_2$ , фиксируются  $\alpha_I, \alpha_{II}$  и  $n$ . На этом основании определяются  $\mathcal{A}_{\text{крит}}$  для каждой гипотезы. Если данные попали в  $\mathcal{A}_{\text{крит}}$   $H_1$  — предпочитается  $H_2$ , иначе  $H_2$ .

Современная теория проверки гипотез есть смесь двух этих подходов, не всегда консистентная. Вводные курсы по статистике формулируют теорию, похожую на significance testing Фишера; при повышенных требованиях к математической строгости, пользуются теорией Неймана-Пирсона.

*Замечание* (О графике  $p$ -values). Поскольку

$$\alpha_I \leftarrow P_{H_0}(T \in \mathcal{A}_{\text{крит}}) = P_{H_0}(p\text{-value} < \alpha),$$

то  $p$ -value по распределению стремятся к  $U(0, 1)$  при верной  $H_0$ . Это соображение позволяет визуально проверить истинность гипотезы: достаточно несколько (много) раз произвести эксперимент, для каждой выборки  $\bar{\mathbf{x}}^{(i)}$  посчитать свой  $p$ -value, построить график и убедиться, что получилась прямая.

### 4.3. $t$ -критерий

#### 4.3.1. $\widehat{E\xi}$

$H_0 : E\xi = a = a_0$ . Соответствие оценки математического ожидания гипотезе удобно выражать разницей  $\bar{\mathbf{x}} - a_0$  с «идеальным» значением 0. Отнормировав эту разницу, получим статистику, распределение которой известно.

- Пусть  $D\xi = \sigma^2 < \infty$ ; тогда используется следующая статистика

$$t = \sqrt{n} \frac{(\bar{\mathbf{x}} - a_0)}{\sigma} \xrightarrow{n \rightarrow \infty} N(0, 1)$$

по ЦПТ.

*Замечание.* При условии нормальности данных,  $t$ -критерий называется « $z$ -критерием», причем

$$t = z \sim N(0, 1).$$

*Доказательство.*

$$z = \frac{\bar{\mathbf{x}} - a_0}{\sqrt{D\bar{\mathbf{x}}}} = \sqrt{n} \frac{\bar{\mathbf{x}} - a_0}{\sigma} \sim N(0, 1).$$

□

- Пусть  $D\xi$  неизвестна; тогда используется следующая статистика

$$t = \sqrt{n-1} \frac{\bar{\mathbf{x}} - a_0}{s} = \frac{\sqrt{n-1}(\bar{\mathbf{x}} - a_0)}{\sqrt{n-1}/\sqrt{n} \cdot \tilde{s}} = \sqrt{n} \frac{\bar{\mathbf{x}} - a_0}{\tilde{s}} \xrightarrow{n \rightarrow \infty} N(0, 1).$$

*Замечание.* При условии нормальности данных,

$$t \sim t(n-1).$$

Доказательство.

$$t = \frac{\sqrt{n-1}(\bar{\mathbf{x}} - a_0)}{s} = \frac{\sqrt{n-1} \left( \frac{\bar{\mathbf{x}} - a_0}{\sigma} \right)}{s/\sigma} = \frac{\left( \frac{\bar{\mathbf{x}} - a_0}{\sigma} \right)}{\sqrt{\frac{s^2/\sigma^2}{n-1}}} = \frac{\frac{\sqrt{n}(\bar{\mathbf{x}} - a_0)}{\sigma}}{\sqrt{\frac{ns^2/\sigma^2}{n-1}}} = \frac{\beta}{\sqrt{\eta/(n-1)}} \sim t(n-1),$$

поскольку

$$\beta = \frac{\sqrt{n}(\bar{\mathbf{x}} - a_0)}{\sigma} \sim N(0, 1), \quad \eta = \frac{ns^2}{\sigma^2} \sim \chi^2(n-1).$$

□

#### 4.3.2. $\widehat{D\xi}$

$H_0 : D\xi = \sigma^2 = \sigma_0^2$ . Соответствие оценки дисперсии гипотезе удобно выражать отношением  $s^2/\sigma_0^2$  (или  $s_a/\sigma_0^2$  если  $a$  известно) с «идеальным» значением 1. Домножив на  $n$ , получим статистику, распределение которой известно.

- Пусть  $E\xi = a$ ; При условии нормальности данных используется следующая статистика («chi-squared test for variance»):

$$\chi^2 = \frac{ns_a^2}{\sigma_0^2} \sim \chi^2(n).$$

Доказательство.

$$\chi^2 = \frac{ns_a^2}{\sigma_0^2} = \frac{n \cdot 1/n \cdot \sum_{i=1}^n (x_i - a)^2}{\sigma_0^2} = \sum_{i=1}^n \left( \frac{x_i - a}{\sigma_0} \right)^2 \sim \chi^2(n).$$

□

- Пусть  $E\xi$  неизвестно. При условии нормальности данных используется следующая статистика («chi-squared test for variance»):

$$\chi^2 = \frac{ns^2}{\sigma_0^2} = \frac{(n-1)\tilde{s}^2}{\sigma_0^2} \sim \chi^2(n-1).$$

Доказательство. См. (3.3).

□

Альтернативное доказательство. По определению запишем

$$D\bar{\xi}_n = D(\bar{\xi}_n - a) = E(\bar{\xi}_n - a)^2 - (E(\bar{\xi}_n - a))^2.$$

Но

$$\begin{aligned} D\bar{\xi}_n &= E(\bar{\xi}_n - E\bar{\xi}_n)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{\mathbf{x}})^2 = s^2 \\ E(\bar{\xi}_n - a)^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - a)^2 = s_a^2 \\ (E(\bar{\xi}_n - a))^2 &= (\bar{\mathbf{x}} - a)^2, \end{aligned}$$

откуда

$$s^2 = s_a^2 - (\bar{\mathbf{x}} - a)^2.$$

Домножив обе части на  $n/\sigma_0^2$ , получим

$$\frac{ns^2}{\sigma_0^2} = \frac{ns_a^2}{\sigma_0^2} - \frac{n(\bar{\mathbf{x}} - a)^2}{\sigma_0^2} = \underbrace{\frac{ns_a^2}{\sigma_0^2}}_{\sim \chi^2(n)} - \underbrace{\left( \frac{\sqrt{n}(\bar{\mathbf{x}} - a)}{\sigma_0} \right)^2}_{\sim \chi^2(1)} \implies \frac{ns^2}{\sigma_0^2} \sim \chi^2(n-1).$$

□

*Замечание.*

$$\chi^2 = \frac{ns^2}{\sigma_0^2} = \frac{(n-1)\tilde{s}^2}{\sigma_0^2}.$$

*Замечание.* Для строгого доказательства, нужно использовать независимость  $\bar{\mathbf{x}}^2$  и  $s^2$  (см. 3.3).

**Упражнение.**  $s^2 = 1.44$ ,  $\bar{\mathbf{x}} = 55$ ,  $n = 101$ . Проверить гипотезу  $\sigma_0^2 = 1.5$  в нормальной модели.

*Решение.* Воспользуемся статистикой

$$\chi^2 = \frac{ns^2}{\sigma_0^2} = 101 \cdot 0.96 = 96.96.$$

«Идеальные» значения близки к  $E\xi_{\chi^2(100)} = 100$ , так что определим критическую область на концах плотности:

$$p\text{-value}/2 = \text{cdf}_{\chi^2(100)}(96.96) = \text{pchisq}(96.96, 100) \approx 0.43 \implies p\text{-value} \approx 0.86.$$

*Замечание.* Можно посчитать и по таблицам для нормального распределения. Раз

$$\frac{\eta_m - E\eta_m}{\sqrt{D\eta_m}} \xrightarrow{m \rightarrow \infty} N(0, 1),$$

то

$$\frac{96.96 - 100}{\sqrt{200}} \approx -0.215 \implies p\text{-value}/2 = \Phi(-0.215) \approx 0.415.$$

┘

## 4.4. Гипотеза согласия с видом распределения

По выборке возможно проверить гипотезу о виде распределения случайной величины, реализацией которой является выборка.

### 4.4.1. Критерий $\chi^2$

*Утверждение.* Для проверки гипотезы согласия с видом произвольного *дискретного* распределения используется асимптотический *критерий*  $\chi^2$  («chi-squared test for goodness of fit»).

**Распределение с известными параметрами** Пусть

$$H_0 : \mathcal{P} = \mathcal{P}_0, \text{ где } \mathcal{P}_0 : \begin{pmatrix} x_1^* & \dots & x_k^* \\ p_1 & \dots & p_k \end{pmatrix}.$$

Сгруппируем  $\mathbf{x}$ ; каждому  $x_i^*$  сопоставим *эмпирическую* абсолютную частоту  $n_i$ ; тогда  $np_i$  — *ожидаемая* абсолютная частота. Построим статистику критерия:

- Введем

$$T = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}$$

с идеальным значением 0.

- $T \xrightarrow{d} \chi^2(k-1)$ .
- Поскольку  $\text{pdf}_{\chi^2}$  не симметрична относительно 0, зададим  $\mathcal{A}_{\text{крит}}$  на хвосте графика.

**Упражнение.**  $n = 100$ ,

$$\begin{pmatrix} \diamond & \heartsuit & \clubsuit & \spadesuit \\ 20 & 30 & 10 & 40 \end{pmatrix}.$$

Проверить гипотезу, что колода полная.

*Решение.*  $H_0 : \mathcal{P}_\xi = \text{U}(1/4)$ . Поскольку речь идет о согласии с дискретным не параметризованным распределением, напрямую воспользуемся критерием  $\chi^2$ . Раз все  $np_i = 100 \cdot 1/4 = 25$ ,

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i} = 1 + 1 + \frac{15^2}{25} + \frac{15^2}{25} = 2 + 2 \cdot 9 = 20.$$

Так как  $\chi^2 \sim \chi^2(k-1) = \chi^2(3)$  со средним 3, и «идеальное» значение 0, определим критическую область в правом конце плотности. Из этих соображений

$$p\text{-value} = 1 - \text{cdf}_{\chi^2(3)}(20) = 1 - \text{pchisq}(20, 3) \approx 0.00017.$$

┘

**Распределение с неизвестными параметрами** В случае сложной гипотезы  $\mathcal{P} \in \{\mathcal{P}(\theta)\}_{\theta \in \Theta}$ ,  $\theta = (\theta_1, \dots, \theta_r)^\top$ , следует найти оценку  $\hat{\theta}_{\text{MLE}}$  (или  $\hat{\theta} : \hat{\theta} \rightarrow \hat{\theta}_{\text{MLE}}$ ) по методу максимального правдоподобия. При подстановке оценок вместо истинных параметров критерий становится консервативным. Чтобы этого избежать, необходимо сделать поправку на количество параметров — отнять  $r$ . Что приятно, одна и та же поправка работает для всех распределений; в этом случае,

$$T \xrightarrow{d} \chi^2(k-r-1).$$

**Упражнение 1.** 60 человек купило подарок сразу, 10 со второго раза, 20 с третьего, 10 с четвертого:

$$\begin{pmatrix} 0 & 1 & 2 & 3 \\ 60 & 10 & 20 & 10 \end{pmatrix}.$$

Проверить гипотезу о том, что это выборка из геометрического распределения.

*Решение.*  $H_0 : \mathcal{P}_\xi = \text{Geom}(p)$ . Воспользуемся критерием  $\chi^2$  для параметризованного распределения  $\text{Geom}(\hat{p}_{\text{MLE}})$ .

Найдем

$$\hat{p}_{\text{MLE}} = \underset{p}{\text{argmax}} \log \mathcal{L}(\mathbf{x}; p) \iff \frac{d}{dp} \log \mathcal{L}(\mathbf{x}; \hat{p}_{\text{MLE}}) = 0.$$

Так как  $\text{pdf}_{\text{Geom}(p)}(k) = (1-p)^{k-1}p$ ,

$$\begin{aligned} \log \mathcal{L}(\mathbf{x}; p) &= \log \prod_{k=1}^n (1-p)^{k-1} p = \log(1-p)^{n\bar{x}} p^n = n\bar{x} \log(1-p) + n \log p \\ &= n(\bar{x} \log(1-p) + \log p) \end{aligned}$$

откуда

$$\frac{d}{dp} \log \mathcal{L}(\mathbf{x}; p) = n \left( -\frac{\bar{x}}{1-p} + \frac{1}{p} \right) = 0 \iff 1-p-p\bar{x} = 0 \iff p = \frac{1}{1+\bar{x}}.$$

Учитывая

$$\bar{x} = 0.1 + 2 \cdot 0.2 + 3 \cdot 0.1 = 0.8,$$

найдем

$$\hat{p}_{\text{MLE}} = \frac{1}{1 + 0.8} \approx 0.55.$$

Посчитаем статистику  $\chi^2$ , найдя соответствующие  $p_i$ :

$$p_0 = P_{\text{Geom}(0.55)}(0) = 0.55, \quad p_1 \approx 0.26, \quad p_2 \approx 0.11, \quad p_3 \approx 0.09.$$

Тогда

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i} = \frac{25}{55} + \frac{16^2}{26} + \frac{81}{11} + \frac{1}{9} \approx 17.77.$$

Наконец, поскольку  $\chi^2 \xrightarrow{n \rightarrow \infty} \chi^2(k - r - 1)$ ,

$$p\text{-value} = 1 - \text{cdf}_{\chi^2(2)}(17.77) \approx 0.00014.$$

┘

**Определение.** Критерий применим, если  $\alpha \rightarrow \alpha_I$ .

*Замечание.* Поскольку критерий асимптотический, с достаточной степенью точностью он применим в случае, если

1.  $n \geq 50$ ;
2.  $np_i \geq 5$ .

*Замечание.* Если условие  $np_i \geq 5$  не выполняется, следует объединить состояния, например, с краев или слева направо; если в хвосте оказалось  $< 5$ , то следует присоединить к последнему.

**Пример** (С монеткой). Пусть  $n = 4040$ ,  $\#H = 2048$ ,  $\#T = 1092$ . Проверим  $H_0 : \mathcal{P} = \text{Ber}(0.5)$  с  $\alpha = 0.1$ . Условия критерия выполняются, поэтому посчитаем

$$T = \frac{(2048 - 2020)^2}{2020} + \frac{(1092 - 2020)^2}{2020} = \frac{28^2 + 28^2}{2020} \approx 0.78 \sim \chi^2(1),$$

откуда

$$p\text{-value} = 1 - \text{cdf}_{\chi^2(1)}(0.78) \approx 0.38.$$

$0.38 > 0.1$ , значит  $H_0$  не отвергается.

*Замечание.* Прохождение критерия не достаточно. Так, альтернирующая (и явно не случайная) последовательность  $\mathbf{x} = (0, 1, 0, 1, \dots)$  имеет  $T = 0$ .

**Согласие с нормальным распределением** Для проверки гипотезы  $H_0 : \mathcal{P}_\xi = N(a, \sigma^2)$  также можно воспользоваться статистикой критерия  $\chi^2$  для сложной гипотезы. В этом случае, нужно дискретизировать нормальное распределение, так, что

$$\mathcal{P}_0 = \begin{pmatrix} x_1^* & \dots & x_k^* \\ p_1(\hat{\theta}) & \dots & p_k(\hat{\theta}) \end{pmatrix}, \quad \hat{\theta} = \hat{\theta}_{\text{MLE}}.$$

Тем не менее, нужно иметь в виду две теоретических неточности:

1. Построение  $\mathcal{P}_0$  происходит случайно, в результате объединения элементов выборки после того, как она получена.
2. Оценка параметров  $\hat{\theta}_{\text{MLE}}$  должна быть посчитана для  $\mathcal{P}_0$ , а не для исходного (нормального) распределения — не  $\bar{\mathbf{x}}, s^2$ . Однако на практике на этот момент не обращают внимания.

Существует два возможных способа дискретизации:

1. Гистограмма: одинаковые интервалы, но разные вероятности.
2. Неравные интервалы с равными вероятностями.

```

N <- length(xs)
xs <- sort(xs)
probs <- pnorm(xs, mean=mean(xs), sd=sd(xs))
i <- 1; j <- i+1
while (N * (probs[j] - probs[i]) < 5) {
  j <- j+1
}
mean(xs[i:j]) # our  $x_1^*$ ;  $n_1 = j - i + 1$ 

```

Этот способ разбиения предпочтителен, потому что:

- Можно разбить максимально часто — так, чтобы  $np_i = 5 \forall i$ , следовательно и мощность будет максимальна.
- Он оказывается точнее первого на практике.
- Получается единственное  $p$ -value.

*Замечание.* Следует иметь в виду, что этот способ не годится для непрерывных, но плохо дискретизированных данных.

#### 4.4.2. Критерий Колмогорова-Смирнова

*Утверждение.* Для проверки гипотезы согласия с видом произвольного абсолютно непрерывного распределения с известными параметрами используется асимптотический критерий Колмогорова-Смирнова со следующей статистикой:

$$D_n = \sup_{x \in \mathbf{x}} |\text{ecdf}_n(x) - \text{cdf}_0(x)|,$$

где  $\text{cdf}_0$  — функция распределения  $\mathcal{P}_0$  нулевой гипотезы.

*Замечание.* Критерий является не асимптотическим, но *точным*. Значит им пользоваться и при маленьких объемах выборки (мощность, при этом, останется низкой все-равно).

*Замечание.*  $\sup_x \sqrt{n} |\text{ecdf}_n(x) - \text{cdf}_0(x)| \xrightarrow{d} \mathcal{P}_{\text{K.S.}}$ , где  $\mathcal{P}_{\text{K.S.}}$  — распределение Колмогорова. Значит, при больших объемах выборки для такой статистики критерия можно пользоваться таблицами распределения Колмогорова.

**Упражнение.** Проверить гипотезу, что  $\mathbf{x} = (0.1, 0.2, 0.4, 0.3, 0.1)$  есть выборка из  $U[0, 1]$ .

*Решение.*  $D_n = 0.6$ ,  $p$ -value  $\approx 0.05$  (по таблицам или компьютером). Таким образом, при  $\alpha > 0.05$  гипотеза отвергается, при  $\alpha < 0.05$  — нет.

```

> ks.test(c(0.1,0.2,0.4,0.3,0.1), 'punif')
      One-sample Kolmogorov-Smirnov test
data:  c(0.1, 0.2, 0.4, 0.3, 0.1)
D = 0.6, p-value = 0.05465

```

┘

*Замечание.* Критерий Колмогорова-Смирнова консервативный — значение  $p$ -value завышено. Поэтому если гипотеза отвергается, то наверняка.



**Критерий согласия с нормальным распределением** Пусть  $H_0 : \mathcal{P}_\xi \in \{N(a, \sigma^2)\}$ . Как известно, критерий Колмогорова-Смирнова используется для непрерывных непараметрических распределений. Им можно воспользоваться и для данной  $H_0$ , если вместо  $a, \sigma^2$  подставить соответствующие оценки. По аналогии с  $\chi^2$  хотелось бы сделать поправку на количество параметров. Для  $N(a, \sigma^2)$  и  $\text{Exp}(\lambda)$  получаем распределение  $D_n$ , не зависящее от параметров (так что поправку можно делать вне зависимости от параметров; к примеру,  $N(a, \sigma^2)$  можно привести к  $N(0, 1)$  непрерывным преобразованием):

**Критерий Бартлетта** есть критерий Колмогорова-Смирнова для  $H_0 : \mathcal{P}_\xi = \text{Exp}(\lambda)$ .

**Критерий Лиллиефорса**<sup>9</sup> для проверки  $H_0 : \mathcal{P}_\xi = N(a, \sigma^2)$  считается статистикой  $D_n$  с  $\text{cdf}_0(x) = \text{cdf}_{N(\bar{x}, s^2)}(x)$ , сходящейся к распределению Лиллиефорса (Колмогорова-Смирнова с учетом подстановки оценок).

**Критерий Шапиро-Уилка** есть  $T \approx \rho^2$  для  $H_0 : \mathcal{P}_\xi = N(a, \sigma^2)$ .

*Замечание.* Распределения Лиллиефорса и Колмогорова-Смирнова были получены путем моделирования.

**Пример.** В R:

```
> require('nortest')
> lillie.test(rt(1000, df=10))
      Lilliefors (Kolmogorov-Smirnov) normality test
data:  rt(1000, df = 10)
D = 0.03042, p-value = 0.02953
```

#### 4.4.3. Критерий типа $\omega^2$

Статистика

$$Q = n \int (F_n(x) - F_0(x))^2 \psi(x) dF_0(x)$$

может быть проинтерпретирована как площадь разницы между соответствующими функциями распределения.

**Cramer von Mises**  $Q$  с  $\psi \equiv 1$ .

**Anderson-Darling**  $Q$  с

$$\psi(x) = \frac{1}{F_0(x)(1 - F_0(x))}.$$

Все эти критерии точны.

#### 4.4.4. Визуальное определение согласия с распределением

##### P-P plot

**Определение.** *P-P plot* есть график

$$\{(\text{cdf}_0(x_i), \text{ecdf}_n(x_i))\}_{i=1}^n.$$

**Пример.** В R:

```
pp.plot <- function(xs, cdf.0=pnorm, n.knots=1000) {
  knots <- seq(min(xs), max(xs), length.out=n.knots)
  plot(cdf.0(knots), ecdf(xs)(knots))
  abline(0, 1)
}
```

## Q-Q plot

**Определение.** *Q-Q plot* есть график

$$\{(x_i, \text{cdf}_0^{-1}(\text{ecdf}_n(x_i)))\}_{i=1}^n.$$

Частный случай Q-Q plot для  $\text{cdf}_0^{-1} = \text{cdf}_{N(0,1)}^{-1}$  называется *normal probability plot*.

**Пример.** В R:

```
qq.plot <- function(xs, qf.0=qnorm, n.ppoints=1000) {  
  qs <- ppoints(n.ppoints)  
  plot(qf.0(qs), unname(quantile(xs, probs=qs)))  
  abline(mean(xs), sd(xs))  
}
```

*Замечание.* Если  $\bar{P}_n \rightarrow \mathcal{P}_\xi$ , то оба графика будут стремиться к  $y = x$ . Референсной прямой normal probability plot будет  $y = \widehat{D}\xi \cdot x + \widehat{E}\xi$ .

*Замечание.* Больше о различии Q-Q и P-P plots, см. <http://v8doc.sas.com/sashtml/qc/chap8/sect9.htm>

*Замечание.* Различные интерпретации параметров распределения по Q-Q plot можно посмотреть в интерактивном приложении: <https://xiongge.shinyapps.io/QQplots/>

## 4.5. Гипотеза о равенстве распределений

$H_0 : \mathcal{P}_{\xi_1} = \mathcal{P}_{\xi_2}$ .

Возможно рассматривать два случая:

1. Для независимых выборок: признак один, но измерен на разных индивидах. Пусть  $\zeta \in \{1, 2\}$  — номер индивида,  $\xi$  — признак. Тогда  $\xi_1 \sim \mathcal{P}_{\xi|\zeta=1}$ ,  $\xi_2 \sim \mathcal{P}_{\xi|\zeta=2}$  и  $\xi_1 \not\parallel \xi_2$ .
2. Для зависимых выборок: две характеристики на одних и тех же индивидах (либо же «до» и «после»);  $\xi = (\xi_1, \xi_2)^T$ .

*Замечание.* Для одной и той же гипотезы могут существовать разные критерии; их возможно сравнить по мощности, но только если они состоятельны против одной и той же альтернативы.

*Замечание.* Не параметрические критерии хороши тем, что основаны на рангах, значит устойчивы к аутлаерам; плохи тем, что не используют всю информацию о значении — только порядок, из-за чего обладают меньшей мощностью.

### 4.5.1. Проверка гипотезы о равенстве математических ожиданий

$H_0 : E\xi_1 = E\xi_2$ . Используется *t*-критерий

$$t = \frac{\bar{\mathbf{x}} - \bar{\mathbf{y}}}{\sqrt{D(\bar{\mathbf{x}} - \bar{\mathbf{y}})}} \xrightarrow{\sim} N(0, 1).$$

Как обычно, если данные нормальные, то  $t \sim N(0, 1)$ . Можно считать и по оценке дисперсии  $D(\bar{\mathbf{x}} - \bar{\mathbf{y}})$ .

Пусть выборка независима,  $(x_1, \dots, x_{n_1}), (y_1, \dots, y_{n_2})$ ,  $n = n_1 + n_2$ . Значит  $D(\bar{\mathbf{x}} - \bar{\mathbf{y}}) = D\bar{\mathbf{x}} + D\bar{\mathbf{y}}$ . Если дисперсия неизвестна,  $D(\bar{\mathbf{x}} - \bar{\mathbf{y}}) = s_1^2/n_1 + s_2^2/n_2$ , откуда

$$t = \frac{\bar{\mathbf{x}} - \bar{\mathbf{y}}}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \xrightarrow{n_1, n_2 \rightarrow \infty} N(0, 1).$$

Точное распределение неизвестно, примерно равно  $t$  с дробным числом степеней свободы (что вычисляется интерполяцией по соседним степеням). Однако всегда ожидается, что если данные нормальны, то распределение известно. Это противоречие носит название *проблемы Беренса-Фишера*<sup>10</sup>.

В случае, если дисперсии одинаковы, то

$$D(\bar{\mathbf{x}} - \bar{\mathbf{y}}) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} = \sigma^2 \left( \frac{1}{n_1} + \frac{1}{n_2} \right).$$

Оценку можно найти по объединенной и центрированной выборке:

$$\begin{aligned} s^2 &= \frac{\overbrace{\sum_{i=1}^n (x_i - \bar{\mathbf{x}})^2}^{\sim \chi^2(n_1-1)} + \overbrace{\sum_{i=1}^n (y_i - \bar{\mathbf{y}})^2}^{\sim \chi^2(n_2-1)}}{n_1 + n_2} = \frac{n_1}{n_1 + n_2} s_1^2 + \frac{n_2}{n_1 + n_2} s_2^2 \\ \tilde{s}^2 &= \frac{\sum_{i=1}^n (x_i - \bar{\mathbf{x}})^2 + \sum_{i=1}^n (y_i - \bar{\mathbf{y}})^2}{n_1 + n_2 - 2} = \frac{n_1}{n_1 + n_2 - 2} \tilde{s}_1^2 + \frac{n_2}{n_1 + n_2 - 2} \tilde{s}_2^2, \end{aligned}$$

где в последнем случае оценка несмещенная и  $E\tilde{s}^2 = \sigma^2$ .

Итого, когда  $\sigma^2$  известна,

$$t = \frac{\bar{\mathbf{x}} - \bar{\mathbf{y}}}{\tilde{s} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \xrightarrow{n \rightarrow \infty} N(0, 1),$$

причем, если данные нормальные, то  $t \sim t(n_1 + n_2 - 2)$ .

*Замечание.* Этот вариант более точен, чем в случае  $\sigma_1 \neq \sigma_2$ .

**Определение.** Выборка обладает *сбалансированным дизайном*, если  $n_1 = n_2$ .

Если дизайн сбалансирован, то

$$s^2 \left( \frac{1}{n_1} + \frac{1}{n_2} \right) = \frac{s_1^2}{n_1} + \frac{s_2^2}{n_2},$$

т.е. даже если дисперсии разные, результат одинаковый. Это остается справедливым даже при  $n_1 \approx n_2$ .

## 5. Доверительные интервалы

### 5.1. Мотивация и определение

Для построенных оценок может понадобиться оценка точности. Так, даже состоятельная оценка может не быть в полном смысле «точной»: пусть  $\theta_n^* \xrightarrow{P} \theta_0$ ; тогда

$$\hat{\theta}'_n = \begin{cases} c & n < N \gg 1 \\ \hat{\theta}_n & \text{иначе} \end{cases}$$

все-равно будет, конечно, состоятельной.

$D\hat{\theta}_n$  может быть не всегда просто вычислить и использовать.

**Определение.**  $[c_1, c_2]$  — *доверительный интервал* для параметра  $\theta_0$  с уровнем доверия  $\gamma \in [0, 1]$ , если  $\forall \theta_0$

$$P(\theta_0 \in [c_1, c_2]) = \gamma, \quad \text{где } c_1 = c_1(\mathbf{x}), c_2 = c_2(\mathbf{x}) \text{ — статистики.}$$

*Замечание.* Если выборка из дискретного распределения, то  $c_1, c_2$  — тоже. Поэтому наперед заданную точность получить может не получиться; в таких случаях знак «=» заменяют « $\geq$ ». Аналогично с заменой на « $\xrightarrow{n \rightarrow \infty}$ ».

<sup>10</sup>Behrens-Fisher problem.

## 5.2. Доверительные интервалы для математического ожидания и дисперсии в нормальной модели

**Предположение.** Пусть  $\xi \sim N(a, \sigma^2)$ .

### 5.2.1. Доверительный интервал для $a$

- Пусть  $\sigma^2$  известно. Свяжем  $a_0$  с выборкой:

$$\gamma = P(c_1 < T < c_2) = P\left(c_1 < \sqrt{n} \frac{(\bar{x} - a_0)}{\sigma} < c_2\right) = P\left(a_0 \in \left(\bar{x} - \frac{\sigma c_2}{\sqrt{n}}, \bar{x} - \frac{\sigma c_1}{\sqrt{n}}\right)\right).$$

Решений уравнения  $P(c_1 < \sqrt{n}(\bar{x} - a_0)/\sigma < c_2) = \Phi(c_2) - \Phi(c_1) = \gamma$  бесконечно много. Чем  $[c_1, c_2]$  короче, тем лучше. Поскольку  $\Phi$  симметрична и унимодальна,

$$\begin{aligned} c_1 &= -c_\gamma \\ c_2 &= c_\gamma, \end{aligned} \quad \text{где } c_\gamma = \text{cdf}_{N(0,1)}^{-1}\left(\gamma + \frac{1-\gamma}{2}\right) = x_{\frac{1+\gamma}{2}}.$$

Наконец,

$$P\left(a_0 \in \left(\bar{x} \pm \frac{\sigma}{\sqrt{n}} x_{\frac{1+\gamma}{2}}\right)\right) = \gamma.$$

- Пусть  $\sigma^2$  неизвестно. По аналогии,

$$\gamma = P\left(c_1 < \frac{\sqrt{n-1}(\bar{x} - a_0)}{s} < c_2\right) = P\left(a_0 \in \left(\bar{x} \pm \frac{c_\gamma s}{\sqrt{n-1}}\right)\right), \quad c_\gamma = \text{cdf}_{t(n-1)}^{-1}\left(\frac{1+\gamma}{2}\right)$$

и

$$P\left(a_0 \in \left(\bar{x} \pm \frac{\tilde{s}}{\sqrt{n}} x_{\frac{1+\gamma}{2}}\right)\right) = \gamma.$$

**Упражнение.** Пусть  $s^2 = 1.21$ ,  $\bar{x} = 1.9$ ,  $n = 36$ . Построить 95% доверительный интервал для  $E\xi$ .

*Решение.*

$$c_\gamma = \text{qt}(0.975, 35) \approx 2.03 \implies \left(1.9 \pm \frac{2.03 \cdot \sqrt{1.21}}{\sqrt{35}}\right) = (1.52; 2.28).$$

┘

### 5.2.2. Доверительный интервал для $\sigma^2$

- Пусть  $a$  известно. Поскольку плотность  $\chi^2$  становится все более симметричной с ростом  $n$ , примем

$$c_1 = \text{cdf}_{\chi^2(n)}^{-1}\left(\frac{1-\gamma}{2}\right), \quad c_2 = \text{cdf}_{\chi^2(n)}^{-1}\left(\frac{1+\gamma}{2}\right).$$

Тогда

$$P\left(c_1 < \frac{ns_a^2}{\sigma_0^2} < c_2\right) = \gamma \iff P\left(\sigma_0^2 \in \left(\frac{ns_a^2}{x_{(1+\gamma)/2}}, \frac{ns_a^2}{x_{(1-\gamma)/2}}\right)\right) = \gamma.$$

- Пусть  $a$  неизвестно. Тогда аналогично

$$P\left(\sigma_0^2 \in \left(\frac{ns^2}{x_{(1+\gamma)/2}}, \frac{ns^2}{x_{(1-\gamma)/2}}\right)\right) = \gamma,$$

где  $x_{(1\pm\gamma)/2} = \text{cdf}_{\chi^2(n-1)}^{-1}((1\pm\gamma)/2)$ .

**Определение.** Случайная величина  $g(x_1, \dots, x_n, \theta)$  называется *центральной статистикой параметра  $\theta$* , если

1. Её распределение («центральное распределение») не зависит от распределения  $\theta$ .
2.  $G_n$  (функция распределения центрального распределения) непрерывна.
3.  $\forall z_1, z_2$  и  $\mathcal{P}_\theta$ -почти всюду

$$z_1 < g(x_1, \dots, x_n, \theta) < z_2$$

монотонно разрешимо относительно  $\theta$ , т.е.

$$\exists f_1, f_n : f_1(x_1, \dots, x_n, \theta, z_1, z_2) < \theta < f_2(x_1, \dots, x_n, \theta, z_1, z_2).$$

Рассмотрим всегда разрешимое

$$\begin{aligned} \gamma &= G_n(z_2) - G_n(z_1) = P(z_1 < g(x_1, \dots, x_n, \theta) < z_2) \\ &= P(\underbrace{f_1(z_1, z_2, x_1, \dots, x_n)}_{c_1} < \theta < \underbrace{f_2(z_1, z_2, x_1, \dots, x_n)}_{c_2}). \end{aligned}$$

### 5.3. Асимптотический доверительный интервал для математического ожидания в модели с конечной дисперсией

Если модель неизвестна, но известно, что  $D\xi < \infty$ , можно построить доверительный интервал для  $E\xi = a$ . Пусть  $\{x_i\}$  i.i.d., тогда

$$t = \frac{\sqrt{n}(\bar{x} - a)}{\sigma} \xrightarrow[n \rightarrow \infty]{} N(0, 1).$$

Если положить  $\sigma := s$ , то сходимость не испортится, потому что  $s^2$  — состоятельная оценка  $\sigma^2$ . Тогда

$$P\left(E\xi \in \left(\bar{x} \pm \frac{sc_\gamma}{\sqrt{n}}\right)\right) \xrightarrow[n \rightarrow \infty]{} \gamma, \quad c_\gamma = \text{cdf}_{t(n-1)}^{-1}\left(\frac{1+\gamma}{2}\right).$$

Альтернативно замену  $\sigma$  на  $s$  можно обосновать по теореме Slutsky.

*Утверждение* (Слуцкий). Если  $\xi_n \xrightarrow{d} \xi$ ,  $\eta_n \xrightarrow{P} c$ , то  $\xi_n + \eta_n \xrightarrow{d} \xi + c$  и  $\xi_n \eta_n \xrightarrow{d} c\xi$ .

Используя тот факт, что  $s \xrightarrow{P} \sigma$ , запишем

$$P\left(c_1 < \frac{\sqrt{n}(\bar{x} - a)}{\sigma} \frac{\sigma}{s} < c_2\right) \xrightarrow[n \rightarrow \infty]{} \Phi(c_2) - \Phi(c_1).$$

### 5.4. Асимптотический доверительный интервал для параметра на основе MLE

Если умеем находить  $\hat{\theta}_{MLE}$ , то по асимптотической нормальности,

$$\frac{\hat{\theta}_{MLE} - E\hat{\theta}_{MLE}}{\sqrt{D\hat{\theta}_{MLE}}} \xrightarrow{d} N(0, 1),$$

по асимптотической несмещенности,

$$\frac{\hat{\theta}_{MLE} - \theta}{\sqrt{D\hat{\theta}_{MLE}}} \xrightarrow{d} N(0, 1),$$

и, учитывая асимптотическую эффективность ( $D\hat{\theta}_{MLE}I_n(\theta) \xrightarrow[n \rightarrow \infty]{} 1$ ), запишем статистику

$$T = (\hat{\theta}_{MLE} - \theta) \sqrt{I_n(\theta)} \xrightarrow{d} N(0, 1).$$

Чтобы по аналогии с предыдущим выразить  $\theta$  в  $P(c_1 < T < c_2) = P(|T| < c_\gamma) = \gamma$ , необходимо выразить  $\theta$  из  $I_n(\theta)$ . Для Poisson и Bernoulli это эквивалентно решению квадратного уравнения.

В общем случае, можно вместо  $\theta$  в  $I_n(\theta)$  подставить  $\hat{\theta}_{\text{MLE}}$  (при  $n \rightarrow \infty$  это не должно сильно испортить дело), откуда

$$P(|T| < c_\gamma) = \gamma \iff P\left(-c_\gamma < \left(\hat{\theta}_{\text{MLE}} - \theta\right) \sqrt{I_n(\theta)} < c_\gamma\right) = \gamma \iff P\left(\theta \in \left(\hat{\theta}_{\text{MLE}} \pm \frac{c_\gamma}{\sqrt{I_n(\theta)}}\right)\right) = \gamma,$$

где

$$T \stackrel{d}{\rightarrow} N(0, 1) \implies c_\gamma = \text{cdf}_{N(0,1)}^{-1}\left(\frac{1+\gamma}{2}\right).$$

**Пример.**  $\xi \sim \text{Pois}(\lambda)$ . По 2.4.1,  $\hat{\lambda}_{\text{MLE}} = \bar{\mathbf{x}}$ , по 2.4.2  $I_n(\lambda) = n/\lambda = n/\bar{\mathbf{x}}$  откуда

$$P\left(\lambda \in \left(\bar{\mathbf{x}} \pm \text{cdf}_{N(0,1)}^{-1}\left(\frac{1+\gamma}{2}\right) \frac{\sqrt{\bar{\mathbf{x}}}}{\sqrt{n}}\right)\right) = \gamma.$$

**Пример.**  $\xi \sim \text{Ber}(p)$ .  $p = E\xi$ .  $\hat{p} = \bar{\mathbf{x}}$ , откуда

$$P\left(p \in \left(\hat{p} \pm c_\gamma \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}\right)\right) \xrightarrow{n \rightarrow \infty} \gamma.$$

*Замечание.* Этот доверительный интервал не очень хорош, потому что не принадлежит  $[0, 1]$ .

## 5.5. Доверительный интервал для проверки гипотезы о значении параметра

Зафиксируем  $H_0 : \theta = \theta_0$  и  $\gamma = 1 - \alpha$ , где  $\alpha$  играет роль уровня значимости. По определению доверительного интервала,  $P(\theta \in [a_\gamma(\mathbf{x}), b_\gamma(\mathbf{x})]) = \gamma$ . Тогда разбиением будет

$$\mathcal{A}_{\text{дов}} = [a_\gamma(\mathbf{x}), b_\gamma(\mathbf{x})], \quad \mathcal{A}_{\text{крит}} = \mathbb{R} \setminus \mathcal{A}_{\text{дов}},$$

причем

$$P(\theta_0 \notin [a_\gamma(\mathbf{x}), b_\gamma(\mathbf{x})]) = \alpha.$$

Иными словам, попадание в критическую область происходит с уровнем значимости  $\alpha$ , что соответствует определению критерия.

## 6. Зависимость и корреляция

**Определение.** Мера зависимости — это функционал  $r : (\xi, \eta) \mapsto x \in [-1, 1]$  со свойствами:

1.  $|r| \leq 1$ .
2. Если  $\xi \nparallel \eta$ , то  $r(\xi, \eta) = 0$ .
3. Если  $\xi$  и  $\eta$  «максимально зависимы», то  $r(\xi, \eta) = 1$ .

### 6.1. Вероятностная независимость

#### 6.1.1. Визуальное определение независимости

- Поскольку при  $p_\eta(y_0) \neq 0$

$$\xi \nparallel \eta \iff p_{\xi|\eta}(x | y_0) = \frac{p_{\xi,\eta}(x, y_0)}{p_\eta(y_0)} = p_\xi(x),$$

то срезы графика совместной плотности при фиксированном  $y_0$  после нормировки  $p_\eta(y_0)$  должны выглядеть одинаково для всех  $y_0$ .

- Для выборки независимости можно попытаться определить по *таблицам сопряженности*: сгруппируем  $\{(x_i, y_i)\}_{i=1}^n$  и сопоставим каждой уникальной паре абсолютную частоту  $n_{ij}$ :

	$y_1^*$	$\cdots$	$y_s^*$
$x_1^*$	$n_{11}$	$\cdots$	$n_{1s}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$
$x_k^*$	$n_{k1}$	$\cdots$	$n_{ks}$

Тогда выборка с большей чем случайной вероятностью будет независима при пропорциональных строчках / столбцах.

**Пример.** Таблица сопряженности похожей на независимую выборки:

1	3	2
2	5	3
9	20	11

### 6.1.2. Критерий независимости $\chi^2$

По определению, для двумерных дискретных распределений, независимость есть

$$\xi \not\parallel \eta \iff \underbrace{P(\xi = i, \eta = j)}_{p_{ij}} = \underbrace{P(\xi = i)}_{p_i} \underbrace{P(\eta = j)}_{p_j} = \underbrace{\sum_{k=1}^K P(\xi = i, \eta = k)}_{p_{i\cdot}} \cdot \underbrace{\sum_{s=1}^S P(\xi = s, \eta = j)}_{p_{\cdot j}}.$$

Проверим  $H_0 : \xi \not\parallel \eta$ .

*Утверждение.* ОМП оценкой будет  $\hat{p}_{i\cdot} = n_{i\cdot}/n$  и  $\hat{p}_{\cdot j} = n_{\cdot j}/n$ .

По утверждению,  $\hat{p}_{ij} = \hat{p}_{i\cdot} \hat{p}_{\cdot j} = n_{i\cdot}/n \cdot n_{\cdot j}/n$ . Запишем статистику

$$\chi^2 = \sum_{i=1}^K \sum_{j=1}^S \frac{(n_{ij} - n \hat{p}_{ij})^2}{n \hat{p}_{ij}} = \sum_{i=1}^K \sum_{j=1}^S \frac{(n_{ij} - n_{i\cdot} n_{\cdot j}/n)^2}{n_{i\cdot} n_{\cdot j}} \xrightarrow{d} \chi^2((k-1)(s-1))$$

Количество параметров таково, потому что если  $\xi \parallel \eta$ , то всего  $ks - 1$  параметров ( $-1$  потому что  $\sum_{ij} p_{ij} = 1$ ); если  $\xi \not\parallel \eta$ , то  $k + s - 2$  ( $-2$  потому что  $\sum_i p_{ij} = 1$  и  $\sum_j p_{ij} = 1$ ). Значит  $ks - 1 - k - s + 2 = (k-1)(s-1)$ .

**Пример.** Дано  $S$  кубиков. Проверить гипотезу, что кубики одинаковы.

*Решение.* FIXME

*Замечание.* На маленьких выборках возникают проблемы со сходимостью, потому что может объединять только столбцы / строки и каждый раз терять сразу  $S - 1$  ( $K - 1$ ) степень свободы.

*Замечание.* Критерий верен и для качественных признаков, потому что нигде не участвуют значения из выборки.

*Замечание.* Критерий не удовлетворяет 1-му пункту определения меры зависимости ( $\chi^2 \notin [-1, 1]$ ). Это обычно исправляют так: рассматривают среднеквадратичную сопряженность  $\chi^2/n$  или коэффициент сопряженности Пирсона  $\chi^2/(\chi^2 + n)$  (тогда 1 никогда не достигается). Могли бы работать с  $1 - p\text{-value}$ , но так почему-то никогда не делают.

## 6.2. Линейная / полиномиальная зависимость

Определим  $\phi(x) := E(\eta | \xi = x)$ . Тогда назовем зависимость *линейной*, если  $\phi(x)$  — линейная функция, *квадратичной* — если квадратичная и т.д.




Рис. 3: Нелинейная зависимость




Рис. 4: Линейная зависимость

**Определение.** Мера *линейной* зависимости между случайными величинами  $\xi$  и  $\eta$  есть *коэффициент корреляции Пирсона*

$$\rho = \frac{\text{cov}(\xi, \eta)}{\sqrt{D\xi}\sqrt{D\eta}}.$$

*Замечание.* Про  $\rho$  можно думать как про  $\cos$  между векторами в соответствующем пространстве.

*Замечание.*  $\xi \nparallel \eta \implies \rho = 0$  и  $\xi, \eta \sim N(a, \sigma^2)$ ,  $\xi \nparallel \eta \iff \rho = 0$ .

**Предложение.** Для линейно зависимых данных, конечно,  $\rho = 1$ .

*Доказательство.* Пусть  $\eta = a + b\xi$ ; тогда

$$\begin{aligned} \rho(\xi, \eta) &= \frac{\text{cov}(\xi, a + b\xi)}{\sqrt{D\xi}\sqrt{D(a + b\xi)}} = \frac{E\xi(a + b\xi) - E\xi E(a + b\xi)}{\sqrt{D\xi}\sqrt{Db\xi}} = \frac{E\xi a + bE\xi^2 - E\xi E a - E\xi bE\xi}{b\sqrt{D\xi}\sqrt{D\xi}} = \\ &= \frac{aE\xi + bE\xi^2 - aE\xi - b(E\xi)^2}{bD\xi} = \frac{b(E\xi^2 - (E\xi)^2)}{bD\xi} = 1. \end{aligned}$$

□

**О соотношении  $\rho$  и коэффициента линейной регрессии** По (6.8), если линейная регрессия уравнением  $y = kx + b$ , то

$$k = \rho \frac{\sigma_\eta}{\sigma_\xi}.$$

В общем случае, по виду прямой линейной регрессии ничего нельзя сказать о зависимости между случайными величинами. Так, если  $\eta = a + b\xi$  есть линейная функция от  $\xi$ , то, по предыдущему,  $\rho = 1$  и

$$k = 1 \cdot \frac{\sqrt{D(a + b\xi)}}{\sqrt{D\xi}} = b$$

и прямая может иметь произвольный, в зависимости от  $b$ , наклон.

*Замечание.* В то же время, поскольку для

$$\begin{pmatrix} \xi \\ \eta \end{pmatrix} \sim N(\boldsymbol{\mu}, \Sigma), \quad \Sigma = \begin{pmatrix} \sigma_\xi^2 & \text{cov}(\xi, \eta) \\ \text{cov}(\xi, \eta) & \sigma_\eta^2 \end{pmatrix}$$

справедливо, что

$$k = \rho \frac{\sigma_\eta}{\sigma_\xi} = \frac{\text{cov}(\xi, \eta)}{\sigma_\xi \sigma_\eta} \cdot \frac{\sigma_\eta}{\sigma_\xi} = \frac{1}{\sigma_\xi^2} \text{cov}(\xi, \eta),$$

то  $k = 0 \iff \text{cov}(\xi, \eta) = 0$ , а для стандартно нормальных данных  $k = \rho = \text{cov}(\xi, \eta)$ .



### 6.3. Корреляционная зависимость

По свойству УМО(2.2.1), для заданного вектора  $\eta$  из  $L_2 = \{\eta : E\eta^2 < \infty\}$  со скалярным произведением  $(\eta, \xi) = E\eta\xi$  и подпространства  $K = \{\phi(\xi)\} = \{\hat{\eta} : \sigma(\phi(\xi))\text{-измерима}\}$  вектор  $\hat{\eta}^* = E\{\eta \mid \phi(\xi)\}$  будет ортогональной проекцией  $\eta$  на  $K$ , т.е.  $(\eta - \hat{\eta}^*, \hat{\eta}) = 0 \forall \hat{\eta} \in K$ . Значит, он минимизирует квадрат нормы расстояния от  $\eta$  до  $K$ :

$$\operatorname{argmin}_{\hat{\eta} \in K} \|\eta - \hat{\eta}\|^2 = \operatorname{argmin}_{\hat{\eta} \in K} E(\eta - \hat{\eta})^2 = E\{\eta \mid \phi(\xi)\} = \hat{\eta}^*.$$

Если  $K = \{a\xi + b\}$  — линейное пространство, то теорема Пифагора принимает вид

$$E(\eta - E\eta)^2 = \underbrace{E(\hat{\eta}^* - E\eta)^2}_{\text{объяснённая доля аппроксимации}} + \underbrace{E(\eta - \hat{\eta}^*)^2}_{\text{ошибка аппроксимации}}.$$

Откуда можно записать меру аппроксимации

$$\frac{E(\hat{\eta}^* - E\eta)^2}{D\eta} = 1 - \frac{E(\eta - \hat{\eta}^*)^2}{D\eta} = 1 - \frac{\min_{\hat{\eta} \in K} E(\eta - \hat{\eta})^2}{D\eta}.$$

$\hat{\eta}^*$  — предсказание  $\eta$  по  $\xi$  по МНК.

$$\min_{\hat{\eta} \in K} E(\eta - \hat{\eta})^2 = D\eta(1 - \rho^2),$$

и можно выразить коэффициент корреляции Пирсона

$$\rho^2(\eta, \xi) = 1 - \frac{\min_{\hat{\eta} \in K} E(\eta - \hat{\eta})^2}{D\eta}.$$

На случай нескольких случайных величин обобщается естественно («множественный коэффициент корреляции»):

$$R^2(\eta, \xi_1, \dots, \xi_k) = 1 - \frac{\min_{\hat{\eta} \in \{\sum_{i=1}^k b_i \xi_i + b_0\}} E(\eta - \hat{\eta})^2}{D\eta}.$$

*Замечание.*  $R^2 \geq \rho^2$ ; если же  $R^2 = \rho^2$ , то  $\xi_1, \dots, \xi_k$  все зависимы.

В общем случае, («корреляционное отношение»)

$$r_{\eta|\xi}^2 = 1 - \frac{\min_{\hat{\eta} \in K} E(\eta - \hat{\eta})^2}{D\eta} = \frac{DE(\eta \mid \xi)}{D\eta}.$$

#### 6.3.1. Свойства корреляционного отношения

1.  $r_{\eta|\xi}^2 \in [0, 1]$ .
2.  $\eta \nparallel \xi \implies r_{\eta|\xi}^2 = 0$ .
3.  $\eta = \phi(\xi) \iff r_{\eta|\xi}^2 = 1$ .
4. Вообще говоря,  $r_{\eta|\xi}^2 \neq r_{\xi|\eta}^2$ . К примеру, для любой не монотонной функции (так, чтобы не существовала обратная).
5.  $r_{\eta|\xi}^2 \geq \rho^2(\eta, \xi)$  (потому что минимум по всем функциям меньше, чем лишь по линейным, значит  $1 - \min$  больше).
6.  $(\xi, \eta)^T \sim N(\mu, \Sigma) \implies r_{\eta|\xi}^2 = \rho^2(\eta, \xi)$ .

## 6.4. Частная корреляция

**Определение.** Частная корреляция случайных величин  $\eta_1, \eta_2$  относительно  $\{\xi_1, \dots, \xi_k\}$  есть

$$\rho(\eta_1, \eta_2 \mid \{\xi_1, \dots, \xi_k\}) := \rho(\eta_1 - \hat{\eta}_1^*, \eta_2 - \hat{\eta}_2^*), \quad \text{где } \hat{\eta}_i^* = \underset{\hat{\eta}_i \in \{\sum_{i=1}^k b_i \xi_i + b_0\}}{\operatorname{argmin}} \mathbb{E}(\eta_i - \hat{\eta}_i)^2.$$

Если регрессия линейна, то

$$\rho(\eta_1, \eta_2 \mid \xi_1, \dots, \xi_k) = \rho(\eta_1 - \mathbb{E}\{\eta_1 \mid \xi_1, \dots, \xi_k\}, \eta_2 - \mathbb{E}\{\eta_2 \mid \xi_1, \dots, \xi_k\}).$$

*Замечание (Важное).* Пусть в эксперименте подсчитан ненулевой  $\rho$ . Это может означать, что один из факторов является причиной, а другой следствием; чтобы установить, что есть что, проводят эксперимент и смотрят, какой фактор в реальности влияет на какой. Это может также означать, что влияет сторонний фактор. Чтобы его исключить, считают частную корреляцию.

**Пример.** Возможна ситуация, когда  $\rho(\eta_1, \eta_2) \neq 0$ , но  $\rho(\eta_1, \eta_2 \mid \xi) = 0$ . Частная корреляция есть, по сути, корреляция на центрированных данных.

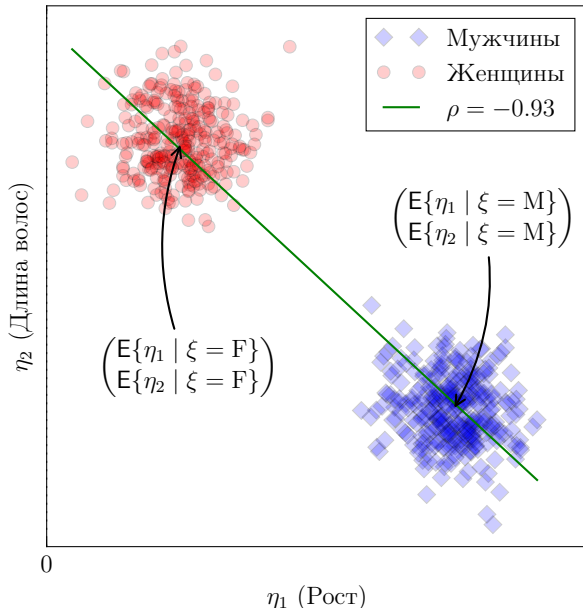


Рис. 5: Исходные данные (бимодальность)




Рис. 6: Центрированные данные

**Пример.** Возможна и ситуация как на (7), где определенно  $\rho(\eta_1, \eta_2) > 0$ , но  $\rho(\eta_1, \eta_2 \mid \xi) < 0$ .




Рис. 7:  $\rho(\eta_1, \eta_2) > 0$ , но  $\rho(\eta_1, \eta_2 \mid \xi) < 0$

*Замечание.* По аналогии с предыдущим примером, если  $|\text{im } \xi| \rightarrow \infty$ , то графики  $(\eta_1, \eta_2)$  при фиксированном  $\xi$  образуют эллипсоид (в этом случае с положительной корреляцией).

## 6.5. Значимость коэффициента корреляции

**Определение.** Коэффициент корреляции *значим*, если отвергается  $H_0 : \rho = 0$ .

Статистика для проверки значимости:

$$T = \frac{\sqrt{n-2}\hat{\rho}_n}{\sqrt{1-\hat{\rho}_n^2}} \sim t(n-2) \quad \text{если} \quad \begin{pmatrix} \xi \\ \eta \end{pmatrix} \sim N(\mu, \Sigma).$$

Идеальное значение — 0, два хвоста.

## 6.6. Зависимость между порядковыми признаками

Пусть на выборке

$$\begin{pmatrix} \xi \\ \eta \end{pmatrix} \sim \begin{pmatrix} x_1 \\ y_1 \end{pmatrix}, \dots, \begin{pmatrix} x_n \\ y_n \end{pmatrix}$$

задан только порядок. Тогда можем считать только эмпирическую функцию распределения.

Следующие коэффициенты основаны на рангах. Ранговые характеристики хорошо работают на выборках *без повторений* (чтобы, к примеру, не возникало дробных рангов).

### 6.6.1. Ранговый коэффициент Спирмана

**Определение.** *Ранговый коэффициент Спирмана* есть

$$\rho_S = \rho(F_\xi(\xi), F_\eta(\eta)).$$

*Замечание.*  $F_\xi(\xi) \sim U(0, 1)$ , потому что  $P(F_\xi(\xi) < x) = P(\xi < F_\xi^{-1}(x)) = F_\xi(F_\xi^{-1}(x)) = x$ .

**Определение.** *Ранг* элемента из выборки  $x_i$  есть его порядковый номер:

$$\text{rk } x_{(i)} = i.$$

*Обозначение.*  $\text{rk } x_{(i)} = R_i$ ,  $\text{rk } y_{(i)} = T_i$ .

*Замечание.* Можем ввести эмпирическое распределение

$$\begin{pmatrix} (R_1/n) & \dots & (R_n/n) \\ (T_1/n) & \dots & (T_n/n) \\ 1/n & \dots & 1/n \end{pmatrix}.$$

**Определение.** *Выборочный коэффициент Спирмана* определяется как выборочный коэффициент корреляции Пирсона  $\hat{\rho}$ , но с заменой значений на ранги:

$$\hat{\rho}_S = \frac{1/n \cdot \sum_{i=1}^n R_i T_i - \bar{R}\bar{T}}{\sqrt{1/n \cdot \sum_{i=1}^n (R_i - \bar{R})^2} \sqrt{1/n \cdot \sum_{i=1}^n (T_i - \bar{T})^2}}.$$

Если нет повторяющихся наблюдений, то знаменатель будет одним и тем же у всех выборок объема  $n$ , значит его можно посчитать заранее. В этом (и только этом) случае, справедлива более простая формула:

$$\hat{\rho}_S = 1 - \frac{6 \sum_{i=1}^n (R_i - T_i)^2}{n^3 - n}.$$

*Замечание.* Из последней формулы хорошо видно, что если  $x_i, y_i$  все идут в одном порядке, то  $R_i - T_i = 0 \ \forall i$  и  $\hat{\rho}_S = 1$ .

*Замечание.*  $\rho_S$  для *количественных* признаков есть мера монотонной зависимости:

$$\rho_S = 1 \iff (x_i > x_{i+1} \implies y_i > y_{i+1} \ \forall i)$$

(даже если зависимость нелинейная и  $\rho \neq 1$ ). Иными словами,  $\rho_S > 0$ , если  $y$  имеет тенденцию к возрастанию с возрастанием  $x$  (и  $\rho_S < 0$  иначе). Чем большее  $\rho_S$ , тем более явно выражена зависимость  $y$  от  $x$  в виде некоторой монотонной функции.

**Согласованность  $\rho$  и  $\rho_S$**   $\rho_S$  не согласована с  $\rho$  в том же смысле, что  $\rho$  и  $r_{\xi|\eta}$ .

*Утверждение.* Справедлива формула

$$\rho = 2 \sin\left(\frac{\pi}{6} \rho_S\right).$$

- Если данные нормальные, то, с точностью до погрешности, по значению,  $\hat{\rho}$  и  $\hat{\rho}_S$  — это одно и то же (см. 8)




Рис. 8:  $\hat{\rho} \approx \hat{\rho}_S$

- $\hat{\rho}$  и  $\hat{\rho}_S$  можно сравнить. Обычный критерий оценки — выборочную дисперсию — посчитать сложно. Тем не менее, можем заметить, что  $\hat{\rho}_S$  более устойчив к аутлаерам (см. 9). Всегда можно добавить аутлаер такой, что  $\hat{\rho} = 0$ ;  $\hat{\rho}_S$  же поменяется не сильно. Поэтому для нормальных данных,  $\rho_S$  — это оценка, что нет аутлаеров.




Рис. 9:  $\hat{\rho}$  до и после добавления аутлаера

- Монотонным преобразованием можем всегда сделать так, чтобы  $\rho$  изменился (например, возведя в квадрат); при монотонном преобразовании, однако, не меняется  $\rho_S$  (см. 10). Значит, чтобы узнать  $\rho$  исходных (нормальных) данных, можно не выполнять обратного преобразования, а сразу посчитать  $\rho_S$ .




Рис. 10: Монотонное преобразование нормальных данных

### 6.6.2. Ранговый коэффициент Кэндалла $\tau(\xi, \eta)$

**Определение.** Пусть  $\begin{pmatrix} \xi_1 \\ \eta_1 \end{pmatrix} \parallel \begin{pmatrix} \xi_2 \\ \eta_2 \end{pmatrix} \sim \mathcal{P}_{\xi, \eta}$ ; тогда *ранговым коэффициентом Кэндалла* называется

$$\tau(\xi, \eta) = \rho(\text{sign}(\xi_2 - \xi_1), \text{sign}(\eta_2 - \eta_1)) = P((\xi_2 - \xi_1)(\eta_2 - \eta_1) > 0) - P((\xi_2 - \xi_1)(\eta_2 - \eta_1) < 0).$$

На выборочном языке, пусть  $(x_1, y_1), \dots, (x_n, y_n) = \bar{\mathbf{x}}$ , тогда

$$\tau = \frac{\#(\text{одинаково упорядоченных пар}) - \#(\text{по-разному упорядоченных пар})}{\#(\text{комбинаций пар})},$$

где пара  $(x_i, y_i), (x_j, y_j)$  считается одинаково упорядоченной, если  $\text{sign}(x_i - x_j) = \text{sign}(y_i - y_j)$ , а  $\#(\text{комбинаций пар}) = C_n^2 = n(n-1)/2$ .

**Утверждение.** Если  $\begin{pmatrix} \xi \\ \eta \end{pmatrix} \sim N(\boldsymbol{\mu}, \Sigma)$ , то справедлива формула

$$\rho = \sin\left(\frac{\pi}{2}\tau\right).$$

Из утверждения следует, что  $\tau$  все время меньше  $\rho$  и  $\rho_S$ .

**Пример** (Проверка ряда на тренд). Пусть  $\xi$  — номера точек, а  $\eta$  — значения ряда. Тогда  $H_0 : \tau_0 = 0$  и если  $H_0$  отвергается, то тренд присутствует.

## 6.7. Корреляционные матрицы

Если признаков много, то их наглядно характеризуют корреляционные матрицы. Улучшить наглядность можно переупорядочив признаки так, чтобы на диагонали матрицы стояли блоки корреляций признаков из «корреляционных плеяд».

**Определение.** Пусть  $\rho_0$ ; корреляционная плеяда есть множество признаков, таких, что их попарная корреляция больше  $\rho_0$ .

Можно выделить и несколько уровней  $\rho_i : \rho_0 < \rho_1 < \dots$ . Тогда сначала следует составить плеяду по  $\rho_0$ , затем внутри полученного по  $\rho_1$  и т.д.

## 6.8. Парная линейная регрессия

**Определение.** Пусть  $\xi, \eta \in L^2(\mathcal{F}, \mathbb{P})$  пространству  $\mathcal{F}$ -измеримых по мере  $\mathbb{P}$  функций с конечным вторым моментом, причем  $\xi \in H \subset L^2$  — пространству линейных функций вида  $h(\xi) = \beta_1 \xi + \beta_2$ . *Линейной регрессией* будет называться такая линейная функция  $h_{\beta_1, \beta_2}(\xi) = \beta_1 \xi + \beta_2$ , что она минимизирует расстояние до  $\eta$  по  $L^2$ -метрике:

$$\begin{aligned} h_{\beta_1, \beta_2}(\xi) &= \operatorname{argmin}_{\beta_1, \beta_2} \|\eta - h_{\beta_1, \beta_2}(\xi)\|^2 = \operatorname{argmin}_{\beta_1, \beta_2} \int_{\Omega} (\eta - h_{\beta_1, \beta_2}(\xi))^2 d\mathbb{P} \\ &= \operatorname{argmin}_{\beta_1, \beta_2} \underbrace{\mathbb{E}(\eta - (\beta_1 \xi + \beta_2))^2}_{\phi(\beta_1, \beta_2)} = \beta_1^* \xi + \beta_2^*. \end{aligned}$$

*Замечание.* Найти минимум  $\phi$  можно, как обычно, решив систему  $\partial \phi / \partial \beta_i = 0$ <sup>11</sup>.

*Утверждение.*  $\beta_1^*, \beta_2^*$  таковы, что

$$\frac{h(\xi) - \mathbb{E}\eta}{\sqrt{D\eta}} = \rho \frac{\xi - \mathbb{E}\xi}{\sqrt{D\xi}}.$$

Иными словами,

$$h(\xi) = \underbrace{\rho \frac{\sqrt{D\eta}}{\sqrt{D\xi}}}_{\beta_1^*} \xi + \underbrace{\mathbb{E}\eta - \rho \frac{\sqrt{D\eta}}{\sqrt{D\xi}} \mathbb{E}\xi}_{\beta_2^*}.$$

Отсюда можно получить соотношение между коэффициентом линейной регрессии  $\beta_1^* = k$  (наклоном регрессионной прямой) и коэффициентом корреляции:

$$k = \rho \frac{\sigma_{\eta}}{\sigma_{\xi}}.$$

*Замечание.* Подстановкой проверяется, что

$$\phi(\beta_1^*, \beta_2^*) = D\eta(1 - \rho^2),$$

откуда можно найти уже известное выражение для

$$\rho^2 = 1 - \frac{\phi(\beta_1^*, \beta_2^*)}{D\eta} = 1 - \frac{\min_{\hat{\eta} \in H} \mathbb{E}(\eta - \hat{\eta})^2}{D\eta}, \quad \hat{\eta} := h(\xi).$$

**Определение.** Величина sum of squares residual есть

$$\underbrace{\text{SSR}}_{\text{sum of squares residual}} = n \cdot \phi(\beta_1^*, \beta_2^*) = \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad \hat{y}_i = h_{\beta_1^*, \beta_2^*}(x_i).$$

**Модель линейной регрессии** Можно описать выборку как

$$y_i = \beta_1 x_i + \beta_2 + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2), \quad \epsilon_i \not\parallel \epsilon_j.$$

$\sigma^2$  — мешающий параметр, который можно оценить через  $\text{SSR}/n$ . Но если  $\epsilon_i \sim N(0, \sigma^2)$ , то

$$\hat{\sigma}^2 = \frac{\text{SSR}}{n-2}$$

есть несмещенная оценка  $\sigma^2$ . Значит,

$$\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sigma^2} \sim \chi^2(n-2).$$

<sup>11</sup>См. [https://en.wikipedia.org/wiki/Simple\\_linear\\_regression](https://en.wikipedia.org/wiki/Simple_linear_regression)

**Значимость линейной регрессии** Значимость регрессии эквивалентна значимости предсказания по ней. Пусть  $H_0 : \rho = 0$ . Если  $H_0$  отвергается, то линейная регрессия значима.

**Доверительные интервалы для  $\beta_1$  и  $\beta_2$**  Как обычно, помимо точечной оценки  $\hat{\beta}_1$  и  $\hat{\beta}_2$ , интересуемся диапазоном значений, которые может принимать оценка с заданной вероятностью. Примем предположение о несмещенности оценки, т.е.  $E\hat{\beta}_i = \beta_i$ . Поскольку в модели  $y_i = \beta_1 x_i + \beta_2 + \epsilon_i$  ошибка  $\epsilon_i \sim N(0, \sigma^2)$  есть случайная величина, оценки  $\hat{\beta}_i$  — тоже становятся случайными величинами:  $\hat{\beta}_i \sim N(\beta_i, D\hat{\beta}_i)$ . В курсе регрессионного анализа доказывается<sup>12</sup>, что

$$D\hat{\beta}_1 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad D\hat{\beta}_2 = \frac{\sigma^2}{n}.$$

Кроме того,

$$SE(\hat{\beta}_1) = \sqrt{D\hat{\beta}_1} = \frac{\hat{\sigma}}{\sqrt{n}s_x} = \frac{\sqrt{\frac{SSR}{n-2}}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}, \quad SE(\hat{\beta}_2) = SE(\hat{\beta}_1) \cdot s_x$$

**Предложение. Статистика**

$$t = \frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\frac{1}{n-2} \sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} \sim t(n-2).$$

*Доказательство.* Известно,

$$t \sim t(m) \iff t = \frac{\xi}{\sqrt{\eta/m}}, \quad \xi \sim N(0, 1), \quad \eta \sim \chi^2(m).$$

Ясно, что

$$\frac{\hat{\beta}_1 - \beta_1}{\sigma} \sim N(0, 1), \quad \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sigma^2} \sim \chi^2(n-2).$$

Тогда

$$\frac{\left( \frac{\hat{\beta}_1 - \beta_1}{\left( \frac{\sigma}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}} \right)} \right)}{\left( \frac{\left( \frac{\sqrt{\sum_{i=1}^n (y_i - \hat{y}_i)^2}}{\sigma} \right)}{\sqrt{n-2}} \right)} = \frac{(\hat{\beta}_1 - \beta_1) \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}{\frac{\sigma}{\sqrt{\sum_{i=1}^n \epsilon_i^2}}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\frac{1}{n-2} \sum_{i=1}^n \epsilon_i^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} \sim t(n-2).$$

□

Используя статистику  $t$ , введем доверительные интервалы с  $c_\gamma = \text{cdf}_{t(n-2)}^{-1}((1+\gamma)/2)$ :

$$t \in (-c_\gamma, c_\gamma) \iff \frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)} \in (-c_\gamma, c_\gamma) \iff \beta_1 \in \left( \hat{\beta}_1 - c_\gamma SE(\hat{\beta}_1), \hat{\beta}_1 + c_\gamma SE(\hat{\beta}_1) \right).$$

Аналогично, для  $\beta_2$ :

$$\beta_2 \in \left( \hat{\beta}_2 - c_\gamma SE(\hat{\beta}_2), \hat{\beta}_2 + c_\gamma SE(\hat{\beta}_2) \right).$$

*Замечание.* На картинке доверительные интервалы изображаются в виде «рукавов» вокруг графика линейной регрессии — т.е. область всевозможных положений прямой при варьировании  $\beta_1, \beta_2$  в заданных интервалах.

<sup>12</sup>См. [https://en.wikipedia.org/wiki/Proofs\\_involving\\_ordinary\\_least\\_squares](https://en.wikipedia.org/wiki/Proofs_involving_ordinary_least_squares)

## А. Другие полезные распределения случайных величин

### А.1. Пуассона

### А.2. Логнормальное

## В. Свойства условного математического ожидания

1.  $E\{a\xi + b\theta \mid \eta\} = aE\{\xi \mid \eta\} + bE\{\theta \mid \eta\}.$
2.  $E E\{\eta \mid \xi\} = E\eta.$
3.  $\xi \nparallel \eta \implies E\{\xi \mid \eta\} = E\xi.$
4.  $\eta = f(\xi) \implies E\{\eta \mid \xi\} = E\{f(\xi) \mid \xi\} = f(\xi).$
5.  $E(\eta f(\xi) \mid f(\xi)) = f(\xi)E\{\eta \mid \xi\}.$
6.  $(\xi, \eta)^T \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies E(\xi \mid \eta) = a\eta + b.$

*Замечание* (Важное). Таким образом, если выборка нормальная, то зависимость линейная всегда.

7.  $\operatorname{argmin}_{\hat{\eta} \in K = \{\phi(\xi)\}} E(\eta - \hat{\eta})^2 = E\{\eta \mid \xi\} = \hat{\eta}^*.$