

# Статистика

## Конспект курса

Мат-Мех, ПМИ

5–7 семестры (2015–2016)

\$Revision: 1.51 \$

## Содержание

<b>1. Описательная статистика</b>	<b>3</b>
1.1. Выборка и эмпирическая случайная величина	3
1.2. Виды признаков	4
<b>2. Точечное оценивание</b>	<b>4</b>
2.1. Характеристики распределений и метод подстановки	4
2.2. Моменты	5
2.2.1. Характеристики положения	5
2.2.2. Характеристики разброса	5
2.2.3. Анализ характера разброса	7
2.3. Свойства оценок	7
2.3.1. Несмещенность	7
2.3.2. Состоятельность	8
2.3.3. Асимптотическая нормальность	10
2.3.4. Эффективность	10
2.4. Метод моментов	10
2.5. Метод оценки максимального правдоподобия	11
2.5.1. Функция правдоподобия и метод	11
2.5.2. Информационное количество Фишера и эффективность оценки MLE	12
<b>3. Некоторые распределения, связанные с нормальным</b>	<b>13</b>
3.1. Распределение $\chi^2(m)$	13
3.2. Распределение Стьюдента $t(m)$	14
3.3. Распределение Фишера	14
3.4. Квадратичные формы от нормально распределенных случайных величин	14
<b>4. Проверка гипотез</b>	<b>15</b>
4.1. Построение критерия	15
4.2. Статистика критерия	18
4.3. Проверка гипотезы о значении мат. ожидания ( $t$ -критерий)	21
4.3.1. $D\xi = \sigma^2 < \infty$	22
4.3.2. $D\xi$ неизвестна	22
4.4. Проверка гипотезы о значении дисперсии в нормальной модели (критерий $\chi^2$ )	23
4.4.1. $E\xi = a < \infty$	23
4.4.2. $E\xi$ неизвестно	23

4.5.	Критерий $\chi^2$ согласия с видом распределения . . . . .	24
4.5.1.	Распределение с известными параметрами . . . . .	25
4.5.2.	Распределение с неизвестными параметрами . . . . .	25
4.5.3.	Согласие с нормальным распределением . . . . .	27
4.6.	Критерий Колмогорова-Смирнова согласия с видом распределения . . . . .	27
4.6.1.	Произвольное абсолютно непрерывное распределение . . . . .	27
4.6.2.	Нормальное распределение . . . . .	28
4.7.	Критерий типа $\omega^2$ . . . . .	28
4.8.	Визуальное определение согласия с распределением . . . . .	29
4.8.1.	P-P plot . . . . .	29
4.8.2.	Q-Q plot . . . . .	29
4.9.	Гипотеза о равенстве распределений . . . . .	30
4.10.	Равенство математических ожиданий для независимых выборок . . . . .	30
4.10.1.	Двухвыборочный $t$ -критерий . . . . .	30
4.10.2.	Непараметрический $t$ -критерий . . . . .	32
4.10.3.	Критерии суммы рангов Wilcoxon . . . . .	32
4.10.4.	Критерий Mann-Whitney ( $U$ test) . . . . .	32
4.10.5.	Критерий серий (runs) . . . . .	33
4.10.6.	Критерий равенства распределений . . . . .	33
4.11.	Равенство математических ожиданий для парных (зависимых) выборок . . . . .	33
4.11.1.	$t$ -критерий . . . . .	33
4.11.2.	Непараметрический тест знаков (Sign test) . . . . .	34
4.11.3.	Непараметрический критерий (Paired Wilcoxon; Wilcoxon signed-rank test) . . . . .	34
4.12.	Равенство дисперсии для двух распределений . . . . .	34
4.12.1.	Критерий Фишера . . . . .	34
4.12.2.	Критерий Левена (Levene's test) . . . . .	35
4.12.3.	Критерий Brown-Forsythe . . . . .	35
<b>5.</b>	<b>Доверительное оценивание</b> . . . . .	<b>35</b>
5.1.	Мотивация и определение . . . . .	35
5.2.	Доверительные интервалы для математического ожидания и дисперсии в нормальной модели . . . . .	35
5.2.1.	Доверительный интервал для $\mu$ . . . . .	35
5.2.2.	Доверительный интервал для $\sigma^2$ . . . . .	36
5.3.	Асимптотический доверительный интервал для математического ожидания в модели с конечной дисперсией . . . . .	37
5.4.	Асимптотический доверительный интервал для параметра на основе MLE . . . . .	37
5.5.	Доверительный интервал для проверки гипотезы о значении параметра . . . . .	38
5.5.1.	Использование SE для построения доверительных интервалов . . . . .	38
<b>6.</b>	<b>Корреляционный и регрессионный анализы</b> . . . . .	<b>38</b>
6.1.	Вероятностная независимость . . . . .	38
6.1.1.	Визуальное определение независимости . . . . .	38
6.1.2.	Критерий независимости $\chi^2$ . . . . .	39
6.2.	Линейная / полиномиальная зависимость . . . . .	40
6.3.	Метод наименьших квадратов (Ordinary Least Squares) . . . . .	41
6.4.	Корреляционное отношение . . . . .	41
6.5.	Регрессия . . . . .	42
6.5.1.	Парная линейная регрессия . . . . .	42
6.5.2.	Модель линейной регрессии . . . . .	43
6.5.3.	Доверительные интервалы для $\beta_1$ и $\beta_2$ . . . . .	44
6.6.	Частная корреляция . . . . .	45

6.7. Зависимость между порядковыми признаками . . . . .	46
6.7.1. Ранговый коэффициент Спирмана . . . . .	46
6.7.2. Ранговый коэффициент Кэндалла $\tau(\xi, \eta)$ . . . . .	48
6.8. Корреляционные матрицы . . . . .	49
<b>А. Другие полезные распределения случайных величин</b>	<b>50</b>
А.1. Пуассона . . . . .	50
А.2. Логнормальное . . . . .	50
<b>В. Свойства условного математического ожидания</b>	<b>50</b>

## 1. Описательная статистика

### 1.1. Выборка и эмпирическая случайная величина

Пусть  $\xi \sim \mathcal{P}$  — случайная величина с распределением  $\mathcal{P}$ .

**Определение.** Повторной независимой выборкой объема  $n$  (до эксперимента) называется набор

$$\mathbf{x} = (x_1, \dots, x_n), \quad x_i \sim \mathcal{P} \quad \forall i \in 1:n, \quad x_1 \perp \dots \perp x_n$$

независимых в совокупности одинаково распределенных случайных величин с распределением  $\mathcal{P}$ .

**Определение.** Повторной независимой выборкой объема  $n$  (после эксперимента) называется набор реализаций, т.е. конкретных значений  $\xi$ , случайных величин  $x_i$ :

$$\mathbf{x} = (x_1, \dots, x_n), \quad x_i \in \text{im } \xi \quad \forall i \in 1:n.$$

**Определение.** Эмпирической случайной величиной  $\hat{\xi}_n$  называется случайная величина с дискретным распределением

$$\hat{\xi}_n \sim \hat{\mathcal{P}}_n : \begin{pmatrix} x_1 & \dots & x_n \\ 1/n & \dots & 1/n \end{pmatrix}.$$

*Замечание.* Подходящее определение выбирается по контексту.

Если  $\xi$  имеет дискретное распределение, то выборку можно *сгруппировать*; тогда получим случайную величину  $\hat{\xi}_m$  с распределением

$$\hat{\mathcal{P}}_m : \begin{pmatrix} x_1^* & \dots & x_m^* \\ \omega_1 & \dots & \omega_m \end{pmatrix} \quad \omega_i = \frac{\nu_i}{n},$$

где  $x_i^*$  — уникальные значения из выборки  $\mathbf{x}$ , а  $\nu_i$  — число  $x_i^*$  в  $\mathbf{x}$  (т.н. «абсолютная частота»; тогда  $\omega_i$  — «относительная частота»). В противном случае, можно разбить интервал всевозможных значений выборки на  $m$  подынтервалов:  $\{[e_0, e_1), \dots, [e_{m-1}, e_m)\}$  и считать число наблюдений  $\nu_i = \nu_i[e_{i-1}, e_i)$ , попавших в интервал.

**Следствие.** По ЗБЧ (теореме Бернулли),

$$\omega_i \xrightarrow{P} p_i = P(e_{i-1} \leq \xi < e_i),$$

т.е. относительная частота является хорошей оценкой вероятности на больших объемах выборки.

## 1.2. Виды признаков

Виды признаков случайной величины  $\xi : (\Omega, \mathcal{F}, P) \rightarrow (V, \mathfrak{A})$  характеризуются тем, что из себя представляет множество  $V$  и что можно делать с его элементами.

**Количественные признаки:**  $V \subset \mathbb{R}$

По типу операций:

- Аддитивные: заданы, т.е. имеют смысл в контексте данного признака, операции  $+$ ,  $-$
- Мультипликативные: заданы операции  $\cdot$ ,  $/$ ; признак принимает не отрицательные значения.

По типу данных:

- Непрерывные
- Дискретные

**Порядковые признаки**  $V$  — упорядоченное множество, определены отношения  $>$ ,  $=$ .

**Качественные признаки** на  $V$  заданы отношения  $=$ ,  $\neq$

**Пример.** Цвет глаз, имена, пол.

## 2. Точечное оценивание

### 2.1. Характеристики распределений и метод подстановки

**Определение.** *Статистика* — измеримая функция от выборки.

Обобщением статистики является понятие характеристики.

**Определение.** *Характеристика* — функционал от распределения:

$$T : \{\mathcal{P}\} \rightarrow V.$$

Где  $V$  — измеримое пространство, чтобы на нём можно было завести  $\sigma$ -алгебру.

*Замечание.* Чаще всего,  $V = \mathbb{R}$ .

**Определение.** Выделяют *генеральные* характеристики  $T(\mathcal{P}) =: \theta$  и *выборочные* характеристики  $T(\hat{\mathcal{P}}_n)$ . *Оценка* — выборочная характеристика  $T(\hat{\mathcal{P}}_n) =: \hat{\theta}_n$ , не зависящая от генеральной характеристики  $\theta$ .

**Следствие.** *Выражения для вычисления генеральных и выборочных характеристик отличаются только используемыми мерами ( $\mathcal{P}$  и  $\hat{\mathcal{P}}_n$  соответственно).*

**Определение.** Пусть  $\hat{\mathcal{P}}_n$  — распределение эмпирической случайной величины. Тогда *эмпирическая функция распределения* есть

$$\widehat{\text{cdf}}_{\xi}(x) = \text{cdf}_{\xi_n}(x) = \hat{\mathcal{P}}_n((-\infty, x)) = \int_{-\infty}^x d\hat{\mathcal{P}}_n = \sum_{x_i: x_i \leq x} \frac{1}{n} = \frac{|\{x_i \in \mathbf{x} : x_i \leq x\}|}{n}.$$

*Утверждение.* Пусть  $\widehat{\text{cdf}}_{\xi}$  — эмпирическая функция распределения,  $\text{cdf}_{\xi}$  — функция распределения  $\xi$ . Тогда, по теореме Гливенко-Кантелли,

$$\sup_x \left| \widehat{\text{cdf}}_{\xi}(x) - \text{cdf}_{\xi}(x) \right| \xrightarrow{\text{a.s.}} 0.$$

*Замечание.* Поскольку  $\widehat{\text{cdf}}_{\xi}(x) = \omega_x$ , где  $\omega_x$  — частота попадания наблюдений в интервал в  $(-\infty, x)$ , а  $\text{cdf}_{\xi}(x) = P(\xi \in (-\infty, x))$  — вероятность того же события, то можно применить теорему Бернулли (ЗБЧ):

$$\widehat{\text{cdf}}_{\xi}(x) \xrightarrow{P} \text{cdf}_{\xi}(x).$$

**Следствие.** *Значит, при достаточно больших  $n$ , в качестве интересующей характеристики  $\theta$  распределения  $\mathcal{P}$  можем брать ее оценку  $\hat{\theta}_n$  — аналогичную характеристику  $\hat{\mathcal{P}}_n$ .*

## 2.2. Моменты

**Определение.** Генеральные и соответствующие им выборочные характеристики  $k$ -го момента и  $k$ -го центрального момента:

$$\begin{aligned} m_k &= \int_{\mathbb{R}} x^k d\mathcal{P} & \hat{m}_k &= \int_{\mathbb{R}} x^k d\hat{\mathcal{P}}_n = \frac{1}{n} \sum_{i=1}^n x_i^k \\ m_k^{(0)} &= \int_{\mathbb{R}} (x - m_1)^k d\mathcal{P} & \hat{m}_k^{(0)} &= \int_{\mathbb{R}} (x - \hat{m}_1)^k d\hat{\mathcal{P}}_n = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{m}_1)^k. \end{aligned}$$

### 2.2.1. Характеристики положения

В качестве характеристики положения выделяется 1-й момент — математическое ожидание и выборочное среднее:

$$m_1 = E\xi, \quad \hat{m}_1 =: \bar{x} = \widehat{E\xi} = E\hat{\xi}_n.$$

*Замечание.* В случае мультипликативных признаков можно посчитать среднее геометрическое; часто логарифмируют и считают среднее арифметическое.

**Определение.** Пусть  $p \in [0, 1]$  и  $\text{cdf} = \text{cdf}_{\mathcal{P}}$ .  $p$ -квантилью называется

$$\text{qnt}_{\mathcal{P}}(p) =: z_p = \sup \{z : \text{cdf}(z) \leq p\}.$$

Квартиль есть 1/4- или 3/4-квантиль.

**Определение.** Медиана есть 1/2-квантиль:

$$\text{med } \xi = z_{1/2}.$$

**Определение.** Мода ( $\text{mode } \xi$ ) есть точка локального максимума плотности.

По методу подстановки можем получить аналогичные выборочные характеристики.

**Определение.** Выборочная  $p$ -квантиль есть такая точка  $\hat{z}_p$ , что она больше по значению  $|\mathbf{x}| \cdot p = np$  точек из выборки:

$$\hat{z}_p = \sup \left\{ z : \widehat{\text{cdf}}_{\xi}(z) \leq p \right\} = x_{[np]+1}.$$

**Определение.** Выборочная медиана упорядоченной выборки  $\mathbf{x} = (x_{(1)}, \dots, x_{(n)})$  есть

$$\hat{z}_{1/2} = \widehat{\text{med}} = \begin{cases} x_{(k+1)} & n = 2k + 1 \\ \frac{x_{(k)} + x_{(k+1)}}{2} & n = 2k \end{cases}$$

**Определение.** Выборочная мода ( $\widehat{\text{mode}}$ ) есть значение из выборки, которое чаще всего встречается.

### 2.2.2. Характеристики разброса

В качестве характеристики разброса выделяется 2-й центральный момент — дисперсия и выборочная дисперсия:

$$m_2^{(0)} = D\xi \quad \hat{m}_2^{(0)} =: s^2 = \widehat{D\xi} = D\hat{\xi}_n = \begin{cases} E \left( \hat{\xi}_n - E\hat{\xi}_n \right)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \\ E\hat{\xi}_n^2 - \left( E\hat{\xi}_n \right)^2 = \left( \frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2. \end{cases}$$

*Замечание.* Если среднее  $E\xi = a$  известно, то дополнительно вводится

$$s_a^2 := \begin{cases} \frac{1}{n} \sum_{i=1}^n (x_i - a)^2 \\ \left( \frac{1}{n} \sum_{i=1}^n x_i^2 \right) - a^2. \end{cases}$$

**Пример** (Оценка дисперсии оценки мат. ожидания). Пусть строится оценка мат. ожидания  $\bar{x}$ . Может интересоваться точность построенной оценки. Вычислим дисперсию теоретически, после чего оценим точность по выборке:

$$D\bar{x} = D\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n^2} \sum_{i=1}^n Dx_i = \frac{1}{n^2} \sum_{i=1}^n D\xi = \frac{D\xi}{n},$$

откуда

$$\widehat{D\bar{x}} = \frac{s^2}{n}.$$

**Пример** (Дисперсия оценки дисперсии). См. по ссылке<sup>1</sup>.

**Определение** (Энтропия). Количество информации, необходимое для выявления объекта из  $n$ -элементного множества вычисляется по *формуле Хартли*:

$$H = \log_2 n$$

(множество это следует итеративно разбивать пополам, откуда и оценка). Пусть теперь множество не равновероятно, т.е. задано дискретное распределение

$$\mathcal{P}_\xi : \begin{pmatrix} x_1 & \dots & x_n \\ p_1 & \dots & p_n \end{pmatrix}.$$

Тогда количество информации  $H(\xi)$ , которую нужно получить, чтобы узнать, какой исход эксперимента осуществлен, вычисляется по формуле Шеннона и называется *энтропией*:

$$H(\xi) = \sum_{i=1}^n p_i \log_2 \frac{1}{p_i}.$$

*Замечание.* В случае равномерного дискретного распределения, конечно,  $H = H(\xi)$ .

**Определение.** *Выборочное стандартное отклонение* есть

$$SD := \sqrt{\widehat{D\xi}} = s.$$

Это показатель разброса случайной величины; показатель того, насколько элементы выборки отличаются от выборочного среднего по значению.

**Определение.** *Стандартная ошибка* оценки есть

$$SE := \sqrt{\widehat{D\hat{\theta}}}.$$

Это показатель разброса оценки случайной величины.

*Замечание.* В частном случае  $\theta = E\xi$ ,  $\hat{\theta} = \bar{x}$  получаем *выборочную стандартную ошибку среднего*

$$SE = \sqrt{\frac{D\xi}{n}} = \frac{s}{\sqrt{n}}.$$

Это, в свою очередь, показатель того, насколько выборочное среднее отличается от истинного.

**Пример** (Пример с мостом и машинами). FIXME

<sup>1</sup><http://mathworld.wolfram.com/SampleVarianceDistribution.html>

### 2.2.3. Анализ характера разброса

**Определение.** Коэффициент асимметрии Пирсона («скошенности»<sup>2)</sup>

$$\gamma_3 = A\xi = \frac{m_3^{(0)}}{\sigma^3} = \frac{E\xi - \text{med } \xi}{\sigma}.$$

*Замечание.* Не зависит от линейных преобразований.

**Определение.** Коэффициент эксцесса («крутизны», «kurtosis»):

$$\gamma_4 = K\xi = \frac{m_4^{(0)}}{\sigma^4} - 3.$$

*Замечание.* Величина  $m_4^{(0)}/\sigma^4 = 3$  соответствует стандартному нормальному распределению. Так что можно сравнивать выборку и  $\gamma_4 N(0, 1)$ .

*Замечание.* При замене  $z := (\xi - E\xi)/\sigma$  величину  $m_4^{(0)}/\sigma^4 = E(z^4)$  можно интерпретировать как ожидание четвертой степени центрированных и нормированных данных. Точки выборки, лежащие внутри  $E\xi \pm \sigma$  из-за малости по модулю не будут увеличивать значение коэффициента, в то время как аутлаеры будут или «тяжелые хвосты» плотности распределения будут. Поэтому  $\gamma_4$  принимает большие значения на распределениях с «тяжелыми хвостами» или выборках с некоторым количеством аутлаеров.

*Замечание.* Справедлива оценка

$$\gamma_3^2 + 4 \leq \gamma_4 + 3 \leq \infty,$$

где минимум достигается  $\text{Ber}(1/2)$ .

**Определение.** Пусть  $(\xi_1, \xi_2) \sim \mathcal{P}$  и  $(x_1, y_1), \dots, (x_n, y_n) \sim \mathcal{P}(du \times dv)$ . Тогда можно записать две другие важные характеристики: ковариацию и коэффициент корреляции:

$$\begin{aligned} \text{cov}(\xi_1, \xi_2) &= \iint_{\mathbb{R}^2} (u - m_1(u))(v - m_1(v)) \mathcal{P}(du \times dv) & \widehat{\text{cov}}(\mathbf{x}, \mathbf{y}) &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{\mathbf{x}})(y_i - \bar{\mathbf{y}}) \\ \text{cor}(\xi_1, \xi_2) &= \frac{\text{cov}(\xi_1, \xi_2)}{\sigma_{\xi_1} \sigma_{\xi_2}} & \widehat{\text{cor}}(\mathbf{x}, \mathbf{y}) &= \frac{\widehat{\text{cov}}(\mathbf{x}, \mathbf{y})}{s(\mathbf{x})s(\mathbf{y})}. \end{aligned}$$

*Замечание (Важное).*  $\xi_1 \not\parallel \xi_2 \implies \text{cov}(\xi_1, \xi_2) \neq 0$ , но  $\text{cov}(\xi_1, \xi_2) = 0 \not\implies \xi_1 \parallel \xi_2$ . Необходимость и достаточность выполняется только в случае нормального распределения.

*Замечание (Проблема моментов).* Для заданной последовательности моментов  $m_1, m_2, \dots$  не обязательно существовать подходящее распределение. Помимо требований  $m_{2k} \geq 0$  и взаимосвязи между соседними моментами по неравенству Гёльдера, существенно, что ряд Тейлора по  $m_\ell$ , в который, как известно, раскладывается характеристическая функция, должен сходиться равномерно.

## 2.3. Свойства оценок

### 2.3.1. Несмещенность

**Определение.** Смещение<sup>3</sup> есть

$$\text{bias } \hat{\theta}_n := E\hat{\theta}_n - \theta \quad \forall \theta \in \Theta.$$

**Определение.** Среднеквадратичная ошибка<sup>4</sup> есть

$$\text{MSE } \hat{\theta}_n := E(\hat{\theta}_n - \theta)^2.$$

<sup>2</sup> «Skewness».

<sup>3</sup> Bias.

<sup>4</sup> Mean square error (MSE).

*Замечание.* Поскольку

$$D\hat{\theta}_n = D(\hat{\theta}_n - \theta) = E(\hat{\theta}_n - \theta)^2 - (E(\hat{\theta}_n - \theta))^2,$$

то

$$\underbrace{E(\hat{\theta}_n - \theta)^2}_{\text{MSE}} = D\hat{\theta}_n + \underbrace{(E(\hat{\theta}_n - \theta))^2}_{\text{bias}^2}.$$

**Определение.** Оценка называется *несмещенной*, если  $\text{bias } \hat{\theta}_n = 0$ , т.е.

$$E\hat{\theta}_n = \theta.$$

**Пример.**  $\bar{x}$  — несмещенная оценка  $E\xi$ .

*Доказательство.* Пусть  $\theta = E\xi$ ,  $\hat{\theta}_n = E\hat{\xi}_n = \bar{x}$ . Тогда

$$E\bar{x} = E\frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} \sum_{i=1}^n E x_i = \frac{1}{n} \sum_{i=1}^n E\xi = E\xi \implies E\hat{\theta}_n = E\theta, \text{ bias } \hat{\theta}_n = 0.$$

□

**Пример.**  $s^2$  является только *асимптотически* несмещенной оценкой  $D\xi$ .

*Доказательство.* Поскольку дисперсия не зависит от сдвига, обозначим  $\eta = \xi - E\xi$  и  $y_i = x_i - E\xi$ ; тогда

$$\begin{aligned} Es^2 &= E\widehat{D\xi} = E\widehat{D\eta} = E\left(\widehat{E\eta^2} - \left(\widehat{E\eta}\right)^2\right) = E\left(\frac{1}{n} \sum_{i=1}^n y_i^2 - \left(\frac{1}{n} \sum_{i=1}^n y_i\right)^2\right) \\ &= E\left(\frac{1}{n} \sum_{i=1}^n y_i^2 - \frac{1}{n^2} \sum_{i,j=1}^n y_i y_j\right) = E\left(\frac{1}{n} \sum_{i=1}^n y_i^2 - \frac{1}{n^2} \sum_{i,j=1}^n y_i^2\right) = \frac{1}{n} \sum_{i=1}^n E y_i^2 - \frac{1}{n^2} \sum_{i=1}^n E y_i^2 \\ &= \frac{1}{n} \sum_{i=1}^n E (x_i - E\xi)^2 - \frac{1}{n^2} \sum_{i=1}^n E (x_i - E\xi)^2 = \frac{1}{n} \sum_{i=1}^n D x_i - \frac{1}{n^2} \sum_{i=1}^n D x_i = D\xi - \frac{1}{n} D\xi \\ &= \frac{n-1}{n} D\xi \xrightarrow{n \rightarrow \infty} D\xi. \end{aligned}$$

□

**Определение.** *Исправленная дисперсия:*

$$\tilde{s}^2 := \frac{n}{n-1} s^2.$$

### 2.3.2. Состоятельность

**Определение.** Оценка называется *состоятельной* в *среднеквадратичном смысле*, если

$$\text{MSE } \hat{\theta}_n \xrightarrow{n \rightarrow \infty} 0.$$

**Определение.** Оценка называется *состоятельной*, если

$$\hat{\theta}_n \xrightarrow{P} \theta.$$

**Предложение.** Если оценка несмещенная и состоятельная в среднеквадратичном смысле, то она состоятельная.



*Доказательство.* В самом деле, по неравенству Чебышева,

$$\mathbb{P}(|\hat{\theta}_n - \theta| > \epsilon) = \mathbb{P}(|\hat{\theta}_n - \mathbb{E}\hat{\theta}_n| > \epsilon) \leq \frac{D\hat{\theta}_n}{\epsilon^2} = \frac{\text{MSE } \hat{\theta}_n}{\epsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

□

**Пример.**  $\hat{\mathbf{m}}_k$  является состоятельной оценкой  $\mathbf{m}_k$ .

*Доказательство.* Докажем для  $\hat{\mathbf{m}}_1$ . По определению выборки до эксперимента,  $x_i \sim \mathcal{P}$ . Тогда, по теореме Хинчина о ЗБЧ,

$$\bar{\mathbf{x}} = \frac{\sum_{i=1}^n x_i}{n} \xrightarrow{\mathbb{P}} \mathbf{m}_1(\mathcal{P}).$$

Для  $k$ -го момента доказываем аналогично заменой  $y_i := x_i^k$ .

□

*Замечание.* Для  $\mathbf{m}_k^{(0)}$  доказательство не пройдет, потому что  $x_i$  и  $\bar{\mathbf{x}}$  не будут независимыми.

**Пример.**  $\hat{\mathbf{m}}_k^{(0)}$  является состоятельной оценкой  $\mathbf{m}_k^{(0)}$ .

*Утверждение.* Пусть  $\xi_n \xrightarrow{\mathbb{P}} c$  и  $f \in C(U_\epsilon(c))$ . Тогда  $f(\xi_n) \xrightarrow{\mathbb{P}} f(c)$ .

*Доказательство предложения.* Докажем для  $s^2$ . Пусть  $f : (x, y) \mapsto x - y^2$ . Устроим последовательность  $(\hat{\mathbf{m}}_2, \hat{\mathbf{m}}_1) \xrightarrow{\mathbb{P}} (\mathbf{m}_2, \mathbf{m}_1)$ . Тогда

$$f(\hat{\mathbf{m}}_2, \hat{\mathbf{m}}_1) = \hat{\mathbf{m}}_2 - \hat{\mathbf{m}}_1^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{\mathbf{x}}^2 = s^2 \xrightarrow{\mathbb{P}} f(\mathbf{m}_2, \mathbf{m}_1) = D\xi.$$

Для  $\mathbf{m}_k^{(0)}$  доказываем аналогично.

□

**Пример.**  $\bar{\mathbf{x}}$  — состоятельная оценка  $\mathbb{E}\xi$ .

*Доказательство.* Либо по (2.3.2) для  $k = 1$ , либо из того факта, что  $\text{bias } \bar{\mathbf{x}} = 0$ , значит

$$\text{MSE } \bar{\mathbf{x}} = D\bar{\mathbf{x}} = \frac{D\xi}{n} \xrightarrow{n \rightarrow \infty} 0,$$

и по (2.3.2) получаем утверждение.

□

**Пример.**  $s^2$  — состоятельная оценка  $D\xi$ .

*Доказательство.* По (2.3.2) с  $k = 2$ .

□

**Пример.**  $\widehat{\text{cdf}}_\xi$  — состоятельная оценка cdf в каждой точке.

*Доказательство.* Введем

$$y_i := \mathbf{1}_{\{x_i < x\}} = \begin{cases} 1 & x_i < x \\ 0 & x_i \geq x. \end{cases}$$

Тогда по теореме Хинчина о ЗБЧ,

$$\widehat{\text{cdf}}_\xi(x) = \frac{|\{x_i \in \bar{\mathbf{x}} : x_i < x\}|}{n} = \frac{\sum_{i=1}^n y_i}{n} \xrightarrow{\mathbb{P}} \mathbb{E}y_i = \mathbb{E}\mathbf{1}_{\{x_i < x\}} = \mathbb{P}(x_i < x) = \text{cdf}(x).$$

Независимость  $y_i$  очевидна, если расписать  $\text{cdf}_{y_i}(x) \text{cdf}_{y_j}(y) = \text{cdf}_{y_i, y_j}(x, y)$ .

□

*Замечание.* Помимо ранее упомянутых, больше нет состоятельных выборочных характеристик.

*Утверждение.* Пусть  $\exists! p_0 : \text{cdf}(x) = p_0$  и  $\text{cdf}(x)$  монотонно возрастает в окрестности  $p_0$ . Тогда  $\bar{z}_{p_0} \xrightarrow{\mathbb{P}} z_{p_0}$ , т.е. является состоятельной оценкой.

### 2.3.3. Асимптотическая нормальность

**Определение.** Оценка называется *асимптотически нормальной*, если

$$\frac{\hat{\theta}_n - E\hat{\theta}_n}{\sqrt{D\hat{\theta}_n}} \xrightarrow{d} N(0, 1).$$

*Замечание.* Если  $\xi \sim N(a, \sigma^2)$ , то  $\bar{x}$  — просто нормальная оценка (как линейная комбинация нормальных случайных величин).

Все рассмотренные прежде оценки — асимптотически нормальные.

### 2.3.4. Эффективность

**Определение.** Соответствующая определению 2.5.2 оценка называется *эффективной*.

**Определение.** Оценка  $\hat{\theta}^{(1)}$  называется *эффективной* в сравнении с  $\hat{\theta}^{(2)}$ , если

$$MSE \hat{\theta}^{(1)} < MSE \hat{\theta}^{(2)}.$$

*Замечание.* Для несмещенных оценок это эквивалентно, конечно,

$$D\hat{\theta}^{(1)} < D\hat{\theta}^{(2)}.$$

**Пример** (Сравнение оценок мат. ожидания симметричного распределения). Пусть  $\mathcal{P}$  *симметрично* — в этом случае  $\widehat{\text{med}} \xi = \bar{x}$  и имеет смысл сравнить две этих характеристики.

$$\begin{aligned} D\bar{x} &= \frac{D\xi}{n} \\ \widehat{D\text{med}} \xi &\sim \frac{1}{4n \text{pdf}_{N(a, \sigma^2)}^2(\text{med } \xi)} \quad \text{при } n \rightarrow \infty. \end{aligned}$$

Так, если  $\xi \sim N(a, \sigma^2)$ , то

$$\text{pdf}_{N(a, \sigma^2)}^2(\text{med } \xi) = \frac{1}{2\pi\sigma^2} \exp \left\{ -\frac{(\text{med } \xi - a)^2}{\sigma^2} \right\} = \frac{1}{2\pi\sigma^2},$$

откуда

$$\widehat{D\text{med}} \xi = \frac{\pi \sigma^2}{2 n} > \frac{\sigma^2}{n} = D\bar{x},$$

значит  $\widehat{\text{med}} \xi$  эффективнее  $\bar{x}$ .

*Замечание.* В то же время,  $\widehat{\text{med}} \xi$  более устойчива к аутлаерам, чем  $\bar{x}$ , и этим лучше.

## 2.4. Метод моментов

Пусть  $\mathcal{P}(\theta)$ ,  $\theta = (\theta_1, \dots, \theta_r)^T$  — параметрическая модель. Найдём оценки для параметров  $\hat{\theta}_i$ ,  $i \in \overline{1:r}$ , для чего составим и решим систему уравнений:

$$\begin{cases} m_1 = \phi_1(\theta_1, \dots, \theta_r) \\ \vdots \\ m_r = \phi_r(\theta_1, \dots, \theta_r) \end{cases} \implies \begin{cases} \theta_1 = f_1(m_1, \dots, m_r) \\ \vdots \\ \theta_r = f_r(m_1, \dots, m_r). \end{cases}$$

Примем

$$\hat{\theta}_i = f_i(\hat{m}_1, \dots, \hat{m}_r).$$

*Замечание.* Поскольку  $f_i$  — непрерывные функции и при непрерывных преобразованиях сходимость не портится, оценки  $\hat{\theta}_i$  являются состоятельными.

Как правило, эти оценки смещенные.

*Замечание.* Случается, что решение находится вне пространства параметров. На практике, если пространство параметров компактное, можно взять точку, ближайшую к полученной оценке. Однако это свидетельствует о том, что модель плохо соответствует данным.

**Пример 1** ( $r = 1$ ). Пусть  $\mathcal{P}_\xi(\lambda) = \text{Exp}(\lambda)$ . Тогда  $E\xi = 1/\lambda$  и  $\bar{x} = 1/\lambda$ .

**Пример 2** ( $r = 2$ ). Пусть  $\mathcal{P}_\xi(\theta_1, \theta_2) = \text{Bin}(m, p)$ . Тогда

$$\begin{cases} E\xi = mp \\ D\xi = mp(1-p) \end{cases} \quad \begin{cases} m = \frac{E\xi}{p} \\ D\xi = E\xi - E\xi p \end{cases} \quad \begin{cases} p = \frac{E\xi - D\xi}{E\xi} \\ m = \frac{(E\xi)^2}{E\xi - D\xi} \end{cases} \Rightarrow \begin{cases} \hat{p} = \frac{\bar{x} - s^2}{\bar{x}} \\ \hat{m} = \frac{\bar{x}^2}{\bar{x} - s^2}. \end{cases}$$

## 2.5. Метод оценки максимального правдоподобия

### 2.5.1. Функция правдоподобия и метод

Пусть  $\mathcal{P}_\xi(\boldsymbol{\theta})$ ,  $\boldsymbol{\theta} = (\theta_1, \dots, \theta_r)^T$  — параметрическая модель.

**Определение.** *Функция правдоподобия:*

$$\mathcal{L}(\boldsymbol{\theta} \mid \mathbf{y}) = P(\mathbf{y} \mid \boldsymbol{\theta}) = \begin{cases} P_\theta(x_1 = y_1, \dots, x_n = y_n) & \mathcal{P}_\xi(\boldsymbol{\theta}) \text{ дискретно;} \\ p_\theta(\mathbf{y}) & \mathcal{P}_\xi(\boldsymbol{\theta}) \text{ абсолютно непрерывно.} \end{cases}$$

**Пример 3.** Пусть  $\xi \sim N(a, \sigma^2)$ . По независимости  $x_i$ ,  $p_\theta(\mathbf{x})$  распадается в произведение:

$$\mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}) = p_\theta(\mathbf{x}) = \prod_{i=1}^n p_\theta(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x_i - a)^2}{2\sigma^2}\right\} = \frac{1}{(2\pi)^{n/2} \sigma^n} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2\right\}.$$

**Пример 4.**  $\xi \sim \text{Pois}(\lambda)$ ,

$$P(\xi = k) = \frac{\lambda^k}{k!} e^{-\lambda} \Rightarrow \mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}) = \prod_{i=1}^n \frac{1}{x_i!} \lambda^{x_i} e^{-\lambda} = \frac{1}{\prod_{i=1}^n x_i!} \lambda^{n\bar{x}} e^{-n\lambda}.$$

*Утверждение.* Пусть  $\mathbf{x}$  — выборка. В качестве оценки максимального правдоподобия<sup>5</sup>  $\hat{\boldsymbol{\theta}}_{\text{MLE}}$  следует взять

$$\hat{\boldsymbol{\theta}}_{\text{MLE}} = \underset{\boldsymbol{\theta}}{\operatorname{argmax}} \ln \mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}).$$

**Предложение.**  $\hat{\boldsymbol{\theta}}_{\text{MLE}}$  является состоятельной оценкой.

*Доказательство.* Пусть  $\boldsymbol{\theta}_0$  — истинный параметр  $\mathcal{P}(\boldsymbol{\theta})$ . По УЗБЧ,

$$\frac{1}{n} \ln \mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \ln p_\theta(x_i) \xrightarrow{P} E \ln p_\theta(x_i) = \int_{\mathbb{R}} \ln(p_\theta(x)) p_{\theta_0}(x) dx.$$

Навесим на обе стороны  $\operatorname{argmax}$  в условии, что это непрерывное преобразование:

$$\hat{\boldsymbol{\theta}}_{\text{MLE}} \leftarrow \underset{\boldsymbol{\theta}}{\operatorname{argmax}} \frac{1}{n} \ln \mathcal{L}(\boldsymbol{\theta} \mid \mathbf{x}) \xrightarrow{P} \underset{\boldsymbol{\theta}}{\operatorname{argmax}} \int_{\mathbb{R}} \ln(p_\theta(x)) p_{\theta_0}(x) dx \rightarrow \boldsymbol{\theta}^*.$$

Тогда в предположении непрерывности  $p_\theta$  по  $\boldsymbol{\theta}$ ,  $\hat{\boldsymbol{\theta}}_{\text{MLE}} \xrightarrow{P} \boldsymbol{\theta}^*$ . Покажем, что  $\boldsymbol{\theta}^* = \boldsymbol{\theta}_0$ . Поделим на  $p_{\theta_0}$  — константу по  $\boldsymbol{\theta}$ :

$$\frac{1}{n} \sum_{i=1}^n \ln \frac{p_\theta}{p_{\theta_0}}(x_i) \xrightarrow{P} \int_{\mathbb{R}} \ln \left( \frac{p_\theta(x)}{p_{\theta_0}(x)} \right) p_{\theta_0}(x) dx = E \ln \frac{p_\theta}{p_{\theta_0}} \leq \ln E \frac{p_\theta}{p_{\theta_0}} = \ln \int_{\mathbb{R}} \frac{p_\theta}{p_{\theta_0}}(x) p_{\theta_0}(x) dx = \ln 1 = 0$$

<sup>5</sup>Maximum likelihood estimate (MLE).

по неравенству Ёнсена  $\mathbb{E}g(\xi) \leq g(\mathbb{E}\xi)$ , для выпуклой вверх  $g(x) = \log(x)$ . Таким образом,

$$\int_{\mathbb{R}} \ln \left( \frac{p_{\theta}(x)}{p_{\theta_0}(x)} \right) p_{\theta_0}(x) dx = 0 \iff \ln \left( \frac{p_{\theta}(x)}{p_{\theta_0}(x)} \right) = 0 \iff \frac{p_{\theta}(x)}{p_{\theta_0}(x)} = 1 \iff p_{\theta}(x) = p_{\theta_0}(x).$$

В предположении свойства *идентифицируемости* задачи  $(\theta_1 \neq \theta_2 \implies \mathcal{P}_{\theta_1} \neq \mathcal{P}_{\theta_2})$ , получаем  $\theta = \theta_0$ .  $\square$

**Пример.**  $\xi \sim \text{Pois}(\lambda)$ .

$$\ln \mathcal{L}(\lambda \mid \mathbf{x}) = - \sum_{i=1}^n x_i! - n\lambda + \ln(\lambda^{n\bar{x}}) \implies \frac{d \ln \mathcal{L}(\lambda \mid \mathbf{x})}{d\lambda} = -n + \lambda^{-n\bar{x}} n\bar{x} \lambda^{n\bar{x}-1} = -n + \frac{n\bar{x}}{\lambda}$$

откуда

$$\frac{d \ln \mathcal{L}(\lambda \mid \mathbf{x})}{d\lambda} = 0 \iff -n + \frac{n\bar{x}}{\lambda} = 0, \quad n\bar{x} - n\lambda = 0, \quad \lambda = \bar{x}.$$

*Утверждение.* В условиях регулярности<sup>6</sup>:

1. Существует один глобальный максимум, так что

$$\left. \frac{d\mathcal{L}(\theta \mid \mathbf{x})}{d\theta} \right|_{\theta=\hat{\theta}_{\text{MLE}}} = 0.$$

2.  $\hat{\theta}_{\text{MLE}}$  обладает всеми свойствами:

- a) Состоятельность;
- b) Асимптотическая несмещенность;
- c) Асимптотическая нормальность;
- d) Эффективность.

## 2.5.2. Информационное количество Фишера и эффективность оценки MLE

Пусть  $r = 1$ .

**Определение.** *Информанта  $n$ -го порядка:*

$$S_n(\mathbf{x}, \theta) = \frac{d^n \ln \mathcal{L}(\theta \mid \mathbf{x})}{d\theta^n}.$$

**Определение.** *Информационное количество Фишера:*

$$I_n(\theta) := -\mathbb{E} S_2(\mathbf{x}, \theta).$$

*Утверждение.*

$$I_n(\theta) = \mathbb{E} S_1^2(\mathbf{x}, \theta).$$

**Пример.**  $\xi \sim \text{Pois}(\lambda)$ .

$$S_1(\mathbf{x}, \theta) = -n + \frac{n\bar{x}}{\lambda}, \quad S_2(\mathbf{x}, \theta) = -\frac{n\bar{x}}{\lambda^2} \implies I_n(\lambda) = \mathbb{E} \frac{n\bar{x}}{\lambda^2} = \frac{n}{\lambda^2} \mathbb{E} \bar{x} = \frac{n}{\lambda}.$$

---

<sup>6</sup>Условия регулярности таковы:

- $\{x : p_{\theta}(x) > 0\}$  не зависит от  $\theta$ ,
- $\int_{V^n} \hat{\theta} \mathcal{L}(\theta \mid \mathbf{x}) d\mathbf{x}$  и  $\int_{V^n} \mathcal{L}(\theta \mid \mathbf{x}) d\mathbf{x}$  можно дифференцировать по  $\theta$  под знаком интеграла,
- $I_n(\theta) > 0$ .

*Замечание.*

$$\ln \mathcal{L}(\theta | \mathbf{x}) = \sum_{i=1}^n \ln p_{\theta}(x_i) \implies S_2 = \frac{d^2 \ln \mathcal{L}(\theta | \mathbf{x})}{d\theta^2} = \sum_{i=1}^n (\ln p_{\theta}(x_i))'',$$

откуда, для повторной независимой выборки,

$$I_n(\theta) = - \sum_{i=1}^n \mathbb{E}(\ln p_{\theta}(x_i))'' = n \cdot i(\theta), \quad \text{где } i(\theta) = -\mathbb{E}(\ln p_{\theta}(\xi))''.$$

*Утверждение.* Для несмещенных оценок в условиях регулярности справедливо неравенство Рао–Крамера:

$$D\hat{\theta}_n \geq \frac{1}{I_n(\theta)}.$$

**Определение.** Эффективная оценка:

$$D\hat{\theta}_n = \frac{1}{I_n(\theta)}.$$

*Замечание.* Для несмещенных оценок неравенство Рао–Крамера указывает точную нижнюю границу дисперсий оценок.

**Пример.** Пусть  $\xi \sim \text{Pois}(\lambda)$ . Поскольку

$$\begin{aligned} D\hat{\lambda}_n &= D\bar{x} = E\xi/n = \lambda/n \\ I_n(\lambda) &= n/\lambda, \end{aligned}$$

то  $\hat{\lambda}_n$  — эффективная оценка (как и ожидалась по свойствам  $\hat{\theta}_{\text{MLE}}$ ).

**Определение.** Пусть  $\hat{\theta}_n$  — асимптотически несмещенная оценка. Тогда  $\hat{\theta}_n$  — асимптотически эффективная, если

$$D\hat{\theta}_n \cdot I_n \xrightarrow{n \rightarrow \infty} 1.$$

**Пример.** Пусть  $\xi \sim N(a, \sigma^2)$ . Можно посчитать, что  $s^2$  является только асимптотически эффективной оценкой  $\sigma^2$ ;  $\tilde{s}^2$  — просто эффективной.

### 3. Некоторые распределения, связанные с нормальным

#### 3.1. Распределение $\chi^2(m)$

**Определение** (Распределение  $\chi^2(m)$ ).  $\eta$  имеет распределение  $\chi^2$  с  $m$  степенями свободы:

$$\eta \sim \chi^2(m) \iff \eta = \sum_{i=1}^m \zeta_i^2, \quad \zeta_i \sim N(0, 1), \quad \zeta_i \text{ независимы.}$$

**Свойства**<sup>7</sup>  $\chi^2(m)$

$$\begin{aligned} E\eta &= \sum_{i=1}^m E\beta_i^2 = m \\ D\eta &= 2m. \end{aligned}$$

*Утверждение.* Пусть  $\eta_m \sim \chi^2(m)$ . Тогда, по ЦПТ,

$$\frac{\eta_m - E\eta_m}{\sqrt{D\eta_m}} = \frac{\eta_m - m}{\sqrt{2m}} \xrightarrow{d} N(0, 1).$$

**Пример.**  $m = 50$ ,  $\eta_m = 80$ . Тогда

$$\frac{80 - 50}{10} = 3$$

и можно посчитать, к примеру,  $\Phi(3) \approx 0.9986$ .

<sup>7</sup>Вычисление  $D\eta$ : <https://www.statlect.com/probability-distributions/chi-square-distribution>

### 3.2. Распределение Стьюдента $t(m)$

**Определение** (Распределение  $t(m)$ ).  $\xi$  имеет распределение Стьюдента с  $m$  степенями свободы, если

$$\xi \sim t(m) \iff \xi = \frac{\zeta}{\sqrt{\eta/m}}, \quad \zeta \sim N(0, 1), \quad \eta \sim \chi^2(m).$$

**Свойства  $t(m)$**

- При  $m = 1$  это распределение Коши.
- При  $m > 1$ ,  $E\zeta = 0$  по симметричности.
- При  $m > 2$ ,  $D\zeta = m/(m - 2)$ .
- При  $m > 3$ ,  $A\zeta = 0$  по симметричности.
- При  $m > 4$ ,  $K\zeta = 6/(m - 4)$ .

**Предложение.** Распределение Стьюдента сходится к стандартному нормальному:

$$t \Rightarrow N(0, 1).$$

Соображения по поводу.  $D\zeta \rightarrow 1$ ,  $K\zeta \rightarrow 0$ . □

### 3.3. Распределение Фишера

**Определение.** Распределение Фишера имеет вид

$$F(m, k) = \frac{\chi^2(m)/m}{\chi^2(k)/k}.$$

*Замечание.*  $F(1, k) \sim t^2(k)$ ;  $m \cdot F(m, \infty) = \chi^2(m)$  потому что  $\chi^2(k) \xrightarrow[k \rightarrow \infty]{} 1$ .

### 3.4. Квадратичные формы от нормально распределенных случайных величин

Пусть  $\xi = (\xi_1, \dots, \xi_p)^T \sim N(0, \sigma^2 I_p)$ ,  $B$  — симметричная, неотрицательно определенная матрица. Найдем распределение  $\xi^T B \xi$ .

*Утверждение.* Пусть  $\xi \sim N(0, \sigma^2 I_p)$ ,  $B, C$  — симметричные матрицы размерности  $p \times p$ . Тогда  $\xi^T B \xi \perp \xi^T C \xi \iff BC = 0$ .

**Пример** (Независимость  $\bar{x}^2$  и  $s^2$ ). Пусть

$$B = \frac{1}{p} \begin{pmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{pmatrix};$$

тогда

$$\mathbf{x}^T B \mathbf{x} = \frac{1}{p} (x_1, \dots, x_p) \begin{pmatrix} \sum_{i=1}^p x_i \\ \vdots \\ \sum_{i=1}^p x_i \end{pmatrix} = \frac{1}{p} \sum_{j=1}^p \sum_{i=1}^p x_i x_j = \frac{1}{p} \left( \sum_{i=1}^p x_i \right)^2 = p \bar{x}^2.$$

В то же время, пусть

$$C = \begin{pmatrix} 1 - 1/p & \dots & -1/p \\ \vdots & \ddots & \vdots \\ -1/p & \dots & 1 - 1/p \end{pmatrix};$$

тогда

$$\begin{aligned} \mathbf{x}^T \mathbf{C} \mathbf{x} &= (x_1, \dots, x_p) \begin{pmatrix} (1 - 1/p) x_1 - 1/p \cdot \sum_{i=2}^p x_i \\ \vdots \\ -1/p \cdot \sum_{i=1}^{p-1} x_i + (1 - 1/p) x_p \end{pmatrix} = (x_1, \dots, x_p) \begin{pmatrix} x_1 - 1/p \cdot \sum_{i=1}^p x_i \\ \vdots \\ x_p - 1/p \cdot \sum_{i=1}^p x_i \end{pmatrix} \\ &= \sum_{j=1}^p \left( x_j^2 - \frac{1}{p} \sum_{i=1}^p x_i x_j \right) = \sum_{j=1}^p x_j^2 - p \bar{x}^2 = p s^2. \end{aligned}$$

Но, учитывая  $\mathbf{B}^2 = \mathbf{B}$  (легко проверяется),

$$\mathbf{C} = \mathbf{I}_p - \mathbf{B} \implies \mathbf{B} \mathbf{C} = \mathbf{B} - \mathbf{B}^2 = \mathbf{0},$$

откуда  $\bar{\mathbf{x}}^2 \perp s^2$ .

Видно, что  $\sigma^{-2} \boldsymbol{\xi}^T \mathbf{I}_p \boldsymbol{\xi} \sim \chi^2(p)$ . На самом деле справедливо

*Утверждение.* Пусть  $\boldsymbol{\xi} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_p)$ ,  $\mathbf{B}$  — симметричная, неотрицательно неопределенная матрица размерности  $p \times p$  и  $\text{rk } \mathbf{B} = r$ . Тогда

$$\sigma^{-2} \boldsymbol{\xi}^T \mathbf{B} \boldsymbol{\xi} \sim \chi^2(r) \iff \mathbf{B}^2 = \mathbf{B}.$$

**Пример.**  $p \sigma^{-2} s^2 \sim \chi^2(p - 1)$ . Воспользуемся представлением из предыдущего примера:  $p s^2 = \mathbf{x}^T \mathbf{C} \mathbf{x}$ . Но  $\text{rk } \mathbf{C} = \text{rk}(\mathbf{I}_p - \mathbf{B}) = p - 1$ ;  $\mathbf{B}^2 = \mathbf{B}$ , значит  $p \sigma^{-2} s^2 \sim \chi^2(p - 1)$ .

*Утверждение (Cochran).* Пусть  $\boldsymbol{\xi} \sim N(\mathbf{0}, \mathbf{I}_p)$ ,  $\boldsymbol{\xi}^T \boldsymbol{\xi} = \sum_i Q_i$ , где  $Q_i$  — квадратичная форма, заданная  $\mathbf{B}_i$ ,  $\text{rk } \mathbf{B}_i = r_i$ . Тогда следующие утверждения эквивалентны:

1.  $\sum r_i = p$
2.  $Q_i \sim \chi^2(r_i)$
3.  $Q_i \perp Q_j, \quad \forall i \neq j$ , т.е.  $\mathbf{B}_i \mathbf{B}_j = \mathbf{0}$ .

## 4. Проверка гипотез

*Замечание.* Этот раздел иногда называется «Confirmatory Data Analysis» в противовес «Exploratory Data Analysis», не включающему в себя понятие *гипотезы*.

### 4.1. Построение критерия

Пусть  $x_1, \dots, x_n \sim \mathcal{P}$ .

**Определение.** *Модель* — утверждение о  $\mathcal{P}$ , которое считается верным и не проверяется.

**Определение.** *Гипотеза* — утверждение о  $\mathcal{P}$ , требующее проверки. Гипотеза называется *простой*, если она соответствует только одному распределению в рамках рассматриваемой модели, или — в противном случае — *сложной*.

**Определение.** *Нулевая гипотеза*  $H_0$  — утверждение об интересующем экспериментатора свойстве распределений.

*Замечание.* Обыкновенно,  $H_0$  — простая гипотеза.

Помимо  $H_0$ , может вводиться *альтернативная гипотеза*  $H_1$ , учитывающая отклонения от  $H_0$ , обнаружение которых желательно. Обыкновенно, это сложная гипотеза.

**Определение.** Пусть  $\mathcal{P}$  — множество всех распределений. Поставленная  $H_0$  задает разбиение  $\mathcal{P} = \mathcal{P}_0 \sqcup \mathcal{P}_1$ , где  $\mathcal{P}_0$  — распределения, удовлетворяющие утверждению. Стоит задача проверить по выборке, что  $\mathcal{P} \in \mathcal{P}_0$ , т.е. пусть задан «оракул»

$$\varphi(\mathbf{x}) = \begin{cases} 0 & H_0 \text{ верна, } \mathcal{P} \in \mathcal{P}_0 \\ 1 & H_0 \text{ не верна, } \mathcal{P} \in \mathcal{P}_1. \end{cases}$$

Будем говорить, что гипотеза *отвергается*, если  $\varphi(\mathbf{x}) = 1$  и *не отвергается* иначе.

Поскольку выборка конечного объема позволяет делать только вероятностные заключения, со статистическим критерием ассоциированы ошибки двух родов:

**Определение.** *Ошибка I-го рода* есть отвержение верной  $H_0$ :

$$H_0 \text{ верна, но } \varphi(\mathbf{x}) = 1.$$

Иными словами, это принятие случайного различия за систематическое.

Соответствующая вероятность обозначается

$$\alpha_I = P(\varphi(\mathbf{x}) = 1 \mid \mathcal{P} \in \mathcal{P}_0) = P_{H_0}(\varphi(\mathbf{x}) = 1).$$

**Определение.** *Ошибка II-го рода* есть вероятность ошибочно не отвергнуть  $H_0$ :

$$H_0 \text{ не верна, но } \varphi(\mathbf{x}) = 0.$$

Иными словами, это принятие наблюдаемого различия за случайный эффект.

Соответствующая вероятность обозначается

$$\alpha_{II} = P(\varphi(\mathbf{x}) = 0 \mid \mathcal{P} \in \mathcal{P}_1) = P_{H_1}(\varphi(\mathbf{x}) = 0).$$

**Определение.** *Мощность* критерия против альтернативы это вероятность справедливо отвергнуть  $H_0$ :

$$\beta = 1 - \alpha_{II} = 1 - P_{H_1}(\varphi(\mathbf{x}) = 0) = P_{H_1}(\varphi(\mathbf{x}) = 1).$$

Иными словами, это способность критерия отличать  $H_0$  от  $H_1$ .

**Определение.** Критерий называется *состоятельным*, если  $\beta \rightarrow 1$ .

**Определение.** До эксперимента фиксируется величина  $\alpha \in [0, 1]$  называемая *уровнем значимости* критерия. Неформально,  $\alpha$  обратно пропорциональна «строгости» критерия, выбираемой экспериментатором.

*Замечание.* Стандартные уровни значимости:  $\alpha = 0.05$  или  $\alpha = 0.01$ .

*Замечание.* В идеале, хотят, чтобы  $\alpha_I, \alpha_{II} \xrightarrow{n \rightarrow \infty} 0$ . Однако отрицание  $H_0$  порождает распределение, которое сложно вычислить.

**Определение.** Для выборки

$$\mathbf{x} = (x_1, \dots, x_n) : (\Omega, \mathcal{F}, P) \rightarrow (V^n, \mathcal{A}^n)$$

*критерий* есть разбиение всевозможных значений выборки на доверительную и критическую области

$$V^n = \mathcal{A}_{\text{крит}}^{(\alpha)} \sqcup \mathcal{A}_{\text{дов}}^{(\alpha)}$$

с учетом желаемого уровня значимости  $\alpha$ , т.е. такое, что

$$P_{H_0}(\mathbf{x} \in \mathcal{A}_{\text{крит}}^{(\alpha)}) = P_{H_0}(\varphi(\mathbf{x}) = 1) = \alpha_I = \alpha.$$

Разумеется,  $\mathcal{A}_{\text{крит}}^{(\alpha)} = \{\mathbf{x} \in V^n : \varphi(\mathbf{x}) = 1\}$  и  $\mathcal{A}_{\text{дов}}^{(\alpha)} = \{\mathbf{x} \in V^n : \varphi(\mathbf{x}) = 0\}$ .



**Определение.** Если

$\alpha = \alpha_I$  то критерий называется *точным*,

$\alpha \xrightarrow[n \rightarrow \infty]{} \alpha_I$  *асимптотическим*,

$\alpha < \alpha_I$  *радикальным* (т.е. отвергает гипотезу чаще, чем точный),

$\alpha > \alpha_I$  *консервативным* (если гипотеза отвергнута, то уж наверняка).

*Замечание.*  $\mathcal{A}_{\text{крит}}$  может быть корректно построена бесчисленным множеством способов. Следует выбрать тот из них, что гарантирует наибольшую мощность.

*Замечание.* Задача может допускать две постановки; в этом случае, поскольку  $\alpha_I$  ( $= \alpha$  для правильно построенного критерия) контролируется экспериментатором, проверяется отрицание эффекта, который хотят подтвердить: к примеру, что новое лекарство *не* лучше старого; если  $H_0$  отвергнется, это будет означать, что новое лекарство-таки лучше старого с вероятностью не ниже, чем  $1 - \alpha$ .

**Пример** (Экстрасенс угадывает карты). Некто заявляет о способности не глядя угадывать масти предлагаемых карт. Выдвигаем гипотезу  $H_0$ : человек *не* экстрасенс, так что угадывает с вероятностью  $p = 1/4$ . Предлагаем отгадать масть 25 карт; число угаданных карт есть  $x$ . Наибольшей «строгости» будет соответствовать  $x = 25$ , таким образом

$$P_{H_0}(x \in \mathcal{A}_{\text{крит}}) = P_{H_0}(x = 25) = \left(\frac{1}{4}\right)^{25} \approx 10^{-15} = \alpha.$$

Если же для нас достаточно 24 угаданных карт из 25, то  $\alpha$  будет побольше:  $P_{H_0}(x \geq 24) = P_{H_0}(x = 24) + P_{H_0}(x = 25)$  и т.д. Зафиксированная до эксперимента  $\alpha$  определяет количество карт  $c$  такое, что при угадывании большего количества  $H_0$  будет считаться опровергнутой:

$$\alpha_I = P_{H_0}(x \geq c) \leq \alpha.$$

Среди всех таких  $c$  следует выбрать наименьшее, чтобы минимизировать ошибку второго рода.

**Пример** (С гранатами). FIXME

*Замечание.* Утверждать об *отвержении* гипотезы можно с вероятностью ошибки  $\alpha$  (достаточно малой и произвольно задаваемой экспериментатором); утверждать о *принятии* гипотезы можно с вероятностью ошибки  $\alpha_{II}$  — не контролируемой и потенциально довольно большой. Иными словами, попадание в доверительную область может означать как то, что  $H_0$  верна, так и то, что верна  $H_1$ , но для распознавания этого не хватило мощности. Поэтому безопасно гипотезу можно только отвергать или не отвергать. Можно и принять, если известна мощность критерия против всех возможных альтернатив, экспериментатора устраивающая.

*Замечание.* При высокой вероятности ошибки II-го рода возможна ситуация не отвержении заведомо ложной гипотезы. Это, в свою очередь, может произойти из-за маленького объема выборки (критерий не находит разницу, см. 5). Чем больше объем выборки, тем мощность больше, но возможна ситуация, когда критерий чувствителен настолько, что находит разницу там, где не должен — например, при генерации «идеальным» датчиком случайных чисел, начиная с какого-то объема заведомо истинная гипотеза может быть отвергнута из-за ошибок в точности представления чисел с плавающей точкой.

**Определение.** Критерий называется *одно- (двух-) сторонним* по тому, где находится альтернатива.

**Определение.** Критическая область называется *одно- (дву-) сторонней* по тому, где формально располагается  $\mathcal{A}_{\text{крит}}$ .

## 4.2. Статистика критерия

Строить разбиение многомерного пространства  $V^n$  неудобно, поэтому вводится статистика критерия.

**Определение.** *Статистика критерия* есть отображение

$$T : \mathbf{x} \mapsto y \in \mathbb{R}.$$

*Утверждение.* С введенной статистикой критерия можно разбивать на критическую и доверительную области не  $V^n$ , а образ  $T$ :

$$\text{im } T = \mathcal{A}_{\text{крит}}^{(\alpha)} \sqcup \mathcal{A}_{\text{дов}}^{(\alpha)}.$$

Остальные связанные с критерием понятия остаются в силе с соответствующей заменой  $\mathbf{x}$  на  $T$ .

**Определение.** *p-value* значения статистики  $T$  есть вероятность получить такое же или большее по модулю значение  $T$  при верной  $H_0$ .

*p-value* обратно пропорционален «существенности» результата.

Если *p-value* меньше  $\alpha$ , то  $H_0$  отвергается, иначе нет.

### Схема построения критерия с помощью статистики критерия на примере *t*-критерия

1. Фиксируют предположение относительно данных.

$$\xi \sim N(a, \sigma^2).$$

2. Выдвигают  $H_0$  и  $H_1$ .

- $H_0$  формулируется согласно замечанию 4.1.
- $H_1$  ставится по смыслу задачи (см. далее).

$$H_0 : a = a_0.$$

3. Выбирают подходящий критерий и статистику  $T$ .  $T$  должна измерять то, насколько выборка соответствует гипотезе. В этом случае должно быть известно «идеальное соответствие»  $T$  ( $E\xi$  логично измерять разницей,  $\bar{\mathbf{x}} - a_0$  — тогда идеальным соответствием будет 0.) Распределение  $T$  при верной  $H_0$  должно быть известно хотя бы асимптотически. Кроме того, должно быть известно поведение статистики в случае верной  $H_1$  (указать распределение в этом случае не всегда возможно, потому что часто  $H_1$  соответствует целый класс распределений).

$$T = z = \sqrt{n} \frac{\bar{\mathbf{x}} - a_0}{\sigma} \sim N(0, 1).$$

(по ??).

4. Фиксируют уровень значимости  $\alpha$ .
5. Строят разбиение  $\text{im } T$  с помощью квантилей распределения  $T$  (при верной  $H_0$ ) так, чтобы  $\alpha_1 = \alpha$ ; положение квантилей выбирают из известного поведения статистики при верной  $H_1$ :

**Двусторонний критерий** Пусть  $H_1 : E\xi = a_1 \neq a_0$ ; тогда по ЗБЧ  $\bar{\mathbf{x}} - a_0 \rightarrow a_1 - a_0$  и  $|T| \xrightarrow[n \rightarrow \infty]{} \infty$ . Следовательно, чтобы максимизировать величину  $\beta = P_{H_1}(\mathbf{x} \in \mathcal{A}_{\text{крит}}^{(\alpha)})$ , следует разместить  $\mathcal{A}_{\text{крит}}$  на правом и левом хвостах (симметрично) распределения статистики:  $\mathcal{A}_{\text{крит}} = \mathbb{R} \setminus (z_{\alpha/2}, z_{1-\alpha/2})$ .

**Односторонний критерий** Пусть  $H_1 : E\xi = a_1 > a_0$ ; тогда по ЗБЧ  $\bar{\mathbf{x}} - a_0 \rightarrow a_1 - a_0 > 0$  и  $T \rightarrow +\infty$ , откуда  $\mathcal{A}_{\text{крит}} = (z_{1-\alpha}, \infty)$ . Для  $H_1 : E\xi = a_1 < a_0$  аналогично  $\mathcal{A}_{\text{крит}} = (-\infty, z_\alpha)$ .

**Простая альтернатива** Пусть  $H_1 : E\xi = a_1$ ; тогда, поскольку при верной  $H_1$ ,  $E\bar{\mathbf{x}} = 1/n \cdot \sum_{i=1}^n \xi_i = n/n \cdot a_1$ , то

$$Ez = \frac{\sqrt{n}(a_1 - a_0)}{\sigma} \Rightarrow z \sim N\left(\frac{\sqrt{n}(a_1 - a_0)}{\sigma}, 1\right) \text{ при верной } H_1.$$

(дисперсия, конечно, не меняется при сдвиге).




Рис. 1: Плотности распределения  $z$  (неоптимальное разбиение)

Чтобы минимизировать  $\alpha_{\text{II}}$ , логично определить  $\mathcal{A}_{\text{крит}}$  только на одном хвосте — с той стороны, где находится альтернатива.




Рис. 2: Плотности распределения  $z$  (оптимальное разбиение)

*Замечание.* Помимо этого, по рисунку видно, что минимизировать  $\alpha_{\text{II}}$  (согласившись на бóльшую ошибку первого рода) можно сдвинув вправо центр второй плотности, увеличив  $n$ .

Аналогично, чем  $a_1$  дальше от  $a_0$ , тем  $\alpha_{\text{II}}$  меньше.

6. Считают значение статистики и принимают решение об отвержении  $H_0$  в зависимости от того, попадает ли оно в  $\mathcal{A}_{\text{крит}}$  или  $\mathcal{A}_{\text{дов}}$ :

$$\varphi(\mathbf{x}) = \begin{cases} 0 & T(\mathbf{x}) \in \mathcal{A}_{\text{дов}} \\ 1 & T(\mathbf{x}) \in \mathcal{A}_{\text{крит}} \end{cases}$$

Альтернативно, можно посчитать  $p$ -value, на основании чего сделать вывод.

**Пример** (Средняя температура в холодильнике). Хотят купить холодильник, такой, чтобы температура держалась в окрестности 0. Известно количество измерений  $n = 25$  и  $\bar{x} = 0.7$ .

1. Пусть  $\xi \sim N(a, 4)$ .
2. Выдвинута  $H_0 : E\xi = a_0 = 0$  — если гипотеза опровергнется, то холодильник не купят;  
 $H_1 : E\xi = a_1 \neq a_0$ .
3. Поскольку модель нормальная и известная  $\sigma^2$ , выберем статистику ?? («z-test»):

$$z = \frac{\sqrt{n}(\bar{x} - a_0)}{\sigma} \sim N(0, 1) \text{ при верной } H_0.$$

Идеальное значение статистики — 0.

4. Зафиксируем два уровня значимости:  $\alpha^{(1)} = 0.2$  (храним петрушку) и  $\alpha^{(2)} = 0.01$  (храним дорогую красную икру).
5. Построим разбиение. Поскольку  $a_1 \neq a_0$ , то  $\mathcal{A}_{\text{крит}} = \mathbb{R} \setminus (z_{\alpha/2}, z_{1-\alpha/2})$ . Для введенных уровней значимости это означает
  - а)  $\mathcal{A}_{\text{крит}}^{(\alpha^{(1)})} \approx \mathbb{R} \setminus (-1.28, 1.28)$ .
  - б)  $\mathcal{A}_{\text{крит}}^{(\alpha^{(2)})} \approx \mathbb{R} \setminus (-2.576, 2.576)$ .
6. Посчитаем

$$z(\mathbf{x}) = \frac{\sqrt{n}(\bar{x} - a_0)}{\sigma} = \frac{5(0.7 - 0)}{2} = 1.75.$$

Дальнейшее принятие решения возможно на основании критического значения или  $p$ -value.

- По вычислению критического значения:
  - ◇  $z \in \mathcal{A}_{\text{крит}}^{(\alpha^{(1)})}$ ,  $H_0$  отвергается, холодильник не покупают.
  - ◇  $z \in \mathcal{A}_{\text{дов}}^{(\alpha^{(2)})}$ ,  $H_0$  не отвергается, холодильник, быть может, покупают.
- Можно посчитать  $p$ -value:

$$2 \cdot (1 - \text{cdf}_{N(0,1)}(1.75)) \approx 0.08.$$

Поэтому при уровне значимости  $\alpha^{(1)} = 0.2 > 0.08$   $H_0$  отвергается, а при  $\alpha^{(2)} = 0.01 < 0.08$  не отвергается.

**Пример** (С мышью). В одном из рукавов Т-образного лабиринта лежит морковка. К развилке по лабиринту бежит мышь и 7 раз из 10 поворачивает в направлении морковки. На основании этих данных хотим сделать вывод, что мышь чует морковь на расстоянии, после чего написать научную статью.

- $\xi \sim \text{Ber}(p)$ . Выдвинем гипотезу, что мышь *не* чует морковку,  $H_0 : p = p_0 = 0.5$ . Поскольку  $E\xi = p$ , воспользуемся критерием для проверки гипотезы о значении среднего с идеальным значением 0; учитывая  $D\xi = p(1 - p)$ ,


$$\begin{aligned} T &= \sqrt{n} \frac{\bar{x} - p_0}{\sqrt{p_0(1 - p_0)}} \xrightarrow{d} N(0, 1). \\ &= \frac{\sqrt{10} \cdot 0.2}{0.5} \approx 1.2649 \implies p\text{-value} = 2 \cdot (1 - \text{cdf}_{N(0,1)}(1.2649)) \approx 0.2. \end{aligned}$$

Значит, с уровнем значимости 0.2 гипотеза не отвергается. Хочется иметь, конечно, один из стандартных уровней значимости, например 0.1.

- Увеличим мощность критерия, введя альтернативную гипотезу, что мышь чует морковку (в предположении, что все мыши любят морковь и к ней бегут),  $H_1 : p_1 > p_0$ . По 5, можем устроить односторонний критерий, так что  $p$ -value теперь 0.1. Однако пользуемся асимптотическим критерием при  $n = 10$ .
- Воспользуемся точным односторонним критерием со статистикой

$$T := n\bar{x} = \sum_{i=1}^n x_i \sim \text{Bin}(n, p_0)$$

и идеальным значением  $np_0$ . Тогда  $T = 10 \cdot 0.7 = 7$ . При уровне значимости  $\alpha = 0.1$  успешно попадаем в критическую область, вследствие чего  $H_0$  отвергается, и можем публиковаться.



*Замечание.* Исторически существовало два подхода к проверке гипотез: Фишера («significance test») и Неймана-Пирсона («hypothesis testing»).

**Фишер** Выдвигается  $H_0$ . Подсчитывается и сообщается точное  $p$ -value. Если результат «незначительный», не делается никаких выводов об отвержении  $H_0$ , но делается возможным дополнительный сбор данных.

**Нейман-Пирсон** Выдвигаются  $H_1, H_2$ , фиксируются  $\alpha_I, \alpha_{II}$  и  $n$ . На этом основании определяются  $\mathcal{A}_{\text{крит}}$  для каждой гипотезы. Если данные попали в  $\mathcal{A}_{\text{крит}}$   $H_1$  — предпочитается  $H_2$ , иначе  $H_2$ .

Современная теория проверки гипотез есть смесь двух этих подходов, не всегда консистентная. Вводные курсы по статистике формулируют теорию, похожую на significance testing Фишера; при повышенных требованиях к математической строгости, пользуются теорией Неймана-Пирсона.

*Замечание* (О графике  $p$ -values). Поскольку

$$\alpha_I \leftarrow P_{H_0}(T \in \mathcal{A}_{\text{крит}}) = P_{H_0}(p\text{-value} < \alpha),$$

то  $p$ -value по распределению стремятся к  $U(0, 1)$  при верной  $H_0$ . Это соображение позволяет визуально проверить истинность гипотезы: достаточно несколько (много) раз произвести эксперимент, для каждой выборки  $\bar{x}^{(i)}$  посчитать свой  $p$ -value, построить график и убедиться, что получилась прямая. Для подсчета мощности  $\beta = P_{H_1}(\mathbf{x} \in \mathcal{A}_{\text{крит}}^{(\alpha)}) = P_{H_1}(p\text{-value} < \alpha)$  считать выборку с параметрами  $H_1$ , а  $T$  относительно  $H_0$ .

### 4.3. Проверка гипотезы о значении мат. ожидания ( $t$ -критерий)

$H_0 : E\xi = a = a_0$ . Соответствие оценки математического ожидания гипотезе удобно выражать разницей  $\bar{x} - a_0$  с «идеальным» значением 0. Отнормировав эту разницу, получим статистику, распределение которой известно.

*Замечание* (Важное). Критерий работает только в нормальной модели и не становится асимптотически нормальным в ином случае!

#### 4.3.1. $D\xi = \sigma^2 < \infty$

**Предложение.** Пусть  $D\xi = \sigma^2 < \infty$ ; тогда используется следующая статистика

$$t = \sqrt{n} \frac{(\bar{\mathbf{x}} - a_0)}{\sigma} \xrightarrow{n \rightarrow \infty} N(0, 1)$$

*Доказательство.* По ЦПТ. □

**Предложение.** При условии нормальности данных,  $t$ -критерий называется « $z$ -критерием», причем

$$t = z \sim N(0, 1).$$

*Доказательство.*

$$z = \frac{\bar{\mathbf{x}} - a_0}{\sqrt{D\bar{\mathbf{x}}}} = \sqrt{n} \frac{\bar{\mathbf{x}} - a_0}{\sigma} \sim N(0, 1).$$

□

#### Разбиение

$$H_1 : E\xi \neq a_0 \quad \mathcal{A}_{\text{крит}} = \mathbb{R} \setminus (z_{\alpha/2}, z_{1-\alpha/2})$$

$$H_1 : E\xi > a_0 \quad \mathcal{A}_{\text{крит}} = (z_{1-\alpha}, \infty)$$

$$H_1 : E\xi < a_0 \quad \mathcal{A}_{\text{крит}} = (-\infty, z_{\alpha})$$

#### 4.3.2. $D\xi$ неизвестна

**Предложение.** Пусть  $D\xi$  неизвестна; тогда используется следующая статистика

$$t = \sqrt{n-1} \frac{\bar{\mathbf{x}} - a_0}{s} = \frac{\sqrt{n-1}(\bar{\mathbf{x}} - a_0)}{\sqrt{n-1}/\sqrt{n} \cdot \tilde{s}} = \sqrt{n} \frac{\bar{\mathbf{x}} - a_0}{\tilde{s}} \xrightarrow{n \rightarrow \infty} N(0, 1).$$

**Предложение.** При условии нормальности данных,

$$t \sim t(n-1).$$

*Доказательство.*

$$t = \frac{\sqrt{n-1}(\bar{\mathbf{x}} - a_0)}{s} = \frac{\sqrt{n-1} \left( \frac{\bar{\mathbf{x}} - a_0}{\sigma} \right)}{s/\sigma} = \frac{\left( \frac{\bar{\mathbf{x}} - a_0}{\sigma} \right)}{\sqrt{\frac{s^2/\sigma^2}{n-1}}} = \frac{\frac{\sqrt{n}(\bar{\mathbf{x}} - a_0)}{\sigma}}{\sqrt{\frac{ns^2/\sigma^2}{n-1}}} = \frac{\beta}{\sqrt{\eta/(n-1)}} \sim t(n-1),$$

поскольку

$$\beta = \frac{\sqrt{n}(\bar{\mathbf{x}} - a_0)}{\sigma} \sim N(0, 1), \quad \eta = \frac{ns^2}{\sigma^2} \sim \chi^2(n-1).$$

□

#### Разбиение

$$H_1 : E\xi \neq a_0 \quad \mathcal{A}_{\text{крит}} = \mathbb{R} \setminus (\text{qnt}_{t(n-1)}(\alpha/2), \text{qnt}_{t(n-1)}(1-\alpha/2))$$

$$H_1 : E\xi > a_0 \quad \mathcal{A}_{\text{крит}} = (\text{qnt}_{t(n-1)}(1-\alpha), \infty)$$

$$H_1 : E\xi < a_0 \quad \mathcal{A}_{\text{крит}} = (-\infty, \text{qnt}_{t(n-1)} \alpha)$$

*Замечание.* При нормальной аппроксимации  $\text{qnt}_{t(n-1)}$  заменить на  $N(0, 1)$ .

**z-критерий для пропорции в модели Бернулли** Пусть  $\xi \sim \text{Ber}(p)$ . Поскольку  $E\xi = p$ , можно воспользоваться только что введенной статистикой; учитывая  $D\xi = p(1-p)$ ,

$$T = \sqrt{n} \frac{\bar{x} - p_0}{\sqrt{p_0(1-p_0)}} \xrightarrow{d} N(0, 1).$$

Разбиение будет таким же, как и в случае известной дисперсии.

#### 4.4. Проверка гипотезы о значении дисперсии в нормальной модели (критерий $\chi^2$ )

Пусть  $\xi \sim N(a, \sigma^2)$ .  $H_0 : D\xi = \sigma^2 = \sigma_0^2$ . Соответствие оценки дисперсии гипотезе удобно выражать отношением  $s^2/\sigma_0^2$  (или  $s_a/\sigma_0^2$  если  $a$  известно) с «идеальным» значением 1. Домножив на  $n$ , получим статистику, распределение которой известно.

##### 4.4.1. $E\xi = a < \infty$

**Предложение.** Пусть  $E\xi = a < \infty$ ; При условии нормальности данных используется следующая статистика:

$$\chi^2 = n \frac{s_a^2}{\sigma_0^2} \sim \chi^2(n).$$

*Доказательство.*

$$\chi^2 = \frac{ns_a^2}{\sigma_0^2} = \frac{n \cdot 1/n \cdot \sum_{i=1}^n (x_i - a)^2}{\sigma_0^2} = \sum_{i=1}^n \left( \frac{x_i - a}{\sigma_0} \right)^2 \sim \chi^2(n).$$

□

#### Разбиение

$$H_1 : D\xi \neq \sigma_0^2 \quad \mathcal{A}_{\text{крит}} = \mathbb{R}_+ \setminus \left( \text{qnt}_{\chi^2(n)}(\alpha/2), \text{qnt}_{\chi^2(n)}(1 - \alpha/2) \right)$$

$$H_1 : E\xi > a \quad \mathcal{A}_{\text{крит}} = (\text{qnt}_{\chi^2(n)}(1 - \alpha), \infty)$$

$$H_1 : E\xi < a \quad \mathcal{A}_{\text{крит}} = (0, \text{qnt}_{\chi^2(n)} \alpha)$$

##### 4.4.2. $E\xi$ неизвестно

**Предложение.** Пусть  $E\xi$  неизвестно. При условии нормальности данных используется следующая статистика:

$$\chi^2 = n \frac{s^2}{\sigma_0^2} = (n-1) \frac{\tilde{s}^2}{\sigma_0^2} \sim \chi^2(n-1).$$

*Доказательство.* См. (3.4).

□

*Альтернативное доказательство.* По определению запишем

$$D\hat{\xi}_n = D(\hat{\xi}_n - a) = E \left( \hat{\xi}_n - a \right)^2 - (E \left( \hat{\xi}_n - a \right))^2.$$

Но

$$\begin{aligned} D\hat{\xi}_n &= E(\hat{\xi}_n - E\hat{\xi}_n)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s^2 \\ E(\hat{\xi}_n - a)^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - a)^2 = s_a^2 \\ (E(\hat{\xi}_n - a))^2 &= (\bar{x} - a)^2, \end{aligned}$$

откуда

$$s^2 = s_a^2 - (\bar{\mathbf{x}} - a)^2.$$

Домножив обе части на  $n/\sigma_0^2$ , получим

$$\frac{ns^2}{\sigma_0^2} = \frac{ns_a^2}{\sigma_0^2} - \frac{n(\bar{\mathbf{x}} - a)^2}{\sigma_0^2} = \underbrace{\frac{ns_a^2}{\sigma_0^2}}_{\sim \chi^2(n)} - \underbrace{\left( \frac{\sqrt{n}(\bar{\mathbf{x}} - a)}{\sigma_0} \right)^2}_{\sim \chi^2(1)} \Rightarrow \frac{ns^2}{\sigma_0^2} \sim \chi^2(n-1).$$

□

*Замечание.* Для строгого доказательства, нужно использовать независимость  $\bar{\mathbf{x}}^2$  и  $s^2$  (см. 3.4).

### Разбиение

$$H_1 : D\xi \neq \sigma_0^2 \quad \mathcal{A}_{\text{крит}} = \mathbb{R}_+ \setminus \left( \text{qnt}_{\chi^2(n-1)}(\alpha/2), \text{qnt}_{\chi^2(n-1)}(1 - \alpha/2) \right)$$

$$H_1 : E\xi > a \quad \mathcal{A}_{\text{крит}} = (\text{qnt}_{\chi^2(n-1)}(1 - \alpha), \infty)$$

$$H_1 : E\xi < a \quad \mathcal{A}_{\text{крит}} = (0, \text{qnt}_{\chi^2(n-1)} \alpha)$$

**Упражнение.**  $s^2 = 1.44$ ,  $\bar{\mathbf{x}} = 55$ ,  $n = 101$ . Проверить гипотезу  $\sigma_0^2 = 1.5$  в нормальной модели.

*Решение.* Воспользуемся статистикой

$$\chi^2 = \frac{ns^2}{\sigma_0^2} = 101 \cdot 0.96 = 96.96.$$

«Идеальные» значения близки к  $E\xi_{\chi^2(100)} = 100$ , так что определим критическую область на концах плотности:

$$p\text{-value}/2 = \text{cdf}_{\chi^2(100)}(96.96) = \text{pchisq}(96.96, 100) \approx 0.43 \Rightarrow p\text{-value} \approx 0.86.$$

*Замечание.* Можно посчитать и по таблицам для нормального распределения. Раз

$$\frac{\eta_m - E\eta_m}{\sqrt{D\eta_m}} \xrightarrow[m \rightarrow \infty]{d} N(0, 1),$$

то

$$\frac{96.96 - 100}{\sqrt{200}} \approx -0.215 \Rightarrow p\text{-value}/2 = \Phi(-0.215) \approx 0.415.$$

┘

## 4.5. Критерий $\chi^2$ согласия с видом распределения

По выборке возможно проверить гипотезу о виде распределения случайной величины, реализацией которой является выборка.

*Утверждение.* Для проверки гипотезы согласия с видом произвольного *дискретного* распределения используется асимптотический *критерий*  $\chi^2$  («*chi-squared test for goodness of fit*»).



#### 4.5.1. Распределение с известными параметрами

Пусть

$$H_0 : \mathcal{P} = \mathcal{P}_0, \text{ где } \mathcal{P}_0 : \begin{pmatrix} x_1^* & \dots & x_k^* \\ p_1 & \dots & p_k \end{pmatrix}.$$

Сгруппируем  $\mathbf{x}$ ; каждому  $x_i^*$  сопоставим *эмпирическую* абсолютную частоту  $\nu_i$ ; тогда  $np_i$  — *ожидаемая* абсолютная частота.

В качестве меры расхождения между эмпирическим и генеральным распределением рассматривается величина

$$\sum_{i=1}^k c_i \left( \frac{\nu_i}{n} - p_i \right)^2, \quad c_i = \frac{n}{p_i},$$

откуда записывается статистика критерия

$$T = \sum_{i=1}^k \frac{(\nu_i - np_i)^2}{np_i}$$

с идеальным значением 0.

*Утверждение.*  $T \xrightarrow{d} \chi^2(k-1)$ .

**Разбиение**  $\mathcal{A}_{\text{крит}} = (\text{qnt}_{\chi^2(k-1)}(1-\alpha), \infty)$  — гипотеза отвергается, если расстояние между предполагаемым и наблюдаемым распределениями большое.

**Упражнение.**  $n = 100$ ,

$$\begin{pmatrix} \diamond & \heartsuit & \clubsuit & \spadesuit \\ 20 & 30 & 10 & 40 \end{pmatrix}.$$

Проверить гипотезу, что колода полная.

*Решение.*  $H_0 : \mathcal{P}_\xi = \text{U}(1/4)$ . Поскольку речь идет о согласии с дискретным не параметризованным распределением, напрямую воспользуемся критерием  $\chi^2$ . Раз все  $np_i = 100 \cdot 1/4 = 25$ ,

$$\chi^2 = \sum_{i=1}^k \frac{(\nu_i - np_i)^2}{np_i} = 1 + 1 + \frac{15^2}{25} + \frac{15^2}{25} = 2 + 2 \cdot 9 = 20.$$

Так как  $\chi^2 \sim \chi^2(k-1) = \chi^2(3)$  со средним 3, и «идеальное» значение 0, определим критическую область в правом конце плотности. Из этих соображений

$$p\text{-value} = 1 - \text{cdf}_{\chi^2(3)}(20) = 1 - \text{pchisq}(20, 3) \approx 0.00017.$$

┘

#### 4.5.2. Распределение с неизвестными параметрами

В случае сложной гипотезы  $\mathcal{P} \in \{\mathcal{P}(\boldsymbol{\theta})\}_{\boldsymbol{\theta} \in \Theta}$ ,  $\boldsymbol{\theta} = (\theta_1, \dots, \theta_r)^T$ , следует найти оценку  $\hat{\boldsymbol{\theta}}_{\text{MLE}}$  (или  $\hat{\boldsymbol{\theta}} : \hat{\boldsymbol{\theta}} \rightarrow \hat{\boldsymbol{\theta}}_{\text{MLE}}$ ) по методу максимального правдоподобия. При подстановке оценок вместо истинных параметров критерий становится консервативным. Чтобы этого избежать, необходимо сделать поправку на количество параметров — отнять  $r$ . Что приятно, одна и та же поправка работает для всех распределений; в этом случае,

$$T \xrightarrow{d} \chi^2(k-r-1).$$

**Упражнение 1.** 60 человек купило подарок сразу, 10 со второго раза, 20 с третьего, 10 с четвертого:

$$\begin{pmatrix} 0 & 1 & 2 & 3 \\ 60 & 10 & 20 & 10 \end{pmatrix}.$$

Проверить гипотезу о том, что это выборка из геометрического распределения.

*Решение.*  $H_0 : \mathcal{P}_\xi = \text{Geom}(p)$ . Воспользуемся критерием  $\chi^2$  для параметризованного распределения  $\text{Geom}(\hat{p}_{\text{MLE}})$ .

Найдем

$$\hat{p}_{\text{MLE}} = \underset{p}{\operatorname{argmax}} \log \mathcal{L}(\mathbf{x}; p) \iff \frac{d}{dp} \log \mathcal{L}(\mathbf{x}; \hat{p}_{\text{MLE}}) = 0.$$

Так как  $\text{pdf}_{\text{Geom}(p)}(k) = (1-p)^k p$ ,

$$\begin{aligned} \log \mathcal{L}(\mathbf{x}; p) &= \log \prod_{k=1}^n (1-p)^k p = \log(1-p)^{n\bar{x}} p^n = n\bar{x} \log(1-p) + n \log p \\ &= n(\bar{x} \log(1-p) + \log p) \end{aligned}$$

откуда

$$\frac{d}{dp} \log \mathcal{L}(\mathbf{x}; p) = n \left( -\frac{\bar{x}}{1-p} + \frac{1}{p} \right) = 0 \iff 1-p-p\bar{x} = 0 \iff p = \frac{1}{1+\bar{x}}.$$

Учитывая

$$\bar{x} = 0.1 + 2 \cdot 0.2 + 3 \cdot 0.1 = 0.8,$$

найдем

$$\hat{p}_{\text{MLE}} = \frac{1}{1+0.8} \approx 0.55.$$

Посчитаем статистику  $\chi^2$ , найдя соответствующие  $p_i$ :

$$p_0 = \text{P}_{\text{Geom}(0.55)}(0) = 0.55, \quad p_1 \approx 0.26, \quad p_2 \approx 0.11, \quad p_3 \approx 0.09.$$

Тогда

$$\chi^2 = \sum_{i=1}^k \frac{(\nu_i - np_i)^2}{np_i} = \frac{25}{55} + \frac{16^2}{26} + \frac{81}{11} + \frac{1}{9} \approx 17.77.$$

Наконец, поскольку  $\chi^2 \xrightarrow{n \rightarrow \infty} \chi^2(k-r-1)$ ,

$$p\text{-value} = 1 - \text{cdf}_{\chi^2(2)}(17.77) \approx 0.00014.$$

┘

**Определение.** Критерий *применим*, если  $\alpha \rightarrow \alpha_I$ .

*Замечание.* Поскольку критерий асимптотический, с достаточной степенью точностью он применим в случае, если

1.  $n \geq 50$ ;
2.  $np_i \geq 5$ .

*Замечание.* Если условие  $np_i \geq 5$  не выполняется, следует объединить состояния, например, с краев или слева направо; если в хвосте оказалось  $< 5$ , то следует присоединить к последнему.

**Пример** (С монеткой). Пусть  $n = 4040$ ,  $\#H = 2048$ ,  $\#T = 1092$ . Проверим  $H_0 : \mathcal{P} = \text{Ber}(0.5)$  с  $\alpha = 0.1$ . Условия критерия выполняются, поэтому посчитаем

$$T = \frac{(2048 - 2020)^2}{2020} + \frac{(1092 - 2020)^2}{2020} = \frac{28^2 + 28^2}{2020} \approx 0.78 \sim \chi^2(1),$$

откуда

$$p\text{-value} = 1 - \text{cdf}_{\chi^2(1)}(0.78) \approx 0.38.$$

$0.38 > 0.1$ , значит  $H_0$  не отвергается.

*Замечание.* Прохождение критерия не достаточно. Так, альтернирующая (и явно не случайная) последовательность  $\mathbf{x} = (0, 1, 0, 1, \dots)$  имеет  $T = 0$ .

### 4.5.3. Согласие с нормальным распределением

Для проверки гипотезы  $H_0 : \mathcal{P}_\xi = N(a, \sigma^2)$  также можно воспользоваться статистикой критерия  $\chi^2$  для сложной гипотезы. В этом случае, нужно дискретизировать нормальное распределение, так, что

$$\mathcal{P}_0 = \begin{pmatrix} x_1^* & \cdots & x_k^* \\ p_1(\hat{\theta}) & \cdots & p_k(\hat{\theta}) \end{pmatrix}, \quad \hat{\theta} = \hat{\theta}_{\text{MLE}}.$$

Тем не менее, нужно иметь в виду две теоретических неточности:

1. Построение  $\mathcal{P}_0$  происходит случайно, в результате объединения элементов выборки после того, как она получена.
2. Оценка параметров  $\hat{\theta}_{\text{MLE}}$  должна быть посчитана для  $\mathcal{P}_0$ , а не для исходного (нормального) распределения — не  $\bar{x}, s^2$ . Однако на практике на этот момент не обращают внимания.

Существует два возможных способа дискретизации:

1. Гистограмма: одинаковые интервалы, но разные вероятности.
2. Неравные интервалы с равными вероятностями.

```
N <- length(xs)
xs <- sort(xs)
probs <- pnorm(xs, mean=mean(xs), sd=sd(xs))
i <- 1; j <- i+1
while (N * (probs[j] - probs[i]) < 5) {
  j <- j+1
}
mean(xs[i:j]) # our  $x_1^*$ ;  $n_1 = j - i + 1$ 
```

Этот способ разбиения предпочтителен, потому что:

- Можно разбить максимально часто — так, чтобы  $np_i = 5 \forall i$ , следовательно и мощность будет максимальна.
- Он оказывается точнее первого на практике.
- Получается единственное  $p$ -value.

*Замечание.* Следует иметь в виду, что этот способ не годится для непрерывных, но плохо дискретизированных данных.

## 4.6. Критерий Колмогорова-Смирнова согласия с видом распределения

### 4.6.1. Произвольное абсолютно непрерывное распределение

$H_0 : \xi \sim \mathcal{P} = \mathcal{P}_0$ .

*Утверждение.* Для проверки гипотезы согласия с видом произвольного абсолютно непрерывного распределения с известными параметрами используется асимптотический критерий Колмогорова-Смирнова со следующей статистикой:

$$D_n = \sup_{x \in \mathbf{x}} \left| \widehat{\text{cdf}}_n(x) - \text{cdf}_0(x) \right|,$$

где  $\text{cdf}_0$  — функция распределения  $\mathcal{P}_0$  нулевой гипотезы.

Альтернатива только одна:  $H_1 : \xi \not\sim \mathcal{P}_0$ ;  $\mathcal{A}_{\text{крит}} = (\text{qnt}_{\text{K-S}}(1 - \alpha), \infty)$ .

*Замечание.* Критерий является не асимптотическим, но *точным*. Значит им пользоваться и при маленьких объемах выборки (мощность, при этом, останется низкой все-равно).

*Замечание.*  $\sup_x \sqrt{n} |\widehat{\text{cdf}}_n(x) - \text{cdf}_0(x)| \xrightarrow{d} \mathcal{P}_{\text{K.S.}}$ , где  $\mathcal{P}_{\text{K.S.}}$  — распределение Колмогорова. Значит, при больших объемах выборки для такой статистики критерия можно пользоваться таблицами распределения Колмогорова.

**Упражнение.** Проверить гипотезу, что  $\mathbf{x} = (0.1, 0.2, 0.4, 0.3, 0.1)$  есть выборка из  $U[0, 1]$ .

*Решение.*  $D_n = 0.6$ ,  $p\text{-value} \approx 0.05$  (по таблицам или компьютером). Таким образом, при  $\alpha > 0.05$  гипотеза отвергается, при  $\alpha < 0.05$  — нет.

```
> ks.test(c(0.1,0.2,0.4,0.3,0.1), 'punif')
      One-sample Kolmogorov-Smirnov test
data:  c(0.1, 0.2, 0.4, 0.3, 0.1)
D = 0.6, p-value = 0.05465
```

┘

*Замечание.* Критерий Колмогорова-Смирнова консервативный — значение  $p\text{-value}$  завышено. Поэтому если гипотеза отвергается, то наверняка.

#### 4.6.2. Нормальное распределение

Пусть  $H_0 : \mathcal{P}_\xi \in \{N(a, \sigma^2)\}$ . Как известно, критерий Колмогорова-Смирнова используется для непрерывных непараметрических распределений. Им можно воспользоваться и для данной  $H_0$ , если вместо  $a, \sigma^2$  подставить соответствующие оценки — в таком случае критерий будет консервативным. По аналогии с  $\chi^2$  хотелось бы сделать поправку на количество параметров — такая поправка осуществляется путем моделирования распределения тестовой статистики. Для  $N(a, \sigma^2)$  и  $\text{Exp}(\lambda)$  получаем распределение  $D_n$ , не зависящее от параметров (так что поправку можно делать вне зависимости от параметров; к примеру,  $N(a, \sigma^2)$  можно привести к  $N(0, 1)$  непрерывным преобразованием):

**Критерий Бартлетта** есть критерий Колмогорова-Смирнова для  $H_0 : \mathcal{P}_\xi = \text{Exp}(\lambda)$ .

**Критерий Лиллиефорса**<sup>8</sup> для проверки  $H_0 : \mathcal{P}_\xi = N(a, \sigma^2)$  считается статистикой  $D_n$  с  $\text{cdf}_0(x) = \text{cdf}_{N(\bar{x}, s^2)}(x)$ , сходящейся к распределению Лиллиефорса (Колмогорова-Смирнова с учетом подстановки оценок).

**Критерий Шапиро-Уилка**  $T \approx \rho^2$ , т.е. ведет себя примерно как квадрат коэффициента корреляции на normal probability plot.

*Замечание.* Распределения Лиллиефорса и Колмогорова-Смирнова были получены путем моделирования.

**Пример.** В R:

```
> require('nortest')
> lillie.test(rt(1000, df=10))
      Lilliefors (Kolmogorov-Smirnov) normality test
data:  rt(1000, df = 10)
D = 0.03042, p-value = 0.02953
```

#### 4.7. Критерий типа $\omega^2$

**Определение.** Статистика

$$Q = n \int_{\mathbb{R}} (\text{cdf}_n(x) - \text{cdf}_0(x))^2 w(x) d\text{cdf}_0(x),$$

где  $w(x)$  — весовая функция.

*Замечание.* Статистика может быть проинтерпретирована как площадь разницы между соответствующими функциями распределения.

**Cramer von Mises**  $Q$  с  $w \equiv 1$ .

**Anderson-Darling**  $Q$  с

$$w(x) = \frac{1}{\text{cdf}_0(x)(1 - \text{cdf}_0(x))}.$$

*Замечание.* Весовая функция критерия Anderson-Darling присваивает большой вес значениям на хвостах распределения, поэтому сам критерий является мощным против разницы на хвостах, но и менее мощным при сдвиге.

*Замечание.* Все эти критерии точны.

*Замечание.* Распределение статистики в каждом случае не зависит от  $\text{cdf}_0$  и все эти критерии состоятельные против любой альтернативы, поэтому не очень мощные.

## 4.8. Визуальное определение согласия с распределением

### 4.8.1. P-P plot

**Определение.** *P-P plot* есть график

$$\left\{ \left( \text{cdf}_0(x_i) + \frac{1}{2n}, \widehat{\text{cdf}}_n(x_i) \right) \right\}_{i=1}^n.$$

**Пример.** В R:

```
pp.plot <- function(xs, cdf.0=pnorm, n.knots=1000) {
  knots <- seq(min(xs), max(xs), length.out=n.knots)
  plot(cdf.0(knots), ecdf(xs)(knots))
  abline(0, 1)
}
```

### 4.8.2. Q-Q plot

**Определение.** *Q-Q plot* есть график

$$\left\{ \left( x_i, \text{cdf}_0^{-1} \left( \widehat{\text{cdf}}_n(x_i) + \frac{1}{2n} \right) \right) \right\}_{i=1}^n.$$

**Определение.** Частный случай Q-Q plot для  $\text{cdf}_0^{-1} = \text{cdf}_{N(0,1)}^{-1}$  называется *normal probability plot*.

**Пример.** В R:

```
qq.plot <- function(xs, qf.0=qnorm, n.ppoints=1000) {
  qs <- ppoints(n.ppoints)
  plot(qf.0(qs), unname(quantile(xs, probs=qs)))
  abline(mean(xs), sd(xs))
}
```

*Замечание.* Если  $\hat{P}_n \rightarrow \mathcal{P}_\xi$ , то оба графика будут стремиться к  $y = x$ . Референсной прямой normal probability plot будет  $y = \widehat{D}\xi \cdot x + \widehat{E}\xi$ .

*Замечание.* Больше о различии Q-Q и P-P plots, см. <http://v8doc.sas.com/sashtml/qc/chap8/sect9.htm>

*Замечание.* Различные интерпретации параметров распределения по Q-Q plot можно посмотреть в интерактивном приложении: <https://xiongge.shinyapps.io/QQplots/>

## 4.9. Гипотеза о равенстве распределений

$$H_0 : \mathcal{P}_{\xi_1} = \mathcal{P}_{\xi_2}.$$

Возможно рассматривать два случая:

**Независимые выборки** Две группы индивидов, на которых измеряется один и тот же признак. Формально: пусть  $\zeta \in \{1, 2\}$  — номер группы,  $\xi$  — признак. Тогда  $\xi_1 \sim \mathcal{P}_{\xi|\zeta=1}$ ,  $\xi_2 \sim \mathcal{P}_{\xi|\zeta=2}$  и  $\xi_1 \perp\!\!\!\perp \xi_2$ . В этом случае выборка имеет вид

$$((x_1, x_2, \dots, x_{n_1}), (y_1, y_2, \dots, y_{n_2})).$$

**Зависимые выборки** Одна группа индивидов, на каждом из которых измеряются две характеристики (либо же «до» и «после»). В этом случае выборка имеет вид

$$((x_1, y_1), \dots, (x_n, y_n)).$$

*Замечание.* Для одной и той же гипотезы могут существовать разные критерии; их возможно сравнить по мощности, но только если они состоятельны против одной и той же альтернативы.

*Замечание.* Непараметрические критерии хороши тем, что основаны на рангах, значит устойчивы к аутлаерам; плохи тем, что не используют всю информацию о значении — только порядок, из-за чего обладают меньшей мощностью.

## 4.10. Равенство математических ожиданий для независимых выборок

### 4.10.1. Двухвыборочный $t$ -критерий

$$H_0 : E\xi_1 = E\xi_2.$$

**Определение.** И для зависимых, и для независимых выборок используется *двухвыборочный  $t$ -критерий*

$$t = \frac{\bar{x} - \bar{y}}{\sqrt{D(\bar{x} - \bar{y})}} \xrightarrow{\sim} N(0, 1).$$

Пусть выборка *независима*<sup>9</sup>,  $(x_1, \dots, x_{n_1}), (y_1, \dots, y_{n_2})$ ,  $n = n_1 + n_2$ . Значит  $D(\bar{x} - \bar{y}) = D\bar{x} + D\bar{y}$ .

**Двухвыборочный  $t$ -критерий для независимых выборок с  $\sigma_1^2 \neq \sigma_2^2$  (Welch  $t$ -test)**

**Предложение.** Если дисперсия известна,  $D(\bar{x} - \bar{y}) = D\bar{x} + D\bar{y} = \sigma_1^2/n_1 + \sigma_2^2/n_2$  и

$$t = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \xrightarrow{n_1, n_2 \rightarrow \infty} N(0, 1).$$

Если данные нормальные, то

$$t \sim N(0, 1).$$

**Предложение.** Если дисперсия неизвестна,  $D(\widehat{\bar{x} - \bar{y}}) = s_1^2/n_1 + s_2^2/n_2$ , откуда

$$t = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \xrightarrow{n_1, n_2 \rightarrow \infty} N(0, 1).$$

*Замечание.* Точное распределение неизвестно, примерно равно  $t$  с дробным числом степеней свободы (что вычисляется интерполяцией по соседним степеням). Всегда ожидается, что если данные нормальны, то распределение известно. Это противоречие носит название *проблемы Беренса-Фишера*<sup>10</sup>.

<sup>9</sup>Случай зависимой выборки рассматривается в другом параграфе.

<sup>10</sup>Behrens-Fisher problem.

### Разбиение

$$H_1 : E\xi_1 \neq E\xi_2 \quad \mathcal{A}_{\text{крит}} = \mathbb{R} \setminus (z_{\alpha/2}, z_{1-\alpha/2})$$

$$H_1 : E\xi_1 > E\xi_2 \quad \mathcal{A}_{\text{крит}} = (z_{1-\alpha}, \infty)$$

$$H_1 : E\xi_1 < E\xi_2 \quad \mathcal{A}_{\text{крит}} = (-\infty, z_{\alpha})$$

### Двухвыборочный $t$ -критерий для независимых выборок с $\sigma_1^2 = \sigma_2^2$ (pooled $t$ -test)

**Предложение.** Если дисперсия известна,

$$D(\bar{x} - \bar{y}) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} = \sigma^2 \left( \frac{1}{n_1} + \frac{1}{n_2} \right),$$

откуда

$$t = \frac{\bar{x} - \bar{y}}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \xrightarrow{n_1, n_2 \rightarrow \infty} N(0, 1).$$

Если данные нормальные, то

$$t \sim N(0, 1).$$

**Предложение.** Если дисперсия неизвестна,

$$t = \frac{\bar{x} - \bar{y}}{\tilde{s}_{1,2} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \xrightarrow{n_1, n_2 \rightarrow \infty} N(0, 1).$$

Если данные нормальные, то

$$t \sim t(n_1 + n_2 - 2).$$

**Доказательство.** Оценку дисперсии можно найти по объединенной и центрированной выборке (т.е. если  $H_0$  верна, то  $E\xi_1 = E\xi_2$  и можно думать как про одну выборку):

$$\begin{aligned} s_{1,2}^2 &= \frac{\overbrace{\sum_{i=1}^n (x_i - \bar{x})^2}^{\sim \chi^2(n_1-1)} + \overbrace{\sum_{i=1}^n (y_i - \bar{y})^2}^{\sim \chi^2(n_2-1)}}{n_1 + n_2} = \frac{n_1 \cdot s_1^2}{n_1 + n_2} + \frac{n_2 \cdot s_2^2}{n_1 + n_2} \\ \tilde{s}_{1,2}^2 &= \frac{\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (y_i - \bar{y})^2}{n_1 + n_2 - 2} = \frac{(n_1 - 1)\tilde{s}_1^2}{n_1 + n_2 - 2} + \frac{(n_2 - 1)\tilde{s}_2^2}{n_1 + n_2 - 2}, \end{aligned}$$

где в последнем случае оценка несмещенная и  $E\tilde{s}_{1,2}^2 = \sigma^2$ . □

**Замечание.** Этот вариант более точен, чем в случае  $\sigma_1 \neq \sigma_2$ .

### Разбиение

$$H_1 : E\xi_1 \neq E\xi_2 \quad \mathcal{A}_{\text{крит}} = \mathbb{R} \setminus \left( \text{qnt}_{t(n_1+n_2-2)}(\alpha/2), \text{qnt}_{t(n_1+n_2-2)}(1 - \alpha/2) \right)$$

$$H_1 : E\xi_1 > E\xi_2 \quad \mathcal{A}_{\text{крит}} = (\text{qnt}_{t(n_1+n_2-2)}(1 - \alpha), \infty)$$

$$H_1 : E\xi_1 < E\xi_2 \quad \mathcal{A}_{\text{крит}} = (-\infty, \text{qnt}_{t(n_1+n_2-2)} \alpha)$$

**Испытания Бернулли** Пусть  $\xi_i \sim \text{Ber}(p_i)$ ,  $i \in \{1, 2\}$ . Рассмотрим  $H_0 : p_1 = p_2$  против  $H_1 : p_1 \neq p_2$ . Поскольку  $E\xi_i = p_i$ , применим двух-выборочный  $t$ -критерий. Объединим выборки и запишем:

$$D(\bar{x} - \bar{y}) = \frac{\hat{p}(1 - \hat{p})}{n_1 + n_2} \implies t = \sqrt{\frac{n_1 n_2}{n_1 + n_2}} \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p})}} \xrightarrow{n_1, n_2 \rightarrow \infty} N(0, 1), \quad \hat{p} = \frac{n_1 \hat{p}_1 + n_2 \hat{p}_2}{n_1 + n_2}.$$

**Разбиение** Аналогично с  $\text{qnt}_{N(0,1)}$ .

**Определение.** Выборка обладает *сбалансированным дизайном*, если  $n_1 = n_2$ .

Если дизайн сбалансирован, то

$$s^2 \left( \frac{1}{n_1} + \frac{1}{n_2} \right) = \frac{s_1^2}{n_1} + \frac{s_2^2}{n_2},$$

т.е. даже если дисперсии разные, результат одинаковый. Это остается справедливым даже при  $n_1 \approx n_2$ .

#### 4.10.2. Непараметрический $t$ -критерий

Можно использовать обычный  $t$ -критерий, но примененный к рангам.

Пусть, как и прежде, дана выборка  $(\mathbf{x}, \mathbf{y})$ . Следующие два критерия — Wilcoxon и Mann-Whitney — проверяют гипотезу  $H_0 : P(\xi_1 > \xi_2) = P(\xi_1 < \xi_2)$  или, альтернативно, что выборки получены из одной генеральной совокупности.

#### 4.10.3. Критерии суммы рангов Wilcoxon

Следует сопоставить каждой выборке соответствующие её элементам ранги в *объединенной выборке*:

$$\begin{aligned}(x_1, \dots, x_{n_1}) &\mapsto (R_1, \dots, R_{n_1}) \\ (y_1, \dots, y_{n_2}) &\mapsto (T_1, \dots, T_{n_2}).\end{aligned}$$

Ясно, что если в целом элементы одной выборки окажутся больше другой, то нельзя будет говорить об их однородности. Определим

$$W_1 := \sum_{i=1}^{n_1} R_i, \quad W_2 := \sum_{i=1}^{n_2} T_i.$$

В качестве статистики можно было бы использовать либо  $W_1$ , либо  $W_2$ , однако, ни той, ни другой статистике невозможно априорно отдать предпочтение. Поэтому используется статистика

$$W := \max(W_1, W_2),$$

не имеющая аналитического выражения (но для которого посчитаны соответствующие таблицы).

Иногда в качестве статистики берут количество инверсий в объединенной выборке.

#### 4.10.4. Критерий Mann-Whitney ( $U$ test)

Используется статистика

$$U := \max \left( n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - W_1, n_1 n_2 + \frac{n_2(n_2 + 1)}{2} - W_2 \right).$$

*Замечание.*  $EU - n_1 n_2 / 2 \xrightarrow{n_1, n_2 \rightarrow \infty} 0$ . Асимптотически,

$$\frac{U - EU}{\sqrt{DU}} \xrightarrow{n_1, n_2 \rightarrow \infty} N(0, 1),$$

но для малых объемов выборки можно посчитать и точные распределения.



*Замечание.* Критерий состоятельный против альтернативы

$$H_1 : P(\xi_1 > \xi_2) \neq P(\xi_1 < \xi_2).$$

Если формы распределений одинаковы, то эта альтернатива обозначает сдвиг. Для симметричных распределений это условие обозначает равенство медиан (а для нормального — математических ожиданий). Поэтому критерий устойчив к аутлаерам, хоть и за счет небольшой ( $\approx 5\%$ ) потери мощности.

*Замечание.* Критерии Манна-Уитни и Вилкоксона *эквивалентны* — в том смысле, что выделяют один и тот же  $p$ -value. Тем не менее, проверяют они разные гипотезы ( $E\xi$  не то же, что  $\text{med } \xi$ ).

#### 4.10.5. Критерий серий (runs)

Следует объединить выборку и в качестве статистики выбрать количество серий, т.е. подряд идущих элементов из одной выборки. Эта статистика имеет специально подобранное распределение.

#### 4.10.6. Критерий равенства распределений

Рассматривается  $H_0 : \mathcal{P}_{\xi_1} = \mathcal{P}_{\xi_2}$  против  $H_1 : \mathcal{P}_{\xi_1} \neq \mathcal{P}_{\xi_2}$ . Этот критерий мощный против неравенства распределений (а не отличия математического ожидания). В качестве статистики используется

$$D = \sup_x \left| \widehat{\text{cdf}}_{\xi_1}(x) - \widehat{\text{cdf}}_{\xi_2}(x) \right|.$$

*Замечание.* Все эти критерии подразумевают отсутствие повторяющихся наблюдений для избежания появления дробных рангов.

### 4.11. Равенство математических ожиданий для парных (зависимых) выборок

Выборка представлена набором пар  $\{(x_i, y_i)\}_{i=1}^n$ .

#### 4.11.1. $t$ -критерий

Пусть  $\xi_1, \xi_2$  заданы на одном  $(\Omega, \mathcal{F}, P)$ . Тогда гипотезу  $H_0 : E\xi_1 = E\xi_2$  можно свести к  $H_0 : E(\xi_1 - \xi_2) = E\eta = 0$  использовать не-парный  $t$ -тест.

*Замечание* (Мощность и зависимость). Сравним статистику для сбалансированного дизайна:

- Независимая выборка

$$t_{\text{indep}} = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{\sqrt{n}(\bar{x} - \bar{y})}{\sqrt{\sigma_1^2 + \sigma_2^2}}.$$

- Зависимая выборка:

$$\begin{aligned} D(\bar{x} - \bar{y}) &= D\bar{x} + D\bar{y} - 2 \text{cov}(\bar{x}, \bar{y}) = \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{n} - 2\rho\sqrt{D\bar{x}}\sqrt{D\bar{y}} \\ &= \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{n} - 2\rho\frac{\sigma_1}{\sqrt{n}}\frac{\sigma_2}{\sqrt{n}} = \frac{1}{n}(\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2), \end{aligned}$$

откуда

$$t_{\text{dep}} = \frac{\sqrt{n}(\bar{x} - \bar{y})}{\sqrt{\sigma_1^2 + \sigma_2^2 - 2\sigma_1\sigma_2\rho}}.$$

При  $\rho > 0$ ,  $t_{\text{dep}} > t_{\text{indep}}$ . Значит, статистика чаще попадает в критическую область и критерий лучше находит различия (и мощность, следовательно, выше). Значит, тот же эксперимент на зависимых выборках мощнее.

**Пример.** Проверяют гипотезу, что белый свет лам влияет на решение задач.

- При тестировании на разных индивидах, должна быть уверенность, что они одинаковы по критичным параметрам (IQ, например).
- При тестировании на одинаковых индивидах следует составлять разные, но одинаковы по сложности задачи (второй раз одну и ту же задачу решать не займет много времени!). Мощность этого эксперимента будет выше.

#### 4.11.2. Непараметрический тест знаков (Sign test)

$H_0 : P(\xi_1 < \xi_2) = P(\xi_1 > \xi_2)$ . Используется статистика

$$W = \sum_{i=1}^n \psi_i, \quad \psi_i = \begin{cases} 1 & x_i > y_i \\ 0 & x_i < y_i. \end{cases}$$

Если при подсчете статистики  $x_i = y_i$ , эта пара игнорируется вместе с соответствующим уменьшением объема выборки.

Пусть после удаления всех пар, таких, что  $x_i = y_i$ , объем выборки стал равен  $m$ . Тогда  $W \sim \text{Bin}(m, 0.5)$  и для построения разбиения можно пользоваться  $\text{qnt}_{\text{Bin}(m, 0.5)}$ .

*Замечание.* Критерий применим к порядковым признакам.

*Замечание.* Критерий очень устойчив к аутлаерам (но и очень низкомощен поэтому).

#### 4.11.3. Непараметрический критерий (Paired Wilcoxon; Wilcoxon signed-rank test)

Увеличить мощность предыдущего критерия можно, учтя больше информации:

$$W := \sum_{i=1}^n R_i \psi_i, \quad R_i := \text{rk} |x_i - y_i|.$$

Для симметрии можно рассмотреть статистику

$$W = \sum_{i=1}^n R_i \text{sign}(x_i - y_i)$$

с идеальным значением 0. При верной  $H_0$ , распределение  $W$  не имеет простого аналитического выражения (но может быть посчитана по таблицам), при этом  $EW = 0$ ,  $DW = n(n+1)(2n+1)/6$ . Кроме того,  $W \xrightarrow{d} N(0, DW)$ , так что уже при  $n \geq 10$  можно полагать, что  $z = W/\sqrt{DW} \xrightarrow{d} N(0, 1)$  и строить разбиение соответственно.

*Замечание.* Критерий уже не применим к порядковым признакам.

### 4.12. Равенство дисперсии для двух распределений

$H_0 : D\xi_1 = D\xi_2$ ,  $\xi_1 \perp\!\!\!\perp \xi_2$ ,  $\xi_i \sim N(a, \sigma_i)^2$ .

#### 4.12.1. Критерий Фишера

$H_0 : \sigma_1^2 = \sigma_2^2$ . Естественно использовать отношение  $s_1^2/s_2^2$  с идеальным значением 1. Поделив на число степеней свободы, получим статистику

$$F := \frac{\tilde{s}_1^2}{\tilde{s}_2^2} \sim F(|\mathbf{x}| - 1, |\mathbf{y}| - 1).$$

*Замечание.* При отклонении от нормальности не становится асимптотическим.

#### 4.12.2. Критерий Левена (Levene's test)

Так как  $D\xi_i = E(\xi_i - E\xi_i)^2$ , то критерий о равенстве дисперсий можно было бы свести к критерию о равенстве математических ожиданий; в этом случае применили бы  $t$ -критерий (подразумевающий разные дисперсии) к выборкам  $\{(x_i - \bar{x})^2\}$  и  $\{(y_i - \bar{y})^2\}$ . Однако при возведении в квадрат распределение стало бы несимметричным и потребовался бы больший объем выборки. Кроме того, значительно бы усилились аутлаеры.

Вместо этого используют гипотезу  $H_0 : E|\xi_1 - E\xi_1| = E|\xi_2 - E\xi_2|$  вместе с  $t$ -критерием, подразумевающим равенство дисперсий (для нормальных данных; иначе с разными).

#### 4.12.3. Критерий Brown-Forsythe

Критерий Brown-Forsythe — это  $t$ -критерий для гипотезы  $H_0 : E|\xi_1 - \text{med } \xi_1| = E|\xi_2 - \text{med } \xi_2|$ .

*Замечание.* Устойчив к аутлаерам из-за использования  $\text{med } \xi_i$ .

### 5. Доверительное оценивание

#### 5.1. Мотивация и определение

Для построенных оценок может понадобиться оценка точности. Так, даже состоятельная оценка может не быть в полном смысле «точной»: пусть  $\theta_n^* \xrightarrow{P} \theta_0$ ; тогда

$$\hat{\theta}'_n = \begin{cases} c & n < N \gg 1 \\ \hat{\theta}_n & \text{иначе} \end{cases}$$

все-равно будет, конечно, состоятельной.

$D\hat{\theta}_n$  может быть не всегда просто вычислить и использовать.

**Определение.**  $[c_1, c_2]$  — доверительный интервал для параметра  $\theta_0$  с уровнем доверия  $\gamma \in [0, 1]$ , если  $\forall \theta_0$

$$P(\theta_0 \in [c_1, c_2]) = \gamma, \quad \text{где } c_1 = c_1(\mathbf{x}), c_2 = c_2(\mathbf{x}) \text{ — статистики.}$$

*Замечание.* Если выборка из дискретного распределения, то  $c_1, c_2$  — тоже. Поэтому наперед заданную точность получить может не получиться; в таких случаях знак « $=$ » заменяют « $\geq$ ». Аналогично с заменой на « $\xrightarrow[n \rightarrow \infty]{} \geq$ ».

#### 5.2. Доверительные интервалы для математического ожидания и дисперсии в нормальной модели

**Предположение.** Пусть  $\xi \sim N(a, \sigma^2)$ .

##### 5.2.1. Доверительный интервал для $a$

- Пусть  $\sigma^2$  известно. Свяжем  $a_0$  с выборкой:

$$\gamma = P(c_1 < T < c_2) = P\left(c_1 < \sqrt{n} \frac{(\bar{x} - a_0)}{\sigma} < c_2\right) = P\left(a_0 \in \left(\bar{x} - \frac{\sigma c_2}{\sqrt{n}}, \bar{x} - \frac{\sigma c_1}{\sqrt{n}}\right)\right).$$

Решений уравнения  $P(c_1 < \sqrt{n}(\bar{x} - a_0)/\sigma < c_2) = \Phi(c_2) - \Phi(c_1) = \gamma$  бесконечно много. Чем  $[c_1, c_2]$  короче, тем лучше. Поскольку  $\Phi$  симметрична и унимодальна,

$$\begin{aligned} c_1 &= -c_\gamma \\ c_2 &= c_\gamma, \end{aligned} \quad \text{где } c_\gamma = \text{cdf}_{N(0,1)}^{-1}\left(\gamma + \frac{1-\gamma}{2}\right) = x_{\frac{1+\gamma}{2}}.$$

Наконец,

$$P\left(a_0 \in \left(\bar{x} \pm \frac{\sigma}{\sqrt{n}} x_{\frac{1+\gamma}{2}}\right)\right) = \gamma.$$

- Пусть  $\sigma^2$  неизвестно. По аналогии,

$$\gamma = P\left(c_1 < \frac{\sqrt{n-1}(\bar{x} - a_0)}{s} < c_2\right) = P\left(a_0 \in \left(\bar{x} \pm \frac{c_\gamma s}{\sqrt{n-1}}\right)\right), \quad c_\gamma = \text{cdf}_{t(n-1)}^{-1}\left(\frac{1+\gamma}{2}\right)$$

и

$$P\left(a_0 \in \left(\bar{x} \pm \frac{\tilde{s}}{\sqrt{n}} x_{\frac{1+\gamma}{2}}\right)\right) = \gamma.$$

**Упражнение.** Пусть  $s^2 = 1.21$ ,  $\bar{x} = 1.9$ ,  $n = 36$ . Построить 95% доверительный интервал для  $E\xi$ .

*Решение.*

$$c_\gamma = \text{qt}(0.975, 35) \approx 2.03 \implies \left(1.9 \pm \frac{2.03 \cdot \sqrt{1.21}}{\sqrt{35}}\right) = (1.52; 2.28).$$

┘

### 5.2.2. Доверительный интервал для $\sigma^2$

- Пусть  $a$  известно. Поскольку плотность  $\chi^2$  становится все более симметричной с ростом  $n$ , примем

$$c_1 = \text{cdf}_{\chi^2(n)}^{-1}\left(\frac{1-\gamma}{2}\right), \quad c_2 = \text{cdf}_{\chi^2(n)}^{-1}\left(\frac{1+\gamma}{2}\right).$$

Тогда

$$P\left(c_1 < \frac{ns_a^2}{\sigma_0^2} < c_2\right) = \gamma \iff P\left(\sigma_0^2 \in \left(\frac{ns_a^2}{x_{(1+\gamma)/2}}, \frac{ns_a^2}{x_{(1-\gamma)/2}}\right)\right) = \gamma.$$

- Пусть  $a$  неизвестно. Тогда аналогично

$$P\left(\sigma_0^2 \in \left(\frac{ns^2}{x_{(1+\gamma)/2}}, \frac{ns^2}{x_{(1-\gamma)/2}}\right)\right) = \gamma,$$

где  $x_{(1\pm\gamma)/2} = \text{cdf}_{\chi^2(n-1)}^{-1}((1 \pm \gamma)/2)$ .

**Определение.** Случайная величина  $g(x_1, \dots, x_n, \theta)$  называется *центральной статистикой параметра  $\theta$* , если

1. Её распределение («центральное распределение») не зависит от распределения  $\theta$ .
2.  $G_n$  (функция распределения центрального распределения) непрерывна.
3.  $\forall z_1, z_2$  и  $\mathcal{P}_\theta$ -почти всюду

$$z_1 < g(x_1, \dots, x_n, \theta) < z_2$$

монотонно разрешимо относительно  $\theta$ , т.е.

$$\exists f_1, f_n : f_1(x_1, \dots, x_n, \theta, z_1, z_2) < \theta < f_2(x_1, \dots, x_n, \theta, z_1, z_2).$$

Рассмотрим всегда разрешимое

$$\begin{aligned} \gamma &= G_n(z_2) - G_n(z_1) = P(z_1 < g(x_1, \dots, x_n, \theta) < z_2) \\ &= P(\underbrace{f_1(z_1, z_2, x_1, \dots, x_n)}_{c_1} < \theta < \underbrace{f_2(z_1, z_2, x_1, \dots, x_n)}_{c_2}). \end{aligned}$$

### 5.3. Асимптотический доверительный интервал для математического ожидания в модели с конечной дисперсией

Если модель неизвестна, но известно, что  $D\xi < \infty$ , можно построить доверительный интервал для  $E\xi = a$ . Пусть  $\{x_i\}$  i.i.d., тогда

$$t = \frac{\sqrt{n}(\bar{x} - a)}{\sigma} \xrightarrow[n \rightarrow \infty]{} N(0, 1).$$

Если положить  $\sigma := s$ , то сходимость не испортится, потому что  $s^2$  — состоятельная оценка  $\sigma^2$ . Тогда

$$P\left(E\xi \in \left(\bar{x} \pm \frac{sc_\gamma}{\sqrt{n}}\right)\right) \xrightarrow[n \rightarrow \infty]{} \gamma, \quad c_\gamma = \text{cdf}_{t(n-1)}^{-1}\left(\frac{1+\gamma}{2}\right).$$

Альтернативно замену  $\sigma$  на  $s$  можно обосновать по теореме Slutsky.

*Утверждение (Слутский).* Если  $\xi_n \xrightarrow{d} \xi$ ,  $\eta_n \xrightarrow{P} c$ , то  $\xi_n + \eta_n \xrightarrow{d} \xi + c$  и  $\xi_n \eta_n \xrightarrow{d} c\xi$ .

Используя тот факт, что  $s \xrightarrow{P} \sigma$ , запишем

$$P\left(c_1 < \frac{\sqrt{n}(\bar{x} - a)}{\sigma} \frac{\sigma}{s} < c_2\right) \xrightarrow[n \rightarrow \infty]{} \Phi(c_2) - \Phi(c_1).$$

### 5.4. Асимптотический доверительный интервал для параметра на основе MLE

Если умеем находить  $\hat{\theta}_{MLE}$ , то по асимптотической нормальности,

$$\frac{\hat{\theta}_{MLE} - E\hat{\theta}_{MLE}}{\sqrt{D\hat{\theta}_{MLE}}} \xrightarrow{d} N(0, 1),$$

по асимптотической несмещенности,

$$\frac{\hat{\theta}_{MLE} - \theta}{\sqrt{D\hat{\theta}_{MLE}}} \xrightarrow{d} N(0, 1),$$

и, учитывая асимптотическую эффективность ( $D\hat{\theta}_{MLE}I_n(\theta) \xrightarrow[n \rightarrow \infty]{} 1$ ), запишем статистику

$$T = (\hat{\theta}_{MLE} - \theta) \sqrt{I_n(\theta)} \xrightarrow{d} N(0, 1).$$

Чтобы по аналогии с предыдущим выразить  $\theta$  в  $P(c_1 < T < c_2) = P(|T| < c_\gamma) = \gamma$ , необходимо выразить  $\theta$  из  $I_n(\theta)$ . Для Pois и Ber это эквивалентно решению квадратного уравнения.

В общем случае, можно вместо  $\theta$  в  $I_n(\theta)$  подставить  $\hat{\theta}_{MLE}$  (при  $n \rightarrow \infty$  это не должно сильно испортить дело), откуда

$$P(|T| < c_\gamma) = \gamma \iff P\left(-c_\gamma < (\hat{\theta}_{MLE} - \theta) \sqrt{I_n(\theta)} < c_\gamma\right) = \gamma \iff P\left(\theta \in \left(\hat{\theta}_{MLE} \pm \frac{c_\gamma}{\sqrt{I_n(\theta)}}\right)\right) = \gamma,$$

где

$$T \xrightarrow{d} N(0, 1) \implies c_\gamma = \text{cdf}_{N(0,1)}^{-1}\left(\frac{1+\gamma}{2}\right).$$

**Пример.**  $\xi \sim \text{Pois}(\lambda)$ . По 2.5.1,  $\hat{\lambda}_{MLE} = \bar{x}$ , по 2.5.2  $I_n(\lambda) = n/\lambda = n/\bar{x}$  откуда

$$P\left(\lambda \in \left(\bar{x} \pm \text{cdf}_{N(0,1)}^{-1}\left(\frac{1+\gamma}{2}\right) \frac{\sqrt{\bar{x}}}{\sqrt{n}}\right)\right) = \gamma.$$

**Пример.**  $\xi \sim \text{Ber}(p)$ .  $p = E\xi$ .  $\hat{p} = \bar{x}$ , откуда

$$P\left(p \in \left(\hat{p} \pm c_\gamma \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}\right)\right) \xrightarrow[n \rightarrow \infty]{} \gamma.$$

*Замечание.* Этот доверительный интервал не очень хорош, потому что не принадлежит  $[0, 1]$ .

## 5.5. Доверительный интервал для проверки гипотезы о значении параметра

Зафиксируем  $H_0 : \theta = \theta_0$  и  $\gamma = 1 - \alpha$ , где  $\alpha$  играет роль уровня значимости. По определению доверительного интервала,  $P(\theta \in [a_\gamma(\mathbf{x}), b_\gamma(\mathbf{x})]) = \gamma$ . Тогда разбиением будет

$$\mathcal{A}_{\text{дов}} = [a_\gamma(\mathbf{x}), b_\gamma(\mathbf{x})], \quad \mathcal{A}_{\text{крит}} = \mathbb{R} \setminus \mathcal{A}_{\text{дов}},$$

причем

$$P(\theta_0 \notin [a_\gamma(\mathbf{x}), b_\gamma(\mathbf{x})]) = \alpha.$$

Иными словами, попадание в критическую область происходит с уровнем значимости  $\alpha$ , что соответствует определению критерия.

### 5.5.1. Использование SE для построения доверительных интервалов

Пусть  $\hat{\theta}$  — асимптотически нормальная оценка параметра  $\theta$ . Чтобы сходимость оставалась верной, даже если подставляем оценку, нужна состоятельность. Тогда доверительный интервал для среднего с уровнем доверия  $\gamma$  имеет вид

$$E\hat{\theta} \pm c_\gamma \sqrt{D\hat{\theta}} \approx E\hat{\theta} \pm \text{cdf}_{N(0,1)}^{-1} \left( \frac{1+\gamma}{2} \right) \cdot \text{SE}.$$

## 6. Корреляционный и регрессионный анализы

**Определение.** Мера зависимости — это функционал  $r : (\xi, \eta) \mapsto x \in [-1, 1]$  со свойствами:

1.  $|r| \leq 1$ .
2.  $\xi \perp \eta \implies r(\xi, \eta) = 0$ .
3. Если  $\xi$  и  $\eta$  «максимально зависимы», то  $r(\xi, \eta) = 1$ .

### 6.1. Вероятностная независимость

#### 6.1.1. Визуальное определение независимости

- Поскольку при  $p_\eta(y_0) \neq 0$

$$\xi \perp \eta \iff p_{\xi|\eta}(x | y_0) = \frac{p_{\xi,\eta}(x, y_0)}{p_\eta(y_0)} = p_\xi(x),$$

то срезы графика совместной плотности при фиксированном  $y_0$  после нормировки  $p_\eta(y_0)$  должны выглядеть одинаково для всех  $y_0$ .

- Для выборки независимость можно попытаться определить по *таблицам сопряженности*: сгруппируем  $\{(x_i, y_i)\}_{i=1}^n$  и сопоставим каждой уникальной паре абсолютную частоту  $\nu_{ij}$ :

$$\begin{array}{cccc} & y_1^* & \cdots & y_s^* \\ x_1^* & \nu_{11} & \cdots & \nu_{1s} \\ \vdots & \vdots & \ddots & \vdots \\ x_k^* & \nu_{k1} & \cdots & \nu_{ks} \end{array}$$

Тогда признаки с большей чем случайной вероятностью будут независимы при пропорциональных строчках / столбцах. Более формально, признаки независимы, если

$$\frac{\nu_{ij}}{\sum_k \nu_{kj}} = \frac{\nu_{ij}}{\nu_{\cdot j}} = \hat{p}_{i|j} \propto \hat{p}_{i|\ell},$$

т.е. вероятности условного распределения не зависят от выбора строки.

**Пример.** Таблица сопряженности похожей на независимую выборки:

1	3	2
2	5	3
9	20	11

### 6.1.2. Критерий независимости $\chi^2$

По определению, для двумерных дискретных распределений, независимость есть

$$\xi \perp\!\!\!\perp \eta \iff \underbrace{P(\xi = i, \eta = j)}_{p_{ij}} = \underbrace{P(\xi = i)}_{p_{i\cdot}} \underbrace{P(\eta = j)}_{p_{\cdot j}} = \underbrace{\sum_{k=1}^K P(\xi = i, \eta = k)}_{p_{i\cdot}} \cdot \underbrace{\sum_{s=1}^S P(\xi = s, \eta = j)}_{p_{\cdot j}}.$$

Проверим  $H_0 : \xi \perp\!\!\!\perp \eta$ .

*Утверждение.* ОМП оценкой будет  $\hat{p}_{i\cdot} = \nu_{i\cdot}/n$  и  $\hat{p}_{\cdot j} = \nu_{\cdot j}/n$ .

Следовательно,

$$\xi \perp\!\!\!\perp \eta \iff \hat{p}_{ij} = \frac{\nu_{ij}}{n} = \hat{p}_{i\cdot} \hat{p}_{\cdot j} = \frac{\nu_{i\cdot}}{n} \cdot \frac{\nu_{\cdot j}}{n}.$$

Это равенство удается получить редко; важно определить, не является ли это нарушение случайным.

Запишем статистику

$$\chi^2 = \sum_{i=1}^K \sum_{j=1}^S \frac{(\nu_{ij} - n\hat{p}_{ij})^2}{n\hat{p}_{ij}} = \sum_{i=1}^K \sum_{j=1}^S \frac{(\nu_{ij} - \nu_{i\cdot}\nu_{\cdot j}/n)^2}{\nu_{i\cdot}\nu_{\cdot j}/n} \xrightarrow{d} \chi^2((k-1)(s-1))$$

Количество параметров таково, потому что если  $\xi \parallel \eta$ , то всего  $ks - 1$  параметров ( $-1$  потому что  $\sum_{ij} p_{ij} = 1$ ); если  $\xi \perp\!\!\!\perp \eta$ , то  $k + s - 2$  ( $-2$  потому что  $\sum_i p_{ij} = 1$  и  $\sum_j p_{ij} = 1$ ). Значит  $ks - 1 - k - s + 2 = (k-1)(s-1)$ .

**Пример.** Дано  $S$  кубиков. Проверить гипотезу, что кубики одинаковы.

*Решение.* FIXME ┘

*Замечание.* На маленьких выборках ( $n < 40$ ,  $np_{ij} < 5$ ) возникают проблемы со сходимостью, потому что можно объединять только столбцы / строки и каждый раз терять сразу  $S - 1$  ( $K - 1$ ) степень свободы. В этих случаях используют критерием с перестановкой<sup>11</sup> или, в случае таблиц сопряженности  $2 \times 2$ , точным критерием Фишера.

*Замечание.* Критерий верен для количественных, порядковых и качественных признаков, потому что нигде не участвуют значения из выборки.

*Замечание.* Критерий асимптотический, поэтому  $\alpha_1 \rightarrow \alpha$ .

*Замечание.* Критерий не удовлетворяет 1-му пункту определения меры зависимости ( $\chi^2 \notin [-1, 1]$ ). Это обычно исправляют так: рассматривают *среднеквадратичную сопряженность*

$$r^2 := \frac{\chi^2}{n}$$

или коэффициент сопряженности Пирсона

$$p^2 := \frac{\chi^2}{\chi^2 + n}$$

(тогда 1 никогда не достигается). Могли бы работать с  $1 - p\text{-value}$ , но так почему-то никогда не делают.

<sup>11</sup>[https://en.wikipedia.org/wiki/Resampling\\_\(statistics\)#Permutation\\_tests](https://en.wikipedia.org/wiki/Resampling_(statistics)#Permutation_tests)

## 6.2. Линейная / полиномиальная зависимость

Пусть теперь  $\xi, \eta$  — количественные признаки.

**Определение.** Определим

$$\phi(x) := E\{\eta \mid \xi = x\}.$$

Тогда назовем зависимость *линейной*, если  $\phi(x)$  — линейная функция, *квадратичной* — если квадратичная и т.д.




Рис. 3: Нелинейная зависимость




Рис. 4: Линейная зависимость

**Определение.** Мера *линейной* зависимости между случайными величинами  $\xi$  и  $\eta$  есть *коэффициент корреляции Пирсона*

$$\rho = \frac{\text{cov}(\xi, \eta)}{\sqrt{D\xi}\sqrt{D\eta}}.$$

*Замечание.* Про  $\rho$  можно думать как про  $\cos$  между векторами в соответствующем пространстве.

*Замечание (Важное).*

$$\begin{aligned} \xi \perp\!\!\!\perp \eta &\implies \rho = 0 \\ \xi, \eta \sim N(a, \sigma^2), \xi \perp\!\!\!\perp \eta &\iff \rho = 0. \end{aligned}$$

**Предложение.** Для линейно зависимых данных, конечно,  $\rho = 1$ .

*Доказательство.* Пусть  $\eta = a + b\xi$ ; тогда

$$\begin{aligned} \rho(\xi, \eta) &= \frac{\text{cov}(\xi, a + b\xi)}{\sqrt{D\xi}\sqrt{D(a + b\xi)}} = \frac{E\xi(a + b\xi) - E\xi E(a + b\xi)}{\sqrt{D\xi}\sqrt{Db\xi}} = \frac{E\xi a + bE\xi^2 - E\xi Ea - E\xi bE\xi}{b\sqrt{D\xi}\sqrt{D\xi}} = \\ &= \frac{aE\xi + bE\xi^2 - aE\xi - b(E\xi)^2}{bD\xi} = \frac{b(E\xi^2 - (E\xi)^2)}{bD\xi} = 1. \end{aligned}$$

□

**О соотношении  $\rho$  и коэффициента линейной регрессии** По (6.5.1), если линейная регрессия уравнением  $y = kx + b$ , то

$$k = \rho \frac{\sigma_\eta}{\sigma_\xi}.$$

В общем случае, по виду прямой линейной регрессии ничего нельзя сказать о зависимости между случайными величинами. Так, если  $\eta = a + b\xi$  есть линейная функция от  $\xi$ , то, по предыдущему,  $\rho = 1$  и

$$k = 1 \cdot \frac{\sqrt{D(a + b\xi)}}{\sqrt{D\xi}} = b$$

и прямая может иметь произвольный, в зависимости от  $b$ , наклон.



*Замечание.* В то же время, поскольку для

$$\begin{pmatrix} \xi \\ \eta \end{pmatrix} \sim N(\boldsymbol{\mu}, \Sigma), \quad \Sigma = \begin{pmatrix} \sigma_\xi^2 & \text{cov}(\xi, \eta) \\ \text{cov}(\xi, \eta) & \sigma_\eta^2 \end{pmatrix}$$

справедливо, что

$$k = \rho \frac{\sigma_\eta}{\sigma_\xi} = \frac{\text{cov}(\xi, \eta)}{\sigma_\xi \sigma_\eta} \cdot \frac{\sigma_\eta}{\sigma_\xi} = \frac{1}{\sigma_\xi^2} \text{cov}(\xi, \eta),$$

то  $k = 0 \iff \text{cov}(\xi, \eta) = 0$ , а для стандартно нормальных данных  $k = \rho = \text{cov}(\xi, \eta)$ .

### Значимость коэффициента корреляции

**Определение.** Коэффициент корреляции *значим*, если отвергается  $H_0 : \rho = 0$ .

Статистика для проверки значимости при  $(\xi, \eta)^T \sim N(\boldsymbol{\mu}, \Sigma)$  (иначе статистика асимптотическая)

$$T = \frac{\sqrt{n-2} \hat{\rho}_n}{\sqrt{1 - \hat{\rho}_n^2}} \sim t(n-2).$$

Идеальное значение — 0, два хвоста.

### 6.3. Метод наименьших квадратов (Ordinary Least Squares)

Пусть  $\eta, \xi \in L^2(\mathcal{F}, \mathbf{P})$  пространству  $\mathcal{F}$ -измеримых по мере  $\mathbf{P}$  функций с конечным вторым моментом и скалярным произведением  $(\eta, \xi) = \mathbf{E} \eta \xi$ , причем  $\hat{\eta} \in K = \{\phi(\xi)\} = \{\hat{\eta} : \sigma(\phi(\xi))\text{-измерима}\}$ . По свойству УМО(2.3.2), вектор

$$\hat{\eta}^* = \mathbf{E} \{\eta \mid \phi(\xi)\}$$

будет ортогональной проекцией  $\eta$  на  $K$ , т.е.  $(\eta - \hat{\eta}^*, \hat{\eta}) = 0 \forall \hat{\eta} \in K$ . Значит, он минимизирует квадрат нормы расстояния от  $\eta$  до  $K$ :

$$\hat{\eta}^* = \underset{\hat{\eta} \in K}{\operatorname{argmin}} \|\eta - \hat{\eta}\|^2 = \underset{\hat{\eta} \in K}{\operatorname{argmin}} \mathbf{E} (\eta - \hat{\eta})^2 = \mathbf{E} \{\eta \mid \phi(\hat{\eta})\}.$$

$\hat{\eta}^*$  называется *наилучшим среднеквадратичным приближением в классе  $K$* .

### 6.4. Корреляционное отношение

Если  $K = \mathcal{L} = \{a\xi + b\}$  — линейное пространство, то теорема Пифагора принимает вид

$$D\eta = \mathbf{E} (\eta - \mathbf{E}\eta)^2 = \underbrace{\mathbf{E} (\hat{\eta}^* - \mathbf{E}\eta)^2}_{\text{объяснённая доля аппроксимации}} + \underbrace{\mathbf{E} (\eta - \hat{\eta}^*)^2}_{\text{ошибка аппроксимации}}.$$

Откуда можно записать меру аппроксимации

$$\frac{\mathbf{E} (\hat{\eta}^* - \mathbf{E}\eta)^2}{D\eta} = 1 - \frac{\mathbf{E} (\eta - \hat{\eta}^*)^2}{D\eta} = 1 - \frac{\min_{\hat{\eta} \in \mathcal{L}} \mathbf{E} (\eta - \hat{\eta})^2}{D\eta}.$$

**Определение.** Полученная величина называется коэффициентом корреляции  $\rho^2$ :

$$\rho^2 := 1 - \frac{\min_{\hat{\eta} \in \mathcal{L}} \mathbf{E} (\eta - \hat{\eta})^2}{D\eta}.$$

$\rho$  — коэффициент корреляции Пирсона.

**Определение.** Множественный коэффициент корреляции есть полученная величина для МНК с  $K = \mathcal{M} = \left\{ \sum_{i=1}^k b_i \xi_i + b_0 \right\}$ .

$$R^2(\eta, \xi_1, \dots, \xi_k) := 1 - \frac{\min_{\hat{\eta} \in \mathcal{M}} \mathbf{E} (\eta - \hat{\eta})^2}{D\eta}.$$

*Замечание.*  $R^2 \geq \rho^2$ ; если же  $R^2 = \rho^2$ , то  $\xi_1, \dots, \xi_k$  все зависимы.

**Определение.** В общем случае, если  $K = \{\phi(\xi) \text{ измеримые}\}$ , то полученная величина называется *корреляционным отношением*:

$$r_{\eta|\xi}^2 := 1 - \frac{\min_{\hat{\eta} \in K} \mathbb{E}(\eta - \hat{\eta})^2}{D\eta} = \frac{D\mathbb{E}(\eta | \xi)}{D\eta}.$$

### Свойства корреляционного отношения

1.  $r_{\eta|\xi}^2 \in [0, 1]$ .
2.  $\eta \perp \xi \implies r_{\eta|\xi}^2 = 0$ .
3.  $\eta = \phi(\xi) \iff r_{\eta|\xi}^2 = 1$ .
4. Вообще говоря,  $r_{\eta|\xi}^2 \neq r_{\xi|\eta}^2$ . К примеру, для любой не монотонной функции (так, чтобы не существовала обратная).
5.  $r_{\eta|\xi}^2 \geq \rho^2(\eta, \xi)$  (потому что минимум по всем функциям меньше, чем лишь по линейным, значит  $1 - \min$  больше).
6.  $(\xi, \eta)^T \sim N(\mu, \Sigma) \implies r_{\eta|\xi}^2 = \rho^2(\eta, \xi)$ .

### Выборочное корреляционное отношение

$$\hat{r}_{\eta|\xi}^2 = \hat{r}_{y|x}^2 = \frac{s_{y|x}^2}{s_y^2}.$$

## 6.5. Регрессия

**Определение.** Регрессией  $\eta$  по  $\xi$  называется  $\mathbb{E}\{\eta | \xi\}$ .

*Замечание.* Таким образом осуществляется предсказание  $\eta$  по  $\xi$  с минимальной среднеквадратичной ошибкой.

**Определение.** Функция регрессии есть  $f(x) = \mathbb{E}\{\eta | \xi = x\}$ .

*Замечание.*  $f$  находится по МНК для  $K = \{\psi(\xi) : \psi \text{—измеримая}\}$ .

### Виды регрессий

- Нелинейными и линейными ( $K = \{a\xi + b\}$ );
- Парными (предсказывая величину по одной случайной величине) и множественными (по многим).

#### 6.5.1. Парная линейная регрессия

**Определение.** Пусть  $\xi, \eta \in L^2$ . Парной линейной регрессией  $\eta$  по  $\xi$  называется наилучшее среднеквадратичное приближение  $h_{\beta_1^*, \beta_2^*}(\xi) = \beta_1^* \xi + \beta_2^*$  в классе линейных по  $\xi$  функций  $K = \mathcal{L} = \{\beta_1 \xi + \beta_2\}$ . Иными словами,

$$h_{\beta_1^*, \beta_2^*}(\xi) = \operatorname{argmin}_{\beta_1, \beta_2} \|\eta - h_{\beta_1, \beta_2}(\xi)\|^2 = \mathbb{E}\{\eta | h_{\beta_1, \beta_2}(\xi)\} = \operatorname{argmin}_{\beta_1, \beta_2} \underbrace{\mathbb{E}(\eta - (\beta_1 \xi + \beta_2))^2}_{\phi(\beta_1, \beta_2)} = \beta_1^* \xi + \beta_2^*.$$

*Замечание.* Найти минимум  $\phi$  можно, как обычно, решив систему  $\partial\phi/\partial\beta_i = 0$ <sup>12</sup>.

*Утверждение.*  $\beta_1^*, \beta_2^*$  таковы, что

$$\frac{h(\xi) - E\eta}{\sqrt{D\eta}} = \rho \frac{\xi - E\xi}{\sqrt{D\xi}}.$$

Это уравнение задает линию регрессии. Иными словами,

$$h(\xi) = \underbrace{\rho \frac{\sqrt{D\eta}}{\sqrt{D\xi}}}_{\beta_1^*} \xi + \underbrace{E\eta - \rho \frac{\sqrt{D\eta}}{\sqrt{D\xi}} E\xi}_{\beta_2^*}.$$

Отсюда можно получить соотношение между коэффициентом линейной регрессии  $\beta_1^* = k$  (наклоном регрессионной прямой) и коэффициентом корреляции:

$$k = \rho \frac{\sigma_\eta}{\sigma_\xi}.$$

*Замечание.* Подстановкой проверяется, что

$$\phi(\beta_1^*, \beta_2^*) = \min_{\hat{\eta} \in K} E(\eta - \hat{\eta})^2 = D\eta(1 - \rho^2),$$

откуда можно найти уже известное выражение для коэффициента корреляции Пирсона

$$\rho^2(\eta, \xi) = 1 - \frac{\phi(\beta_1^*, \beta_2^*)}{D\eta} = 1 - \frac{\min_{\hat{\eta} \in H} E(\eta - \hat{\eta})^2}{D\eta}, \quad \hat{\eta} := h(\xi).$$

**Определение.** Линейная регрессия *значима*, если  $\beta_1^* \neq 0 \implies \rho \neq 0$ . Значимость регрессии эквивалентна значимости предсказания по ней.

**Определение.** Величина *sum of squares residual* есть

$$SSR = n \cdot \phi(\beta_1^*, \beta_2^*) = \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad \hat{y}_i = h_{\beta_1^*, \beta_2^*}(x_i).$$

### 6.5.2. Модель линейной регрессии

Можно описать выборку как

$$y_i = \beta_1 x_i + \beta_2 + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2), \quad \epsilon_i \perp \epsilon_j.$$

$\sigma^2$  — мешающий параметр, который можно оценить через  $SSR/n$ . Но если  $\epsilon_i \sim N(0, \sigma^2)$ , то

$$\hat{\sigma}^2 = \frac{SSR}{n-2}$$

есть несмещенная оценка  $\sigma^2$ . Значит,

$$\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sigma^2} \sim \chi^2(n-2).$$

*Замечание.* МНК минимизирует разницу  $y_i - \hat{y}_i$ , что на графике соответствует вертикальным отрезкам, соединяющим  $y_i$  и  $\hat{y}_i = h(x_i)$ . Это не то же, что минимизация перпендикуляров от  $y_i$  на  $h(x)$  — техники метода анализа главных компонент («РСА»).

*Замечание.* Существует три базовых модели, в которых функция регрессии линейная:

- $\eta = \beta_1 \xi + \beta_2 + \epsilon$ ,  $\epsilon \perp \xi$ ,  $E\epsilon = 0$ .
- $(\xi, \eta)^T \sim N(\mu, \sigma^2)$ .
- $\xi$  принимает всего два значения (возможно, как качественный признак).

<sup>12</sup>См. [https://en.wikipedia.org/wiki/Simple\\_linear\\_regression](https://en.wikipedia.org/wiki/Simple_linear_regression)

### 6.5.3. Доверительные интервалы для $\beta_1$ и $\beta_2$

Как обычно, помимо точечной оценки  $\hat{\beta}_1$  и  $\hat{\beta}_2$ , интересуемся диапазоном значений, которые может принимать оценка с заданной вероятностью. Примем предположение о несмещенности оценки, т.е.  $E\hat{\beta}_i = \beta_i$ . Поскольку в модели  $y_i = \beta_1 x_i + \beta_2 + \epsilon_i$  ошибка  $\epsilon_i \sim N(0, \sigma^2)$  есть случайная величина, оценки  $\hat{\beta}_i$  — тоже становятся случайными величинами:  $\hat{\beta}_i \sim N(\beta_i, D\hat{\beta}_i)$ . В курсе регрессионного анализа доказывается<sup>13</sup>, что

$$D\hat{\beta}_1 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad D\hat{\beta}_2 = \frac{\sigma^2}{n}.$$

Кроме того,

$$SE(\hat{\beta}_1) = \sqrt{D\hat{\beta}_1} = \frac{\hat{\sigma}}{\sqrt{ns_x}} = \frac{\sqrt{\frac{SSR}{n-2}}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}, \quad SE(\hat{\beta}_2) = SE(\hat{\beta}_1) \cdot s_x$$

**Предложение.** *Статистика*

$$t = \frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\frac{1}{n-2} \sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} \sim t(n-2).$$

*Доказательство.* Известно,

$$t \sim t(m) \iff t = \frac{\xi}{\sqrt{\eta/m}}, \quad \xi \sim N(0, 1), \quad \eta \sim \chi^2(m).$$

Ясно, что

$$\frac{\hat{\beta}_1 - \beta_1}{\frac{\sigma}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}} \sim N(0, 1), \quad \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sigma^2} \sim \chi^2(n-2).$$

Тогда

$$\frac{\left( \frac{\hat{\beta}_1 - \beta_1}{\left( \frac{\sigma}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}} \right)} \right)}{\left( \frac{\left( \frac{\sqrt{\sum_{i=1}^n (y_i - \hat{y}_i)^2}}{\sigma} \right)}{\sqrt{n-2}} \right)} = \frac{(\hat{\beta}_1 - \beta_1) \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}{\frac{\sigma}{\sqrt{\sum_{i=1}^n \hat{\epsilon}_i^2}}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\frac{1}{n-2} \sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} \sim t(n-2).$$

□

Используя статистику  $t$ , введем доверительные интервалы с  $c_\gamma = \text{cdf}_{t(n-2)}^{-1}((1+\gamma)/2)$ :

$$t \in (-c_\gamma, c_\gamma) \iff \frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)} \in (-c_\gamma, c_\gamma) \iff \beta_1 \in \left( \hat{\beta}_1 - c_\gamma SE(\hat{\beta}_1), \hat{\beta}_1 + c_\gamma SE(\hat{\beta}_1) \right).$$

Аналогично, для  $\beta_2$ :

$$\beta_2 \in \left( \hat{\beta}_2 - c_\gamma SE(\hat{\beta}_2), \hat{\beta}_2 + c_\gamma SE(\hat{\beta}_2) \right).$$

<sup>13</sup>См. [https://en.wikipedia.org/wiki/Proofs\\_involving\\_ordinary\\_least\\_squares](https://en.wikipedia.org/wiki/Proofs_involving_ordinary_least_squares)

*Замечание.* На картинке доверительные интервалы изображаются в виде «рукавов» вокруг графика линейной регрессии — т.е. область всевозможных положений прямой при варьировании  $\beta_1, \beta_2$  в заданных интервалах.

**Пример.** Линейная регрессия как предсказательная модель может быть использована неправильно в следующих случаях:

- неправильная модель;
- применение к неоднородным данным (аутлаер или неоднородность);
- хотим построить предсказание в точке, далекой от данных (проблема — большая ошибка);
- не знаем какая модель там, где данных нет.

## 6.6. Частная корреляция

**Определение.** Частная корреляция случайных величин  $\eta_1, \eta_2$  относительно  $\{\xi_1, \dots, \xi_k\}$  есть

$$\rho(\eta_1, \eta_2 \mid \{\xi_1, \dots, \xi_k\}) := \rho(\eta_1 - \hat{\eta}_1^*, \eta_2 - \hat{\eta}_2^*), \quad \text{где } \hat{\eta}_i^* = \underset{\hat{\eta}_i \in \{\sum_{i=1}^k b_i \xi_i + b_0\}}{\operatorname{argmin}} \mathbb{E}(\eta_i - \hat{\eta}_i)^2.$$

Если регрессия линейна, то

$$\rho(\eta_1, \eta_2 \mid \xi_1, \dots, \xi_k) = \rho(\eta_1 - \mathbb{E}\{\eta_1 \mid \xi_1, \dots, \xi_k\}, \eta_2 - \mathbb{E}\{\eta_2 \mid \xi_1, \dots, \xi_k\}).$$

*Замечание (Важное).* Пусть в эксперименте подсчитан ненулевой  $\rho$ . Это может означать, что один из факторов является причиной, а другой следствием; чтобы установить, что есть что, проводят эксперимент и смотрят, какой фактор в реальности влияет на какой. Это может также означать, что влияет сторонний фактор. Чтобы его исключить, считают частную корреляцию.

**Пример.** Возможна ситуация, когда  $\rho(\eta_1, \eta_2) \neq 0$ , но  $\rho(\eta_1, \eta_2 \mid \xi) = 0$ . Частная корреляция есть, по сути, корреляция на центрированных данных.




Рис. 5: Исходные данные (бимодальность)




Рис. 6: Центрированные данные

**Пример.** Возможна и ситуация как на (7), где определено  $\rho(\eta_1, \eta_2) > 0$ , но  $\rho(\eta_1, \eta_2 \mid \xi) < 0$ .




Рис. 7:  $\rho(\eta_1, \eta_2) > 0$ , но  $\rho(\eta_1, \eta_2 \mid \xi) < 0$

*Замечание.* По аналогии с предыдущим примером, если  $|\text{im } \xi| \rightarrow \infty$ , то графики  $(\eta_1, \eta_2)$  при фиксированном  $\xi$  образуют эллипсоид (в этом случае с положительной корреляцией).

## 6.7. Зависимость между порядковыми признаками

Пусть на выборке

$$\begin{pmatrix} \xi \\ \eta \end{pmatrix} \sim \begin{pmatrix} x_1 \\ y_1 \end{pmatrix}, \dots, \begin{pmatrix} x_n \\ y_n \end{pmatrix}$$

задан только порядок. Тогда можем считать только эмпирическую функцию распределения.

Следующие коэффициенты основаны на рангах. Ранговые характеристики хорошо работают на выборках *без повторений* (чтобы, к примеру, не возникало дробных рангов).

### 6.7.1. Ранговый коэффициент Спирмана

**Определение.** Ранговый коэффициент Спирмана есть

$$\rho_S = \rho(\text{cdf}_\xi(\xi), \text{cdf}_\eta(\eta)).$$

*Замечание.*  $\text{cdf}_\xi(\xi) \sim U(0, 1)$ , потому что  $P(\text{cdf}_\xi(\xi) < x) = P(\xi < \text{cdf}_\xi^{-1}(x)) = \text{cdf}_\xi(\text{cdf}_\xi^{-1}(x)) = x$ .

**Определение.** Ранг элемента из выборки есть его порядковый номер в упорядоченной выборке:

$$\text{rk } x_{(i)} = i.$$

*Обозначение.*  $\text{rk } x_{(i)} =: R_i$ ,  $\text{rk } y_{(i)} =: T_i$ .

Можем ввести эмпирическое распределение

$$\text{cdf}_{\xi_n}(x_i) = \frac{\text{rk } x_i}{n}, \quad \text{cdf}_{\eta_n}(y_i) = \frac{\text{rk } y_i}{n} = \frac{T_i}{n}.$$

Тогда будет справедливо следующее

**Определение.** Выборочный коэффициент Спирмана определяется как выборочный коэффициент корреляции Пирсона  $\hat{\rho}$ , но с заменой значений на ранги:

$$\hat{\rho}_S \begin{pmatrix} \xi_n \\ \eta_n \end{pmatrix} = \rho \begin{pmatrix} R_n \\ T_n \end{pmatrix} = \frac{1/n \cdot \sum_{i=1}^n R_i T_i - \bar{R} \bar{T}}{\sqrt{1/n \cdot \sum_{i=1}^n (R_i - \bar{R})^2} \sqrt{1/n \cdot \sum_{i=1}^n (T_i - \bar{T})^2}}.$$

Если нет повторяющихся наблюдений, то знаменатель будет одним и тем же у всех выборок объема  $n$ , значит его можно посчитать заранее. В этом (и только этом) случае, справедлива более простая формула:

$$\hat{\rho}_S = 1 - \frac{6 \sum_{i=1}^n (R_i - T_i)^2}{n^3 - n}.$$

*Замечание.* Из последней формулы хорошо видно, что если  $x_i, y_i$  все идут в одном порядке, то  $R_i - T_i = 0 \forall i$  и  $\hat{\rho}_S = 1$ .

*Замечание.*  $\rho_S$  для количественных признаков есть мера монотонной зависимости:

$$\rho_S = 1 \iff (x_i > x_{i+1} \implies y_i > y_{i+1} \forall i)$$

(даже если зависимость нелинейная и  $\rho \neq 1$ ). Иными словами,  $\rho_S > 0$ , если  $y$  имеет тенденцию к возрастанию с возрастанием  $x$  (и  $\rho_S < 0$  иначе). Чем большее  $\rho_S$ , тем более явно выражена зависимость  $y$  от  $x$  в виде некоторой монотонной функции.

**Согласованность  $\rho$  и  $\rho_S$**   $\rho_S$  не согласована с  $\rho$  в том же смысле, что  $\rho$  и  $r_{\xi|\eta}$ .

*Утверждение.* Если данные нормальные то справедлива формула

$$\rho = 2 \sin\left(\frac{\pi}{6} \rho_S\right).$$

Значит, можем сравнить критерии между собой.

- С точностью до погрешности, по значению,  $\hat{\rho}$  и  $\hat{\rho}_S$  — это одно и то же (см. 8)




Рис. 8:  $\hat{\rho} \approx \hat{\rho}_S$

- Обычный критерий оценки — выборочную дисперсию — посчитать сложно. Тем не менее, можем заметить, что  $\hat{\rho}_S$  более устойчив к аутлаерам (см. 9). Всегда можно добавить аутлаер такой, что  $\hat{\rho} = 0$ ;  $\hat{\rho}_S$  же поменяется не сильно. Поэтому для нормальных данных,  $\rho_S$  — это оценка, что нет аутлаеров.




Рис. 9:  $\hat{\rho}$  до и после добавления аутлаера

- Монотонным преобразованием можем всегда сделать так, чтобы  $\rho$  изменился (например, возведя в квадрат); при монотонном преобразовании, однако, не меняется  $\rho_S$  (см. 10). Значит, чтобы узнать  $\rho$  исходных (нормальных) данных, можно не выполнять обратного преобразования, а сразу посчитать  $\rho_S$ .




Рис. 10: Монотонное преобразование нормальных данных

### 6.7.2. Ранговый коэффициент Кэндалла $\tau(\xi, \eta)$

**Определение.** Пусть  $(\xi_1, \eta_1)^T \perp (\xi_2, \eta_2)^T \sim \mathcal{P}_{\xi, \eta} \sim (\xi, \eta)^T$ ; тогда *ранговым коэффициентом Кэндалла* называется

$$\tau(\xi, \eta) = \rho(\text{sign}(\xi_2 - \xi_1), \text{sign}(\eta_2 - \eta_1)) = P((\xi_2 - \xi_1)(\eta_2 - \eta_1) > 0) - P((\xi_2 - \xi_1)(\eta_2 - \eta_1) < 0).$$

На выборочном языке, пусть дана выборка  $(x_1, y_1), \dots, (x_n, y_n)$ ; тогда

$$\tau = \frac{\#(\text{одинаково упорядоченных пар}) - \#(\text{по-разному упорядоченных пар})}{\#(\text{комбинаций пар})},$$

где пара  $(x_i, y_i), (x_j, y_j)$  считается одинаково упорядоченной, если  $\text{sign}(x_i - x_j) = \text{sign}(y_i - y_j)$ , а  $\#(\text{комбинаций пар}) = C_n^2 = n(n-1)/2$ .

*Утверждение.* Если  $(\xi, \eta)^T \sim N(\boldsymbol{\mu}, \Sigma)$ , то справедлива формула

$$\rho = \sin\left(\frac{\pi}{2}\tau\right).$$



Из утверждения следует, что  $\tau$  все время меньше  $\rho$  и  $\rho_S$  (по модулю).




Рис. 11:  $\rho$  и  $\tau$

**Пример** (Проверка ряда на тренд). Пусть  $\xi$  — номера точек, а  $\eta$  — значения ряда. Тогда  $H_0$  :  $\tau_0 = 0$  и если  $H_0$  отвергается, то тренд присутствует.

## 6.8. Корреляционные матрицы

Если признаков много, то их наглядно характеризуют корреляционные матрицы. Улучшить наглядность можно переупорядочив признаки так, чтобы на диагонали матрицы стояли блоки корреляций признаков из «корреляционных плеяд».

**Определение.** Пусть  $\rho_0$ ; корреляционная плеяда есть множество признаков, таких, что их попарная корреляция больше  $\rho_0$ .

Можно выделить и несколько уровней  $\rho_i$  :  $\rho_0 < \rho_1 < \dots$ . Тогда сначала следует составить плеяду по  $\rho_0$ , затем внутри полученного по  $\rho_1$  и т.д.

## А. Другие полезные распределения случайных величин

### А.1. Пуассона

### А.2. Логнормальное

## В. Свойства условного математического ожидания

1.  $E\{a\xi + b\theta \mid \eta\} = aE\{\xi \mid \eta\} + bE\{\theta \mid \eta\}.$

2.  $E E\{\eta \mid \xi\} = E\eta.$

3.  $\xi \perp \eta \implies E\{\xi \mid \eta\} = E\xi.$

4.  $\eta = f(\xi) \implies E\{\eta \mid \xi\} = E\{f(\xi) \mid \xi\} = f(\xi).$

5.  $E(\eta f(\xi) \mid f(\xi)) = f(\xi)E\{\eta \mid \xi\}.$

6.  $(\xi, \eta)^T \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies E(\xi \mid \eta) = a\eta + b.$

*Замечание* (Важное). Таким образом, если выборка нормальная, то зависимость линейная всегда.

7.  $\operatorname{argmin}_{\hat{\eta} \in K = \{\phi(\xi)\}} E(\eta - \hat{\eta})^2 = E\{\eta \mid \xi\} = \hat{\eta}^*.$